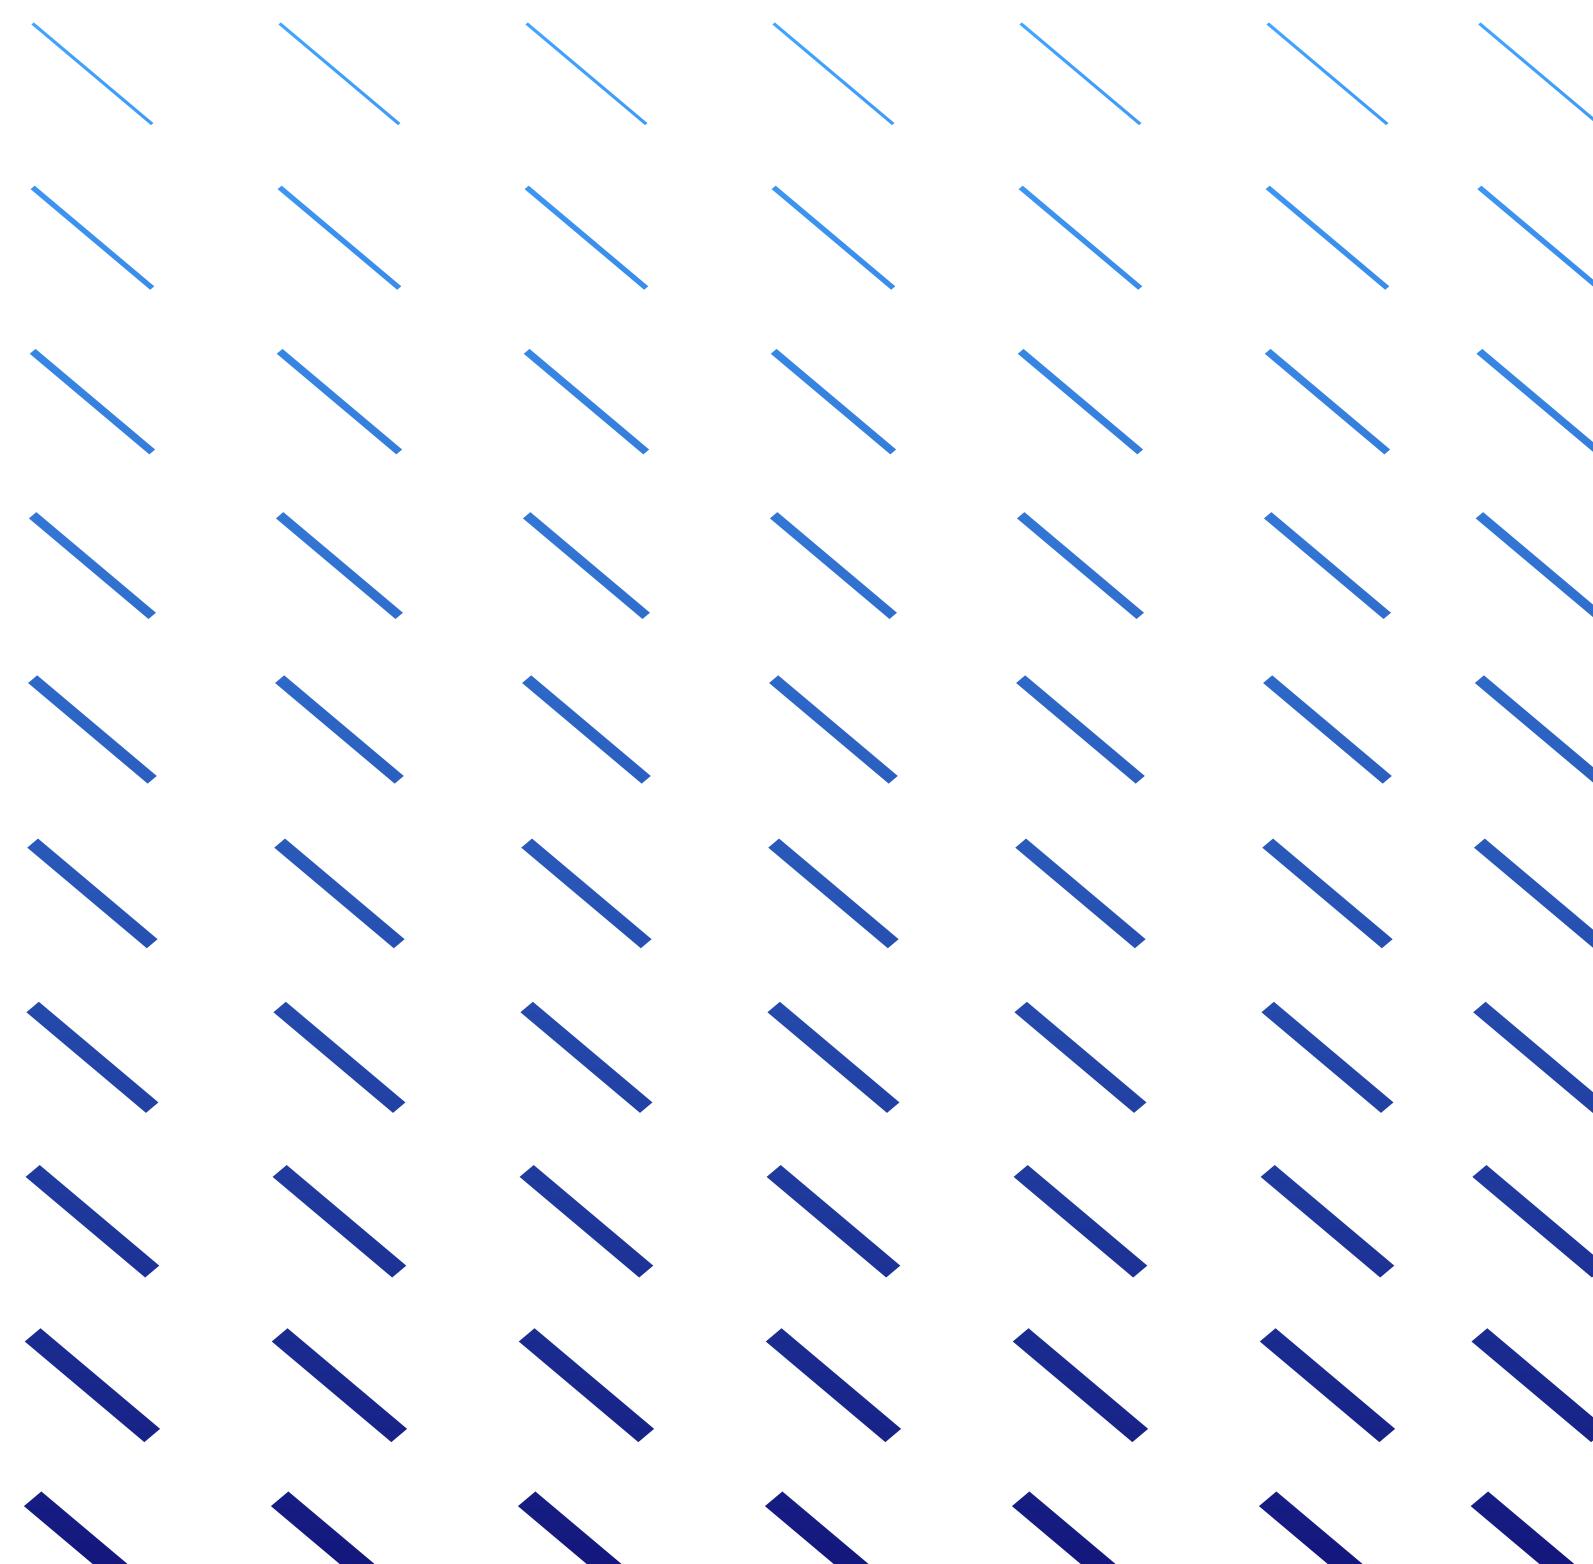


AI Software Update

문제성 김동현 권순범 이연준

Contents



프로젝트 소개

Abalone

Pulsar Star

Faulty Steel

프로젝트 정리 / 회고

프로젝트 개요

프로젝트 목적

C사의 AI R&D 그룹에서는 세 가지 데이터에 따른 회귀, 이진 판단, 다중 분류를 수행할 수 있는 프로그램 개선을 희망. 사전에 제작이 완료된 코드가 있으나, 이는 Numpy 위주로 개발된 레거시 코드기에 리팩터링, AI 성능 고도화, UI/UX 개선이 동시에 요구됨.

프로젝트 수행 방안

리팩터링을 통한 AI 성능 고도화를 위해 Tensorflow 라이브러리를 이용하여 Deep Learning 코드를 구현함. 가독성을 높히고, 유지 및 보수를 편하게 할 수 있도록 수정함. 또한 유저 친화적으로 사용될 수 있도록 UI/UX를 개선하기 위해 Django를 이용해 웹 서비스를 구현함. Abalone, Pulsar Star, Faulty Steel 각 데이터마다 기존 레거시 코드의 accuracy를 확인하고 모델에 맞는 성능 향상을 시도하였음.

프로젝트 소개

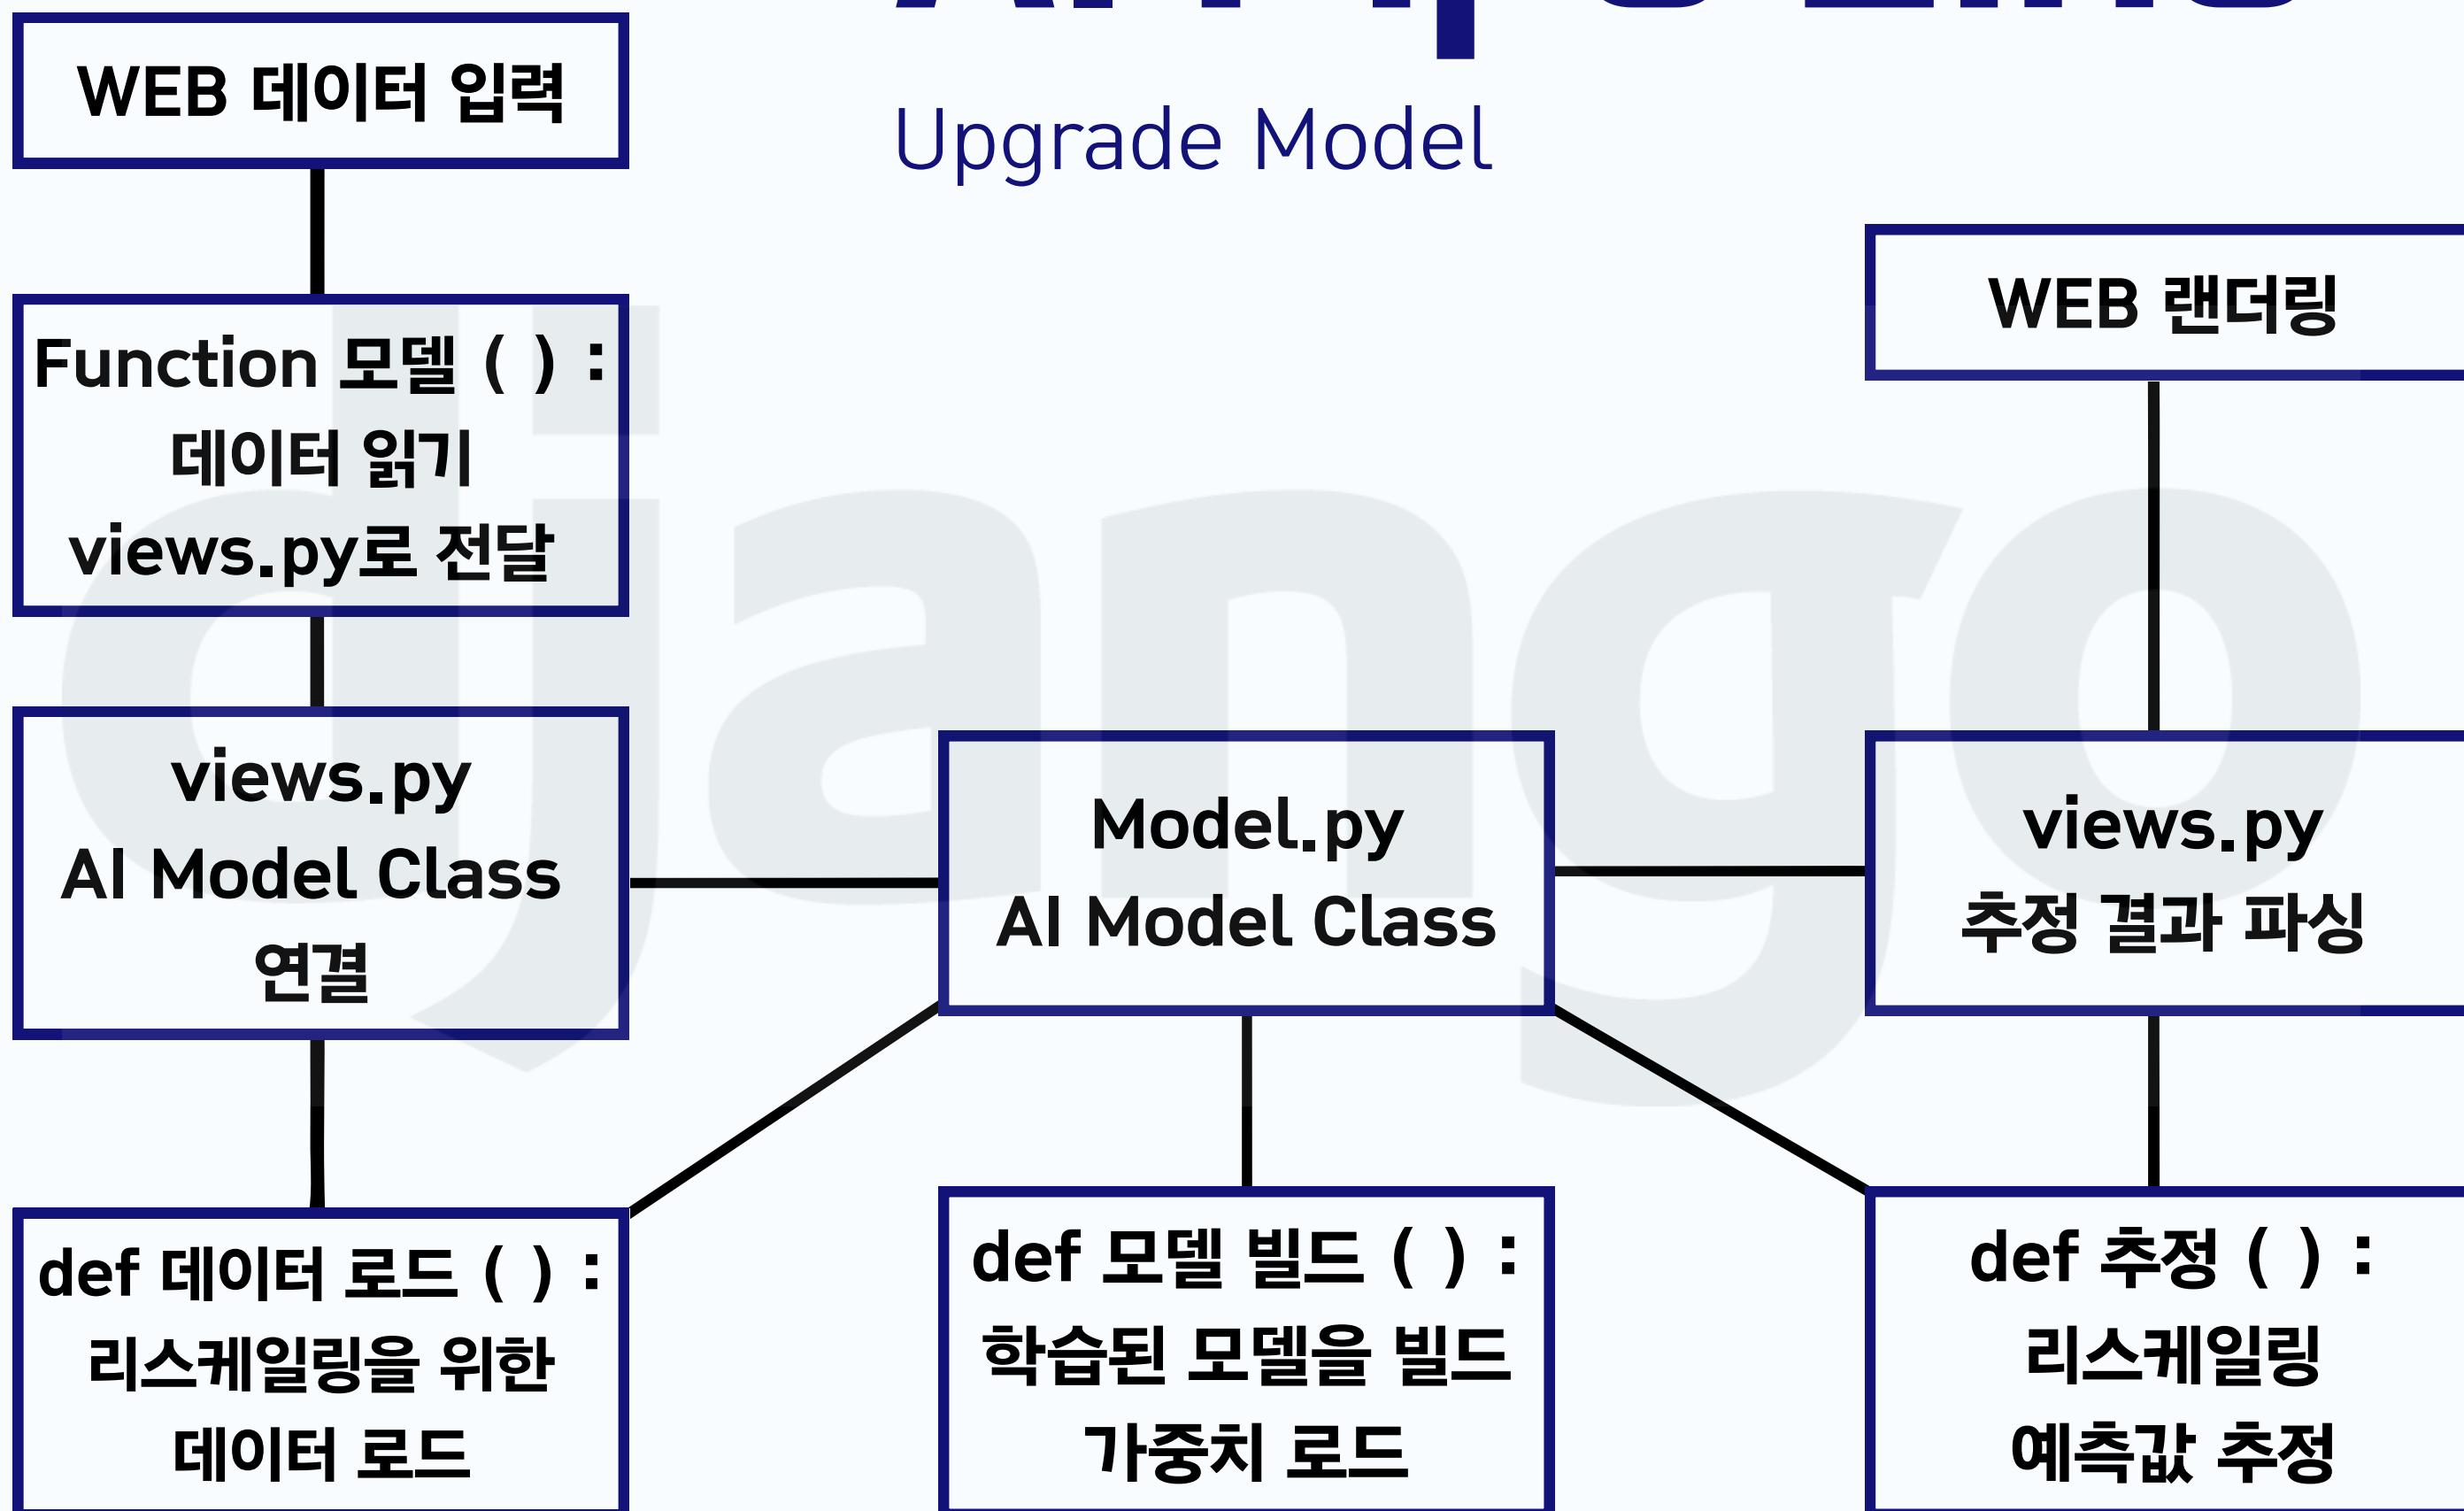
Abalone
(Regression Model)

Pulsar Star
(Binary classification)

Faulty Steel
(Multi Classification)

- **전복 연령 예측 회귀 모델**
 - 전복의 크기, 무게, 껍질 무늬 등으로 전복의 연령을 예측
- **맥동성(Pulsar Star) 여부 예측 이진분류 모델**
 - 별의 파장, 파형 등의 정보로 깜빡이는 별 여부를 예측
- **강철판의 결함 종류 예측 모델**
 - 철판의 휘어짐, 두께 등으로 철판의 결함 종류를 예측

AI Pipe Line



Abalone

Domain Understanding



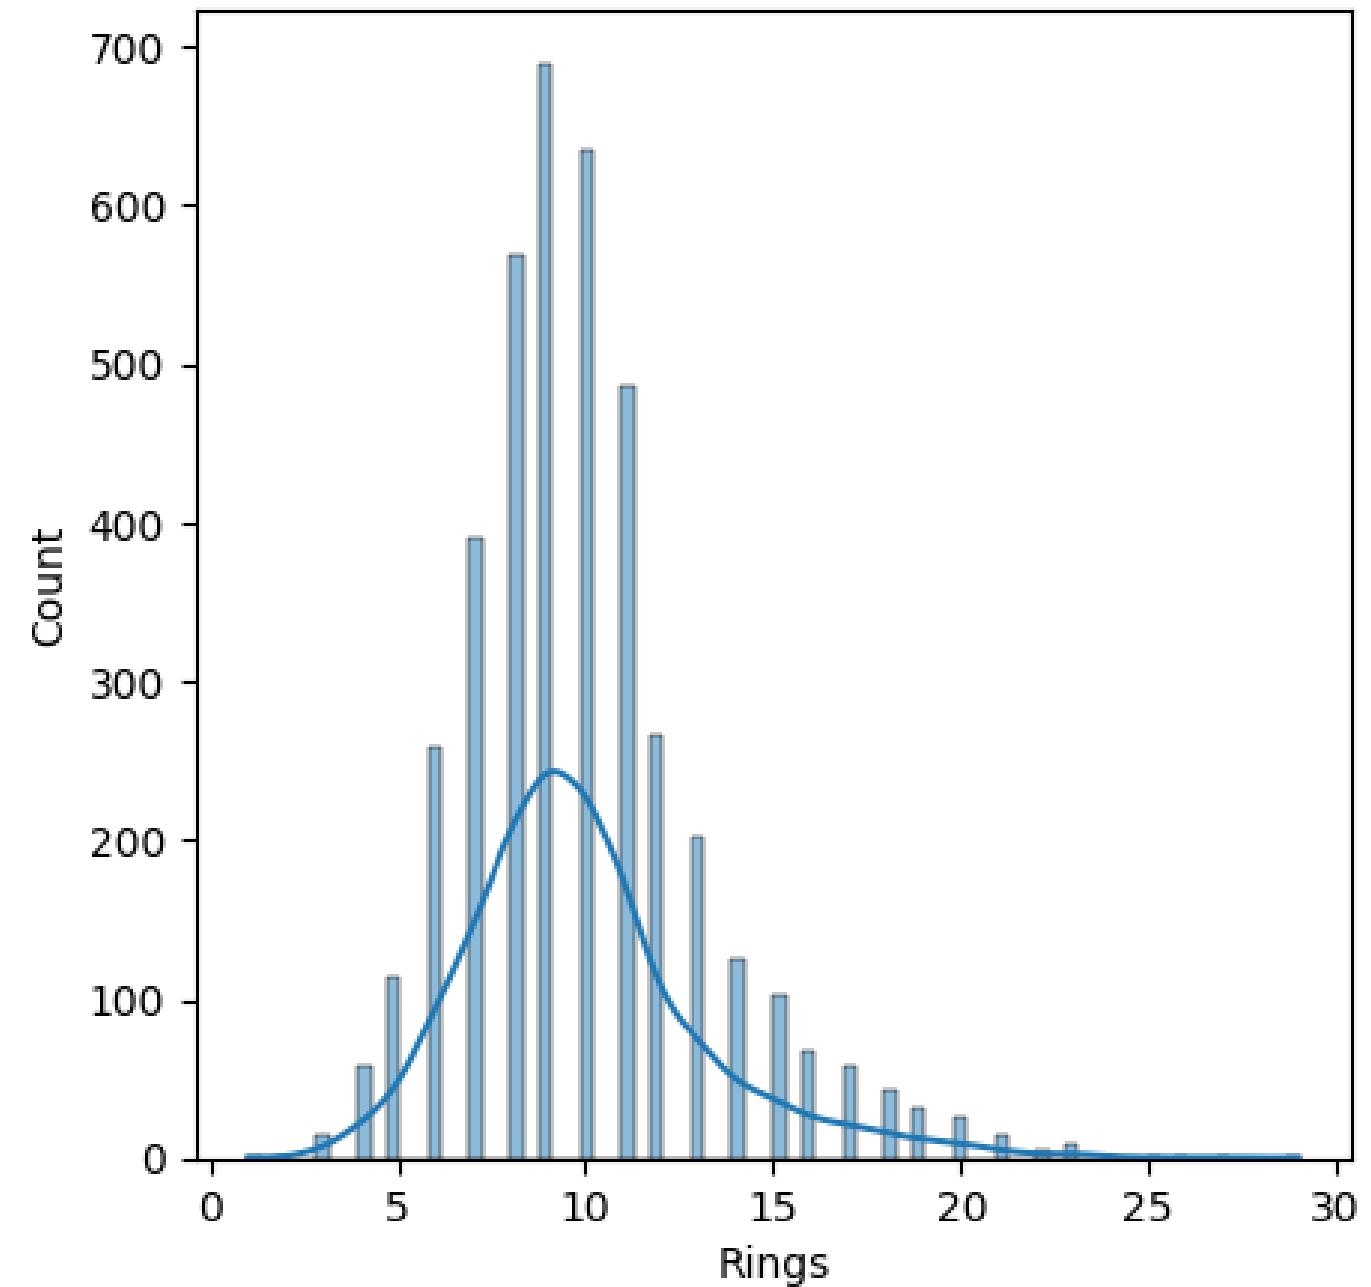
전복의 나이?

- 전복의 나이는 보통 껍질에 있는 고리의 수를 세어 판단



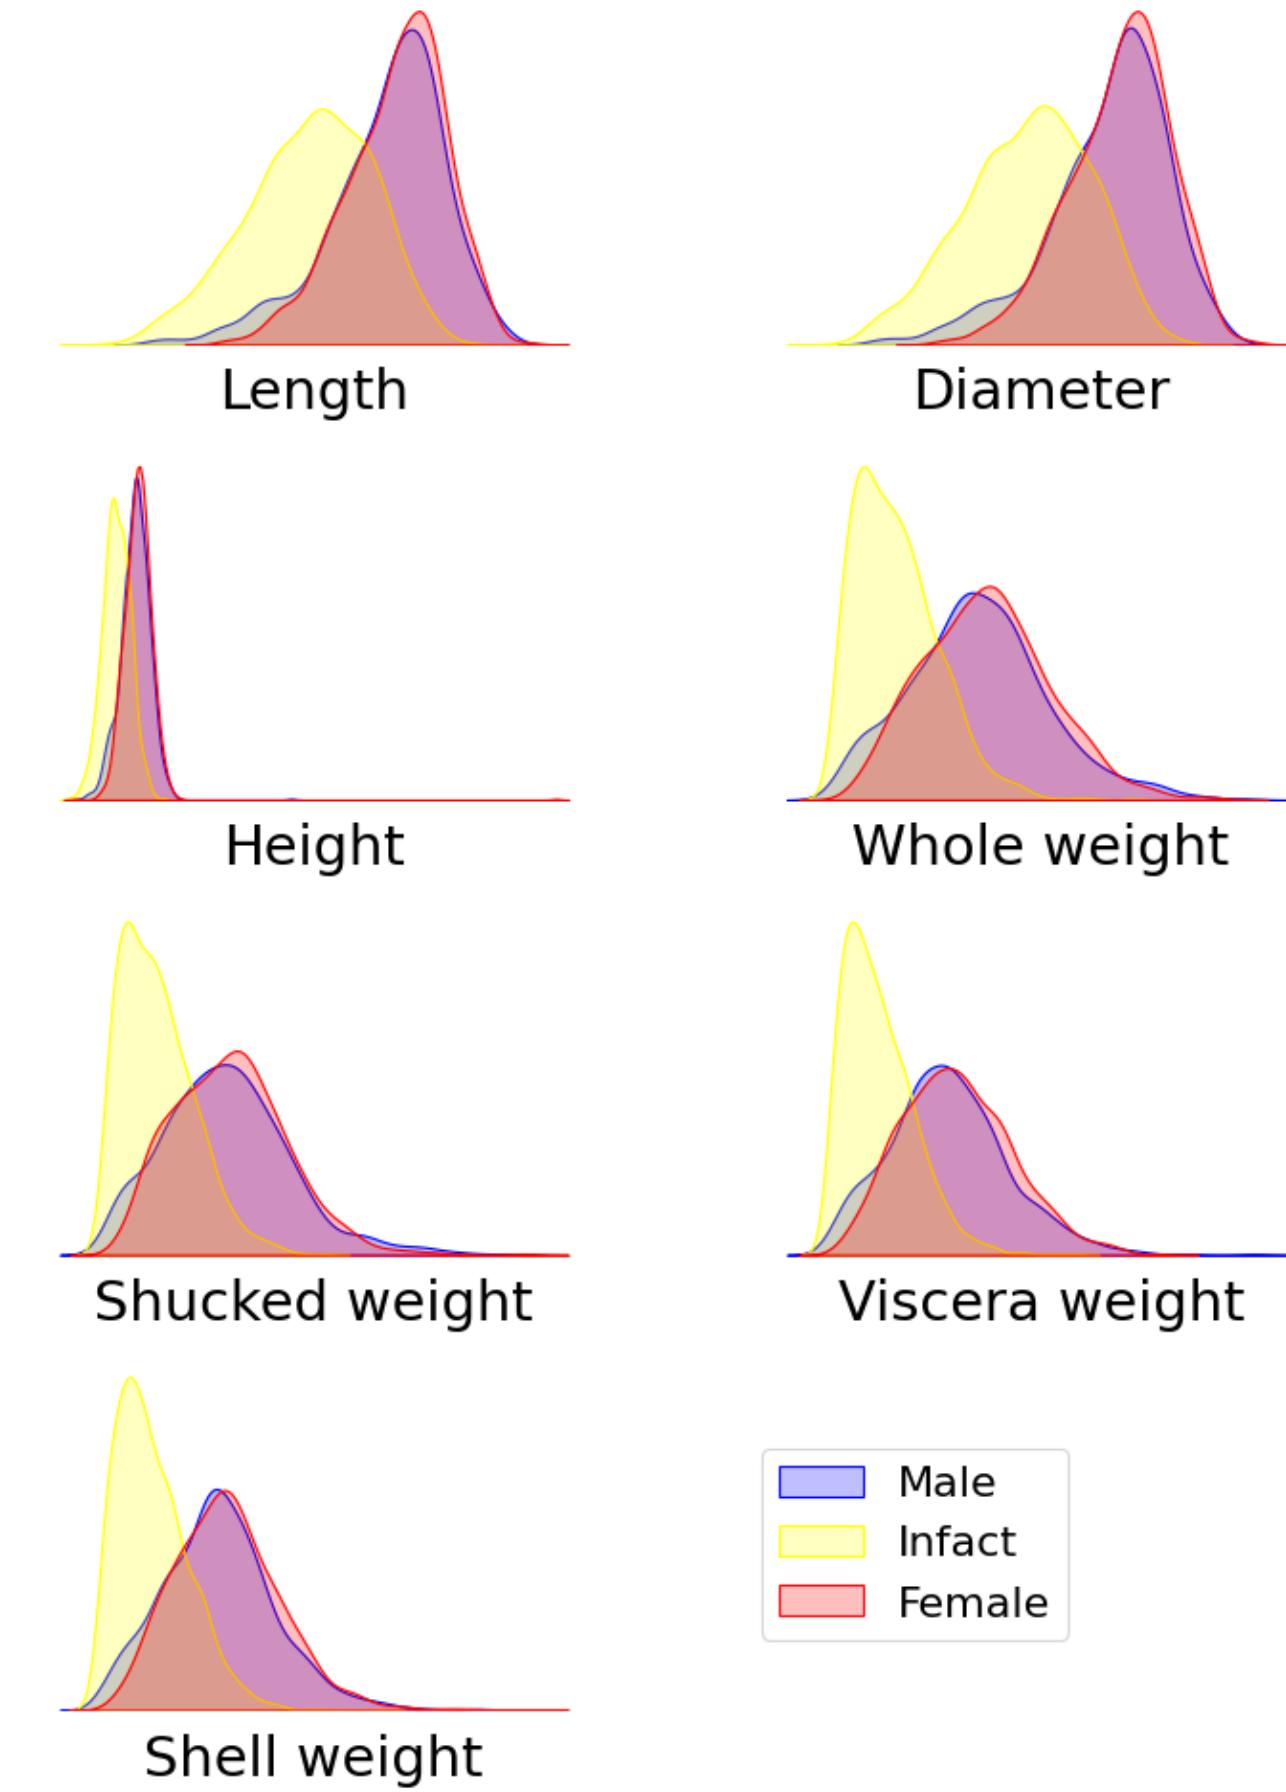
Abalone

Exploratory data analysis



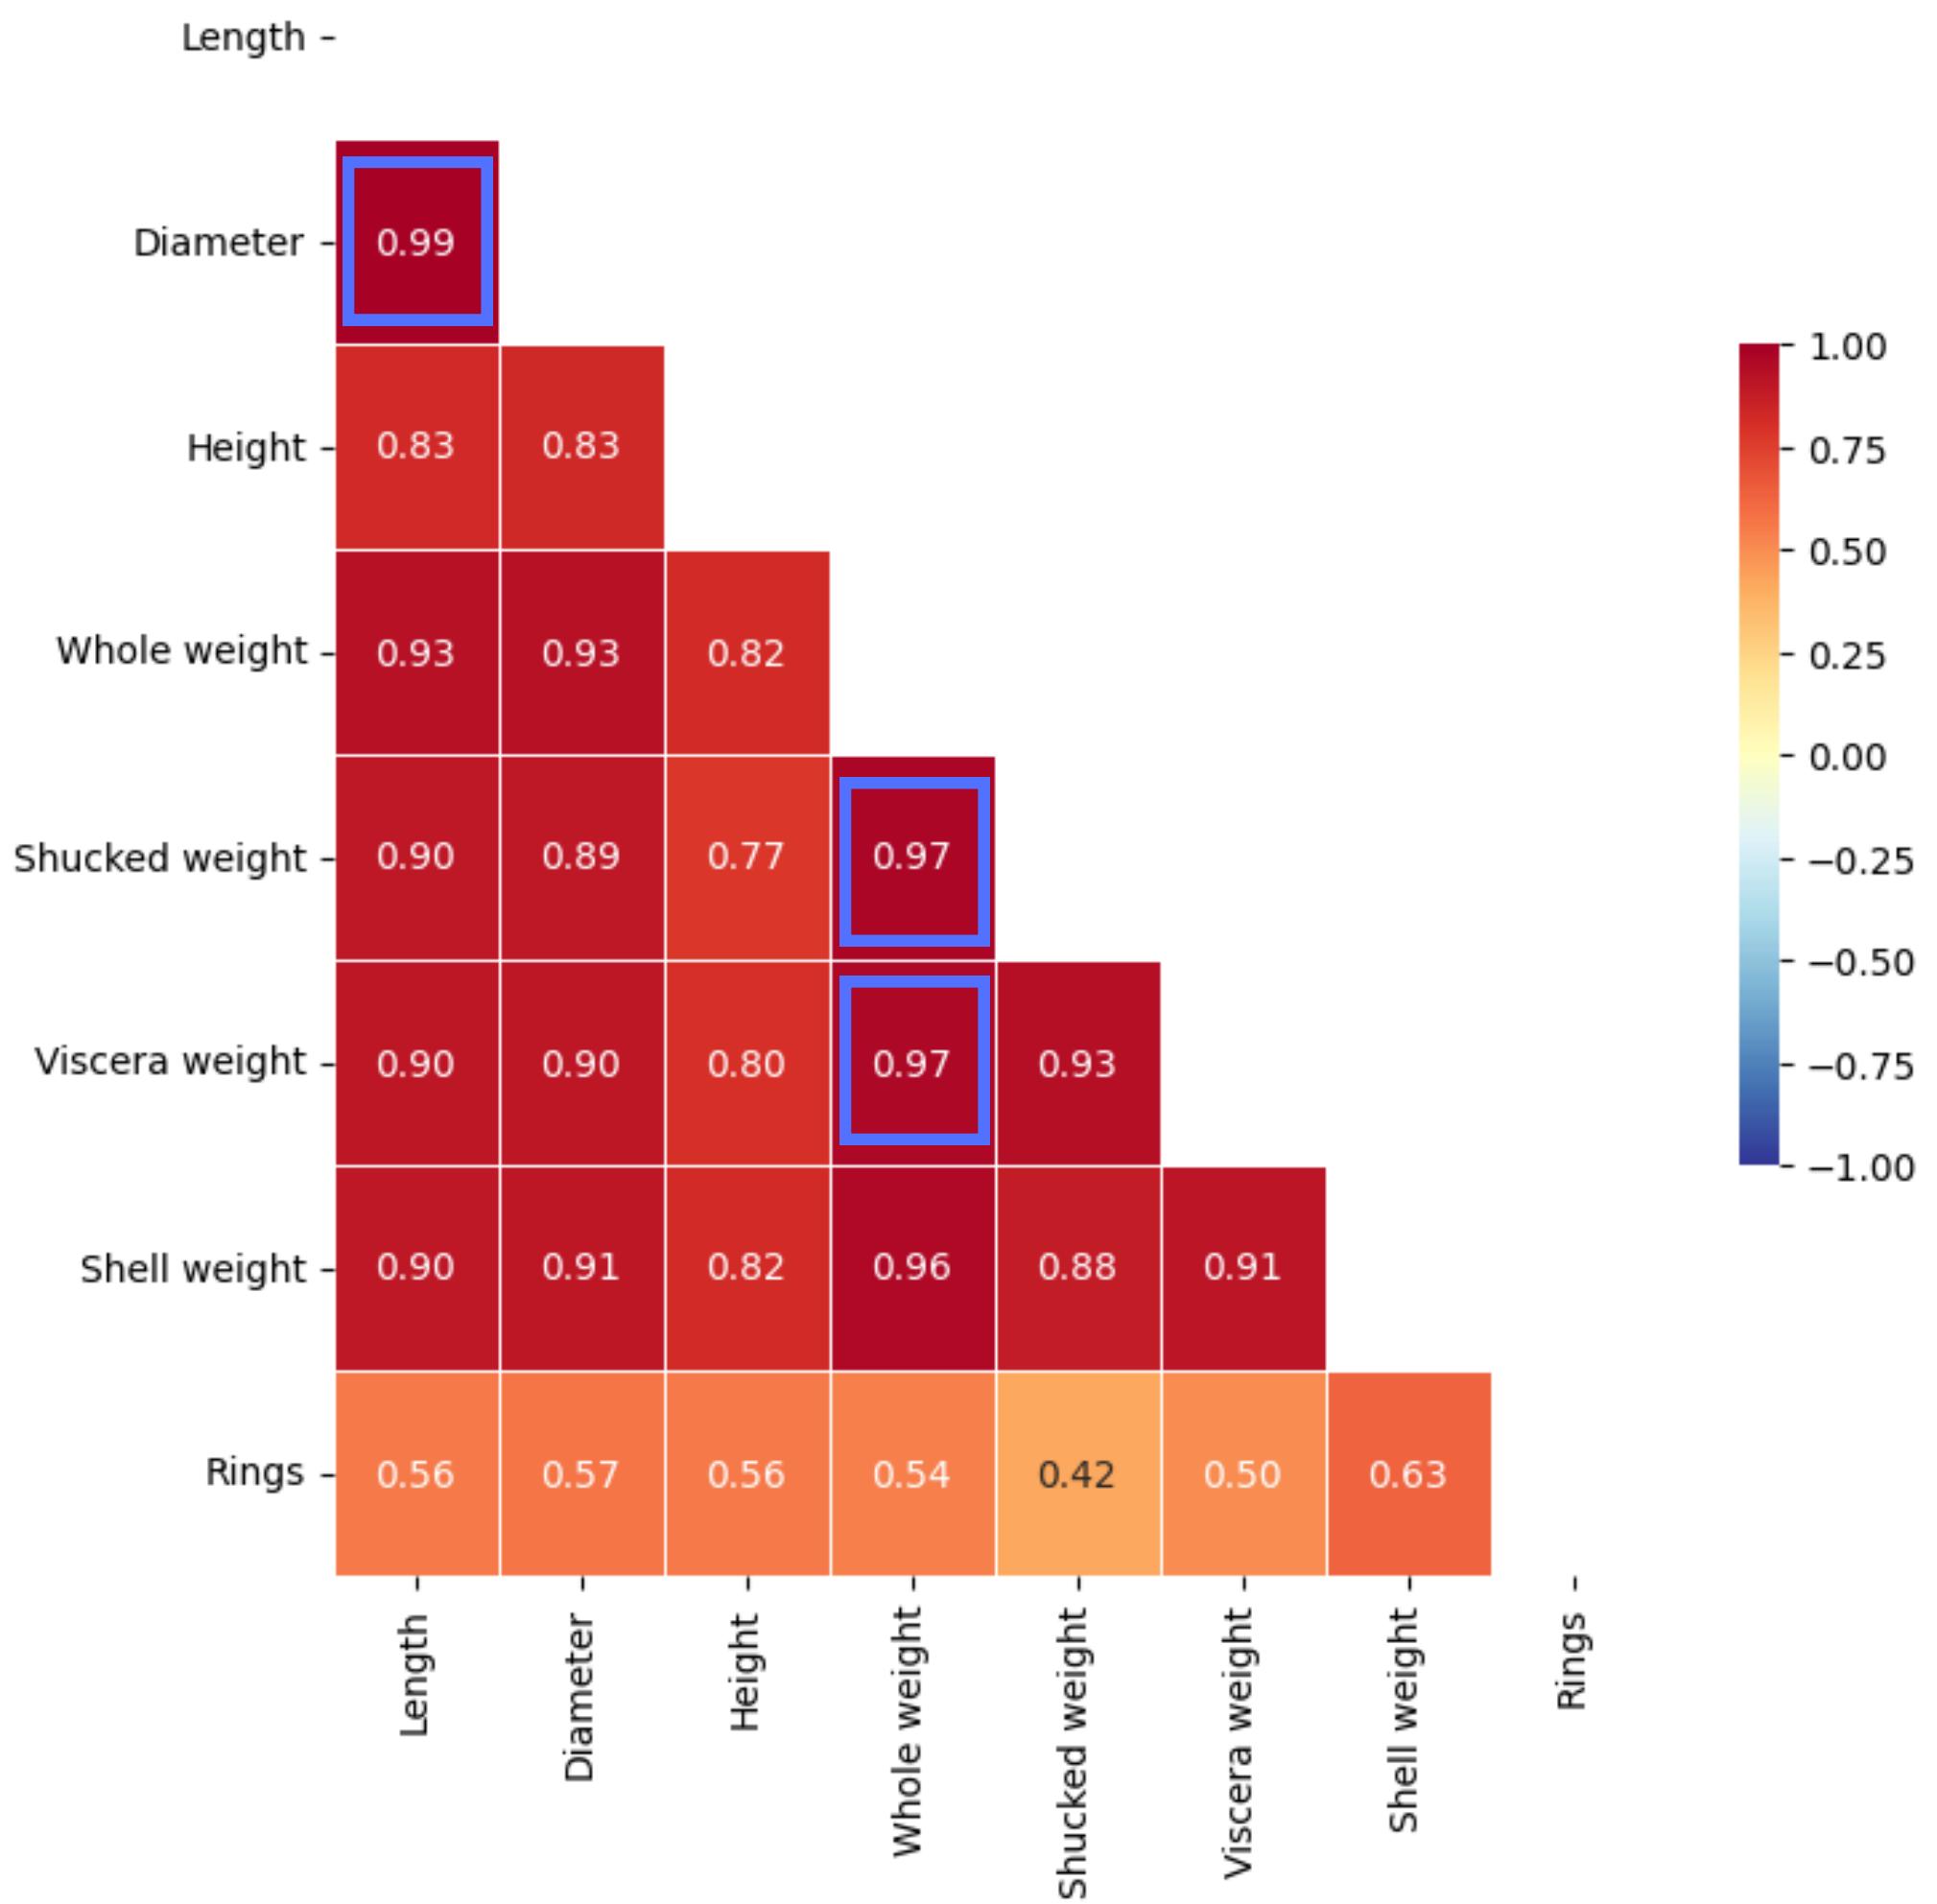
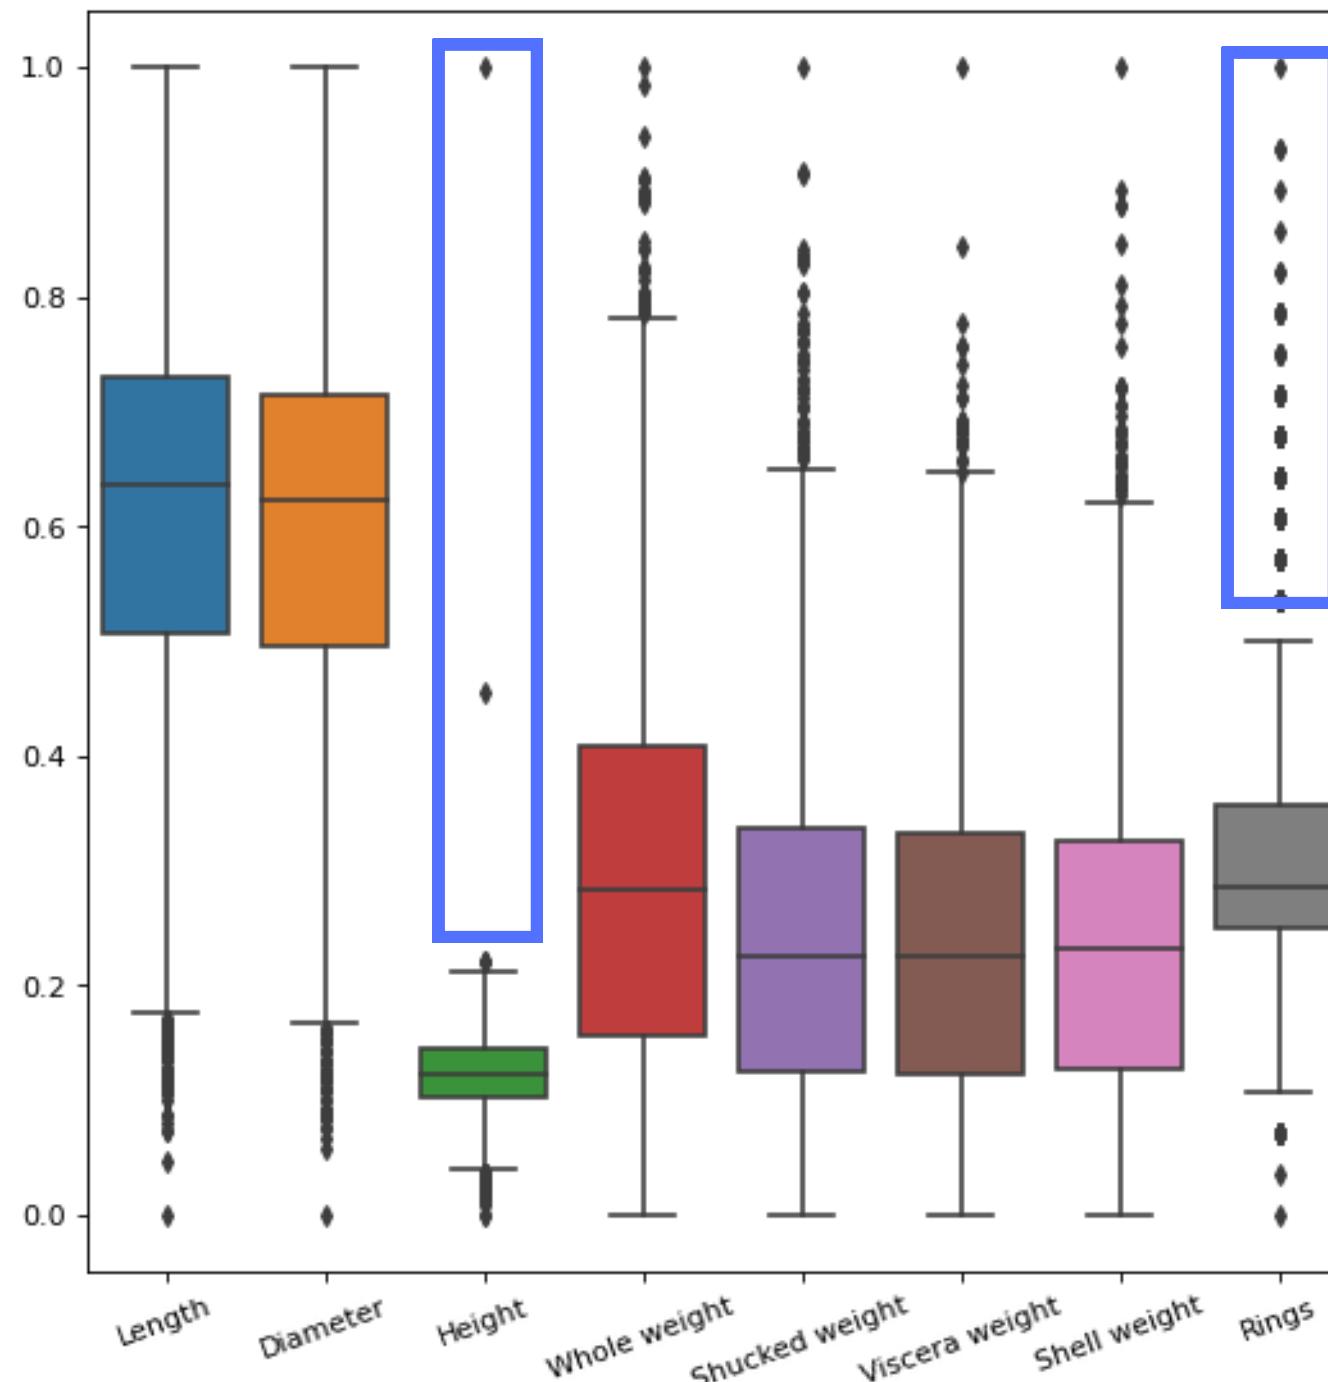
종속변수 : Rings

독립변수



Abalone

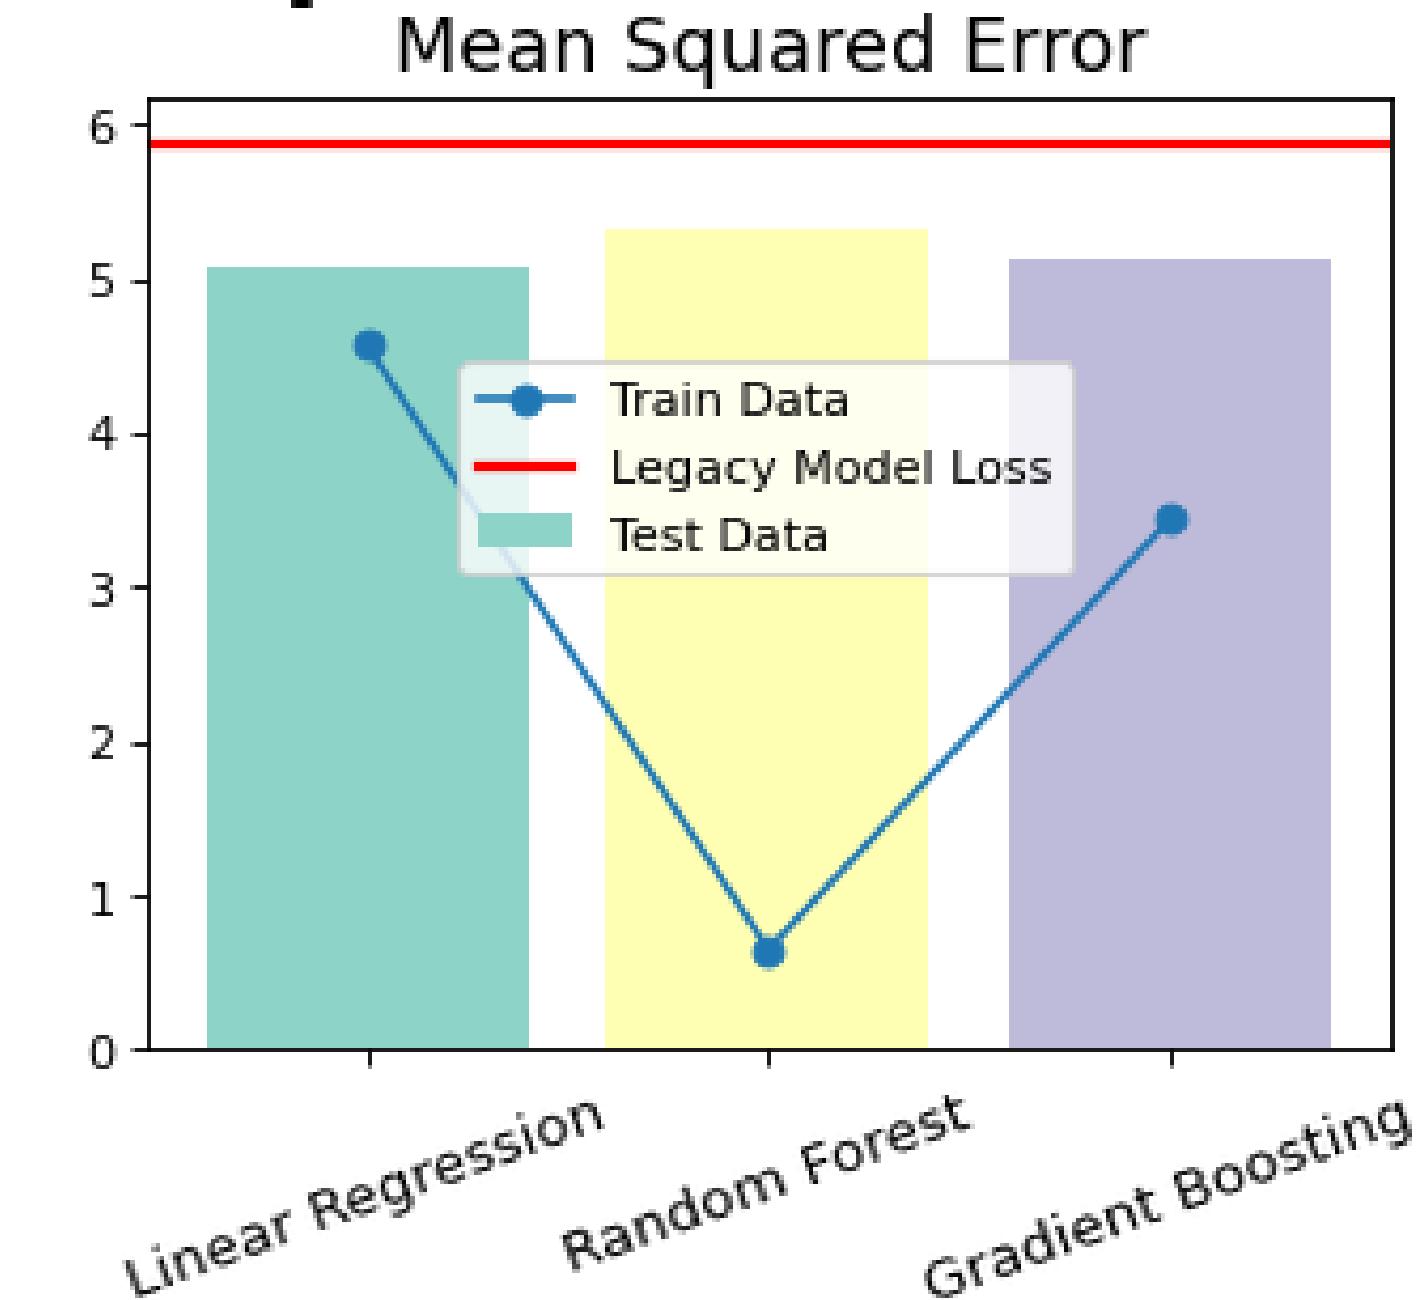
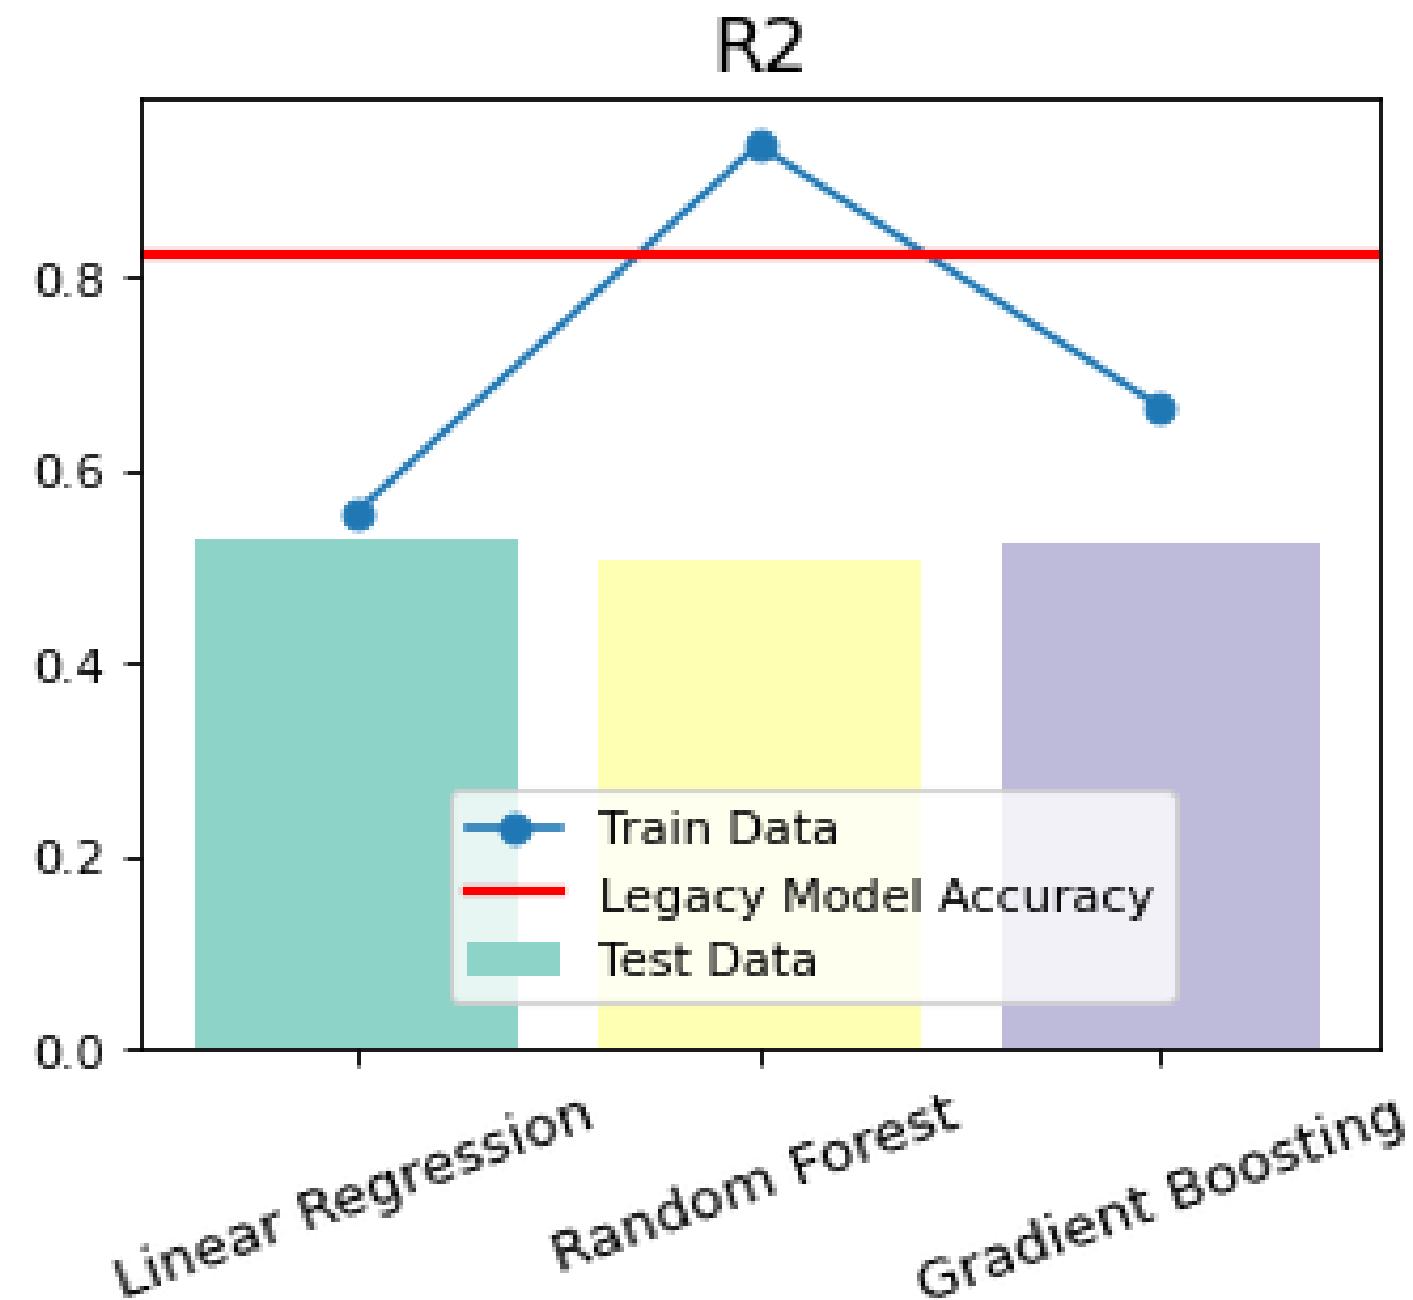
Exploratory data analysis



Abalone

Machine Learning

ML Model Compare

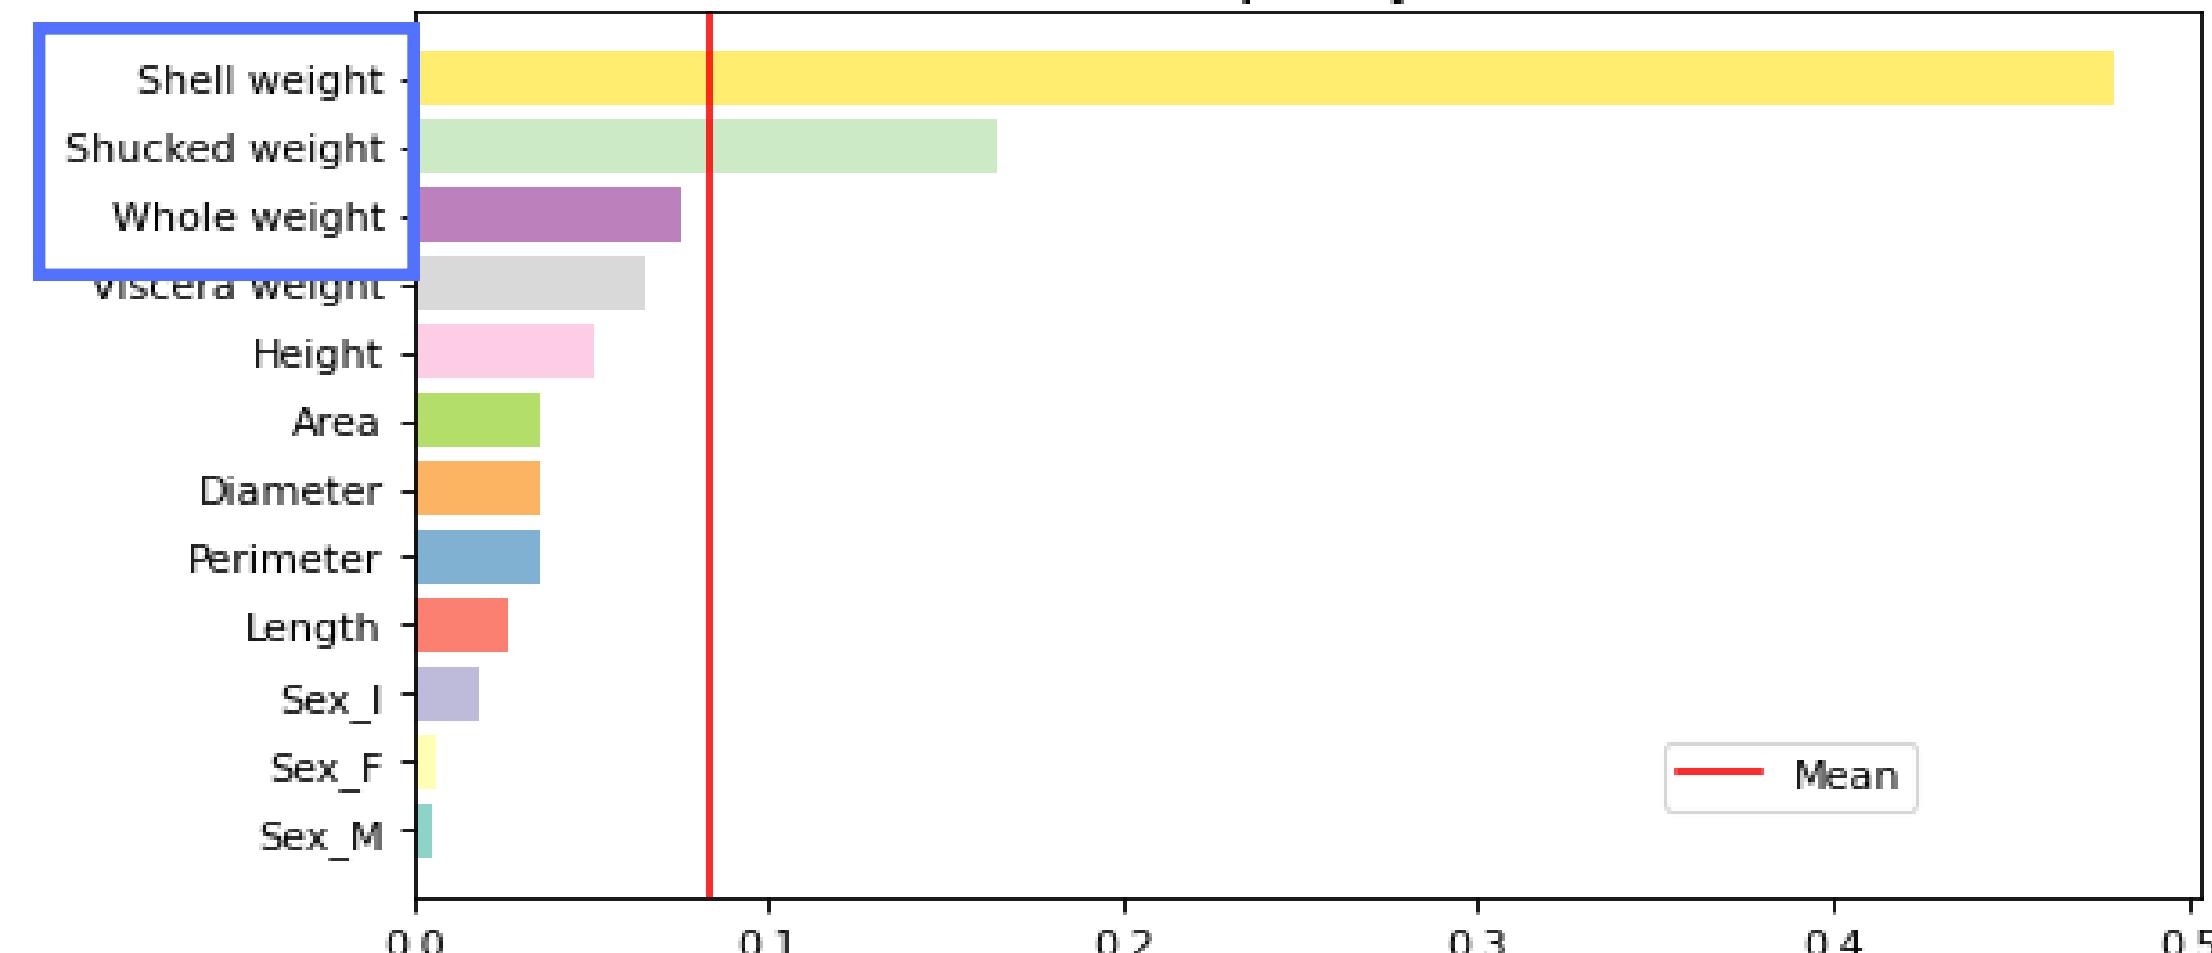


Abalone

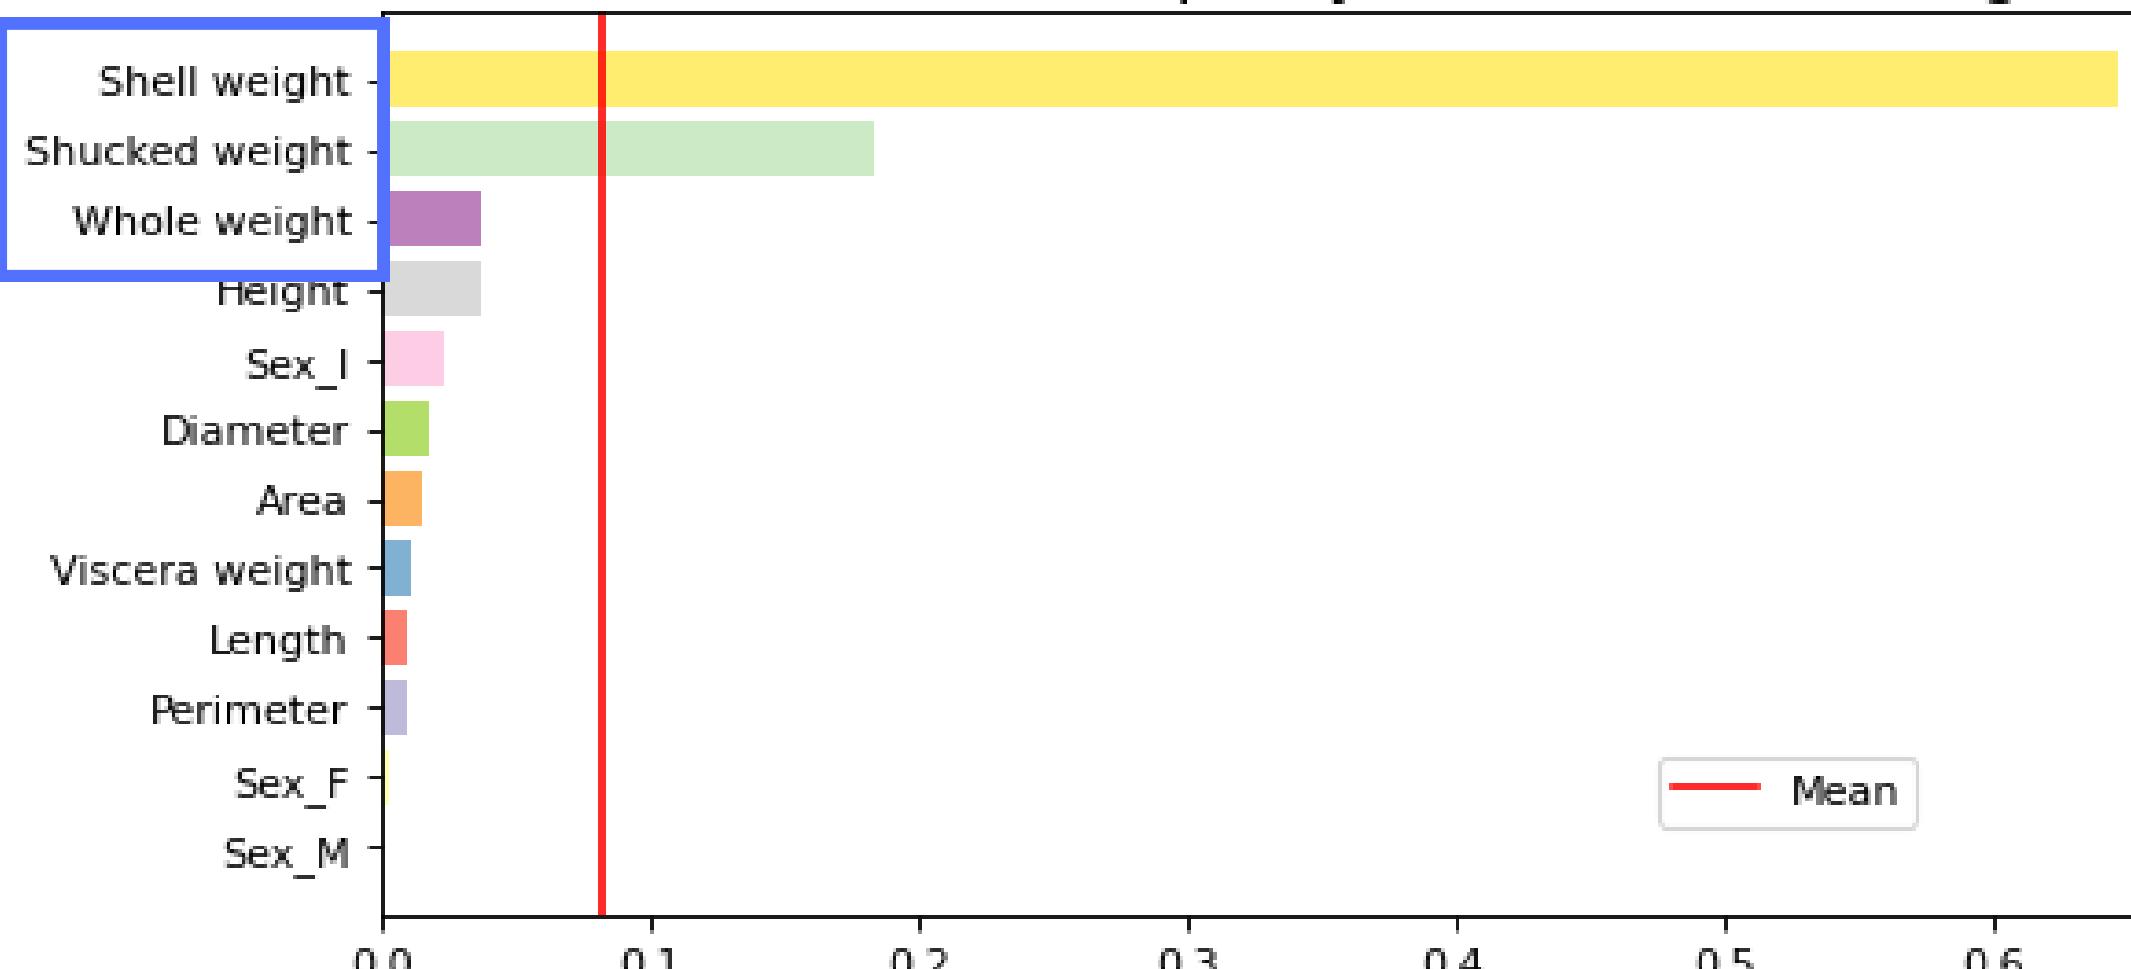
Machine Learning

껍질, 살 등의
'무게'가 중요

Mean Decrease Impurity : Random Forest



Mean Decrease Impurity : Gradient Boosting



Abalone

... Insight!

탐색적 데이터 분석

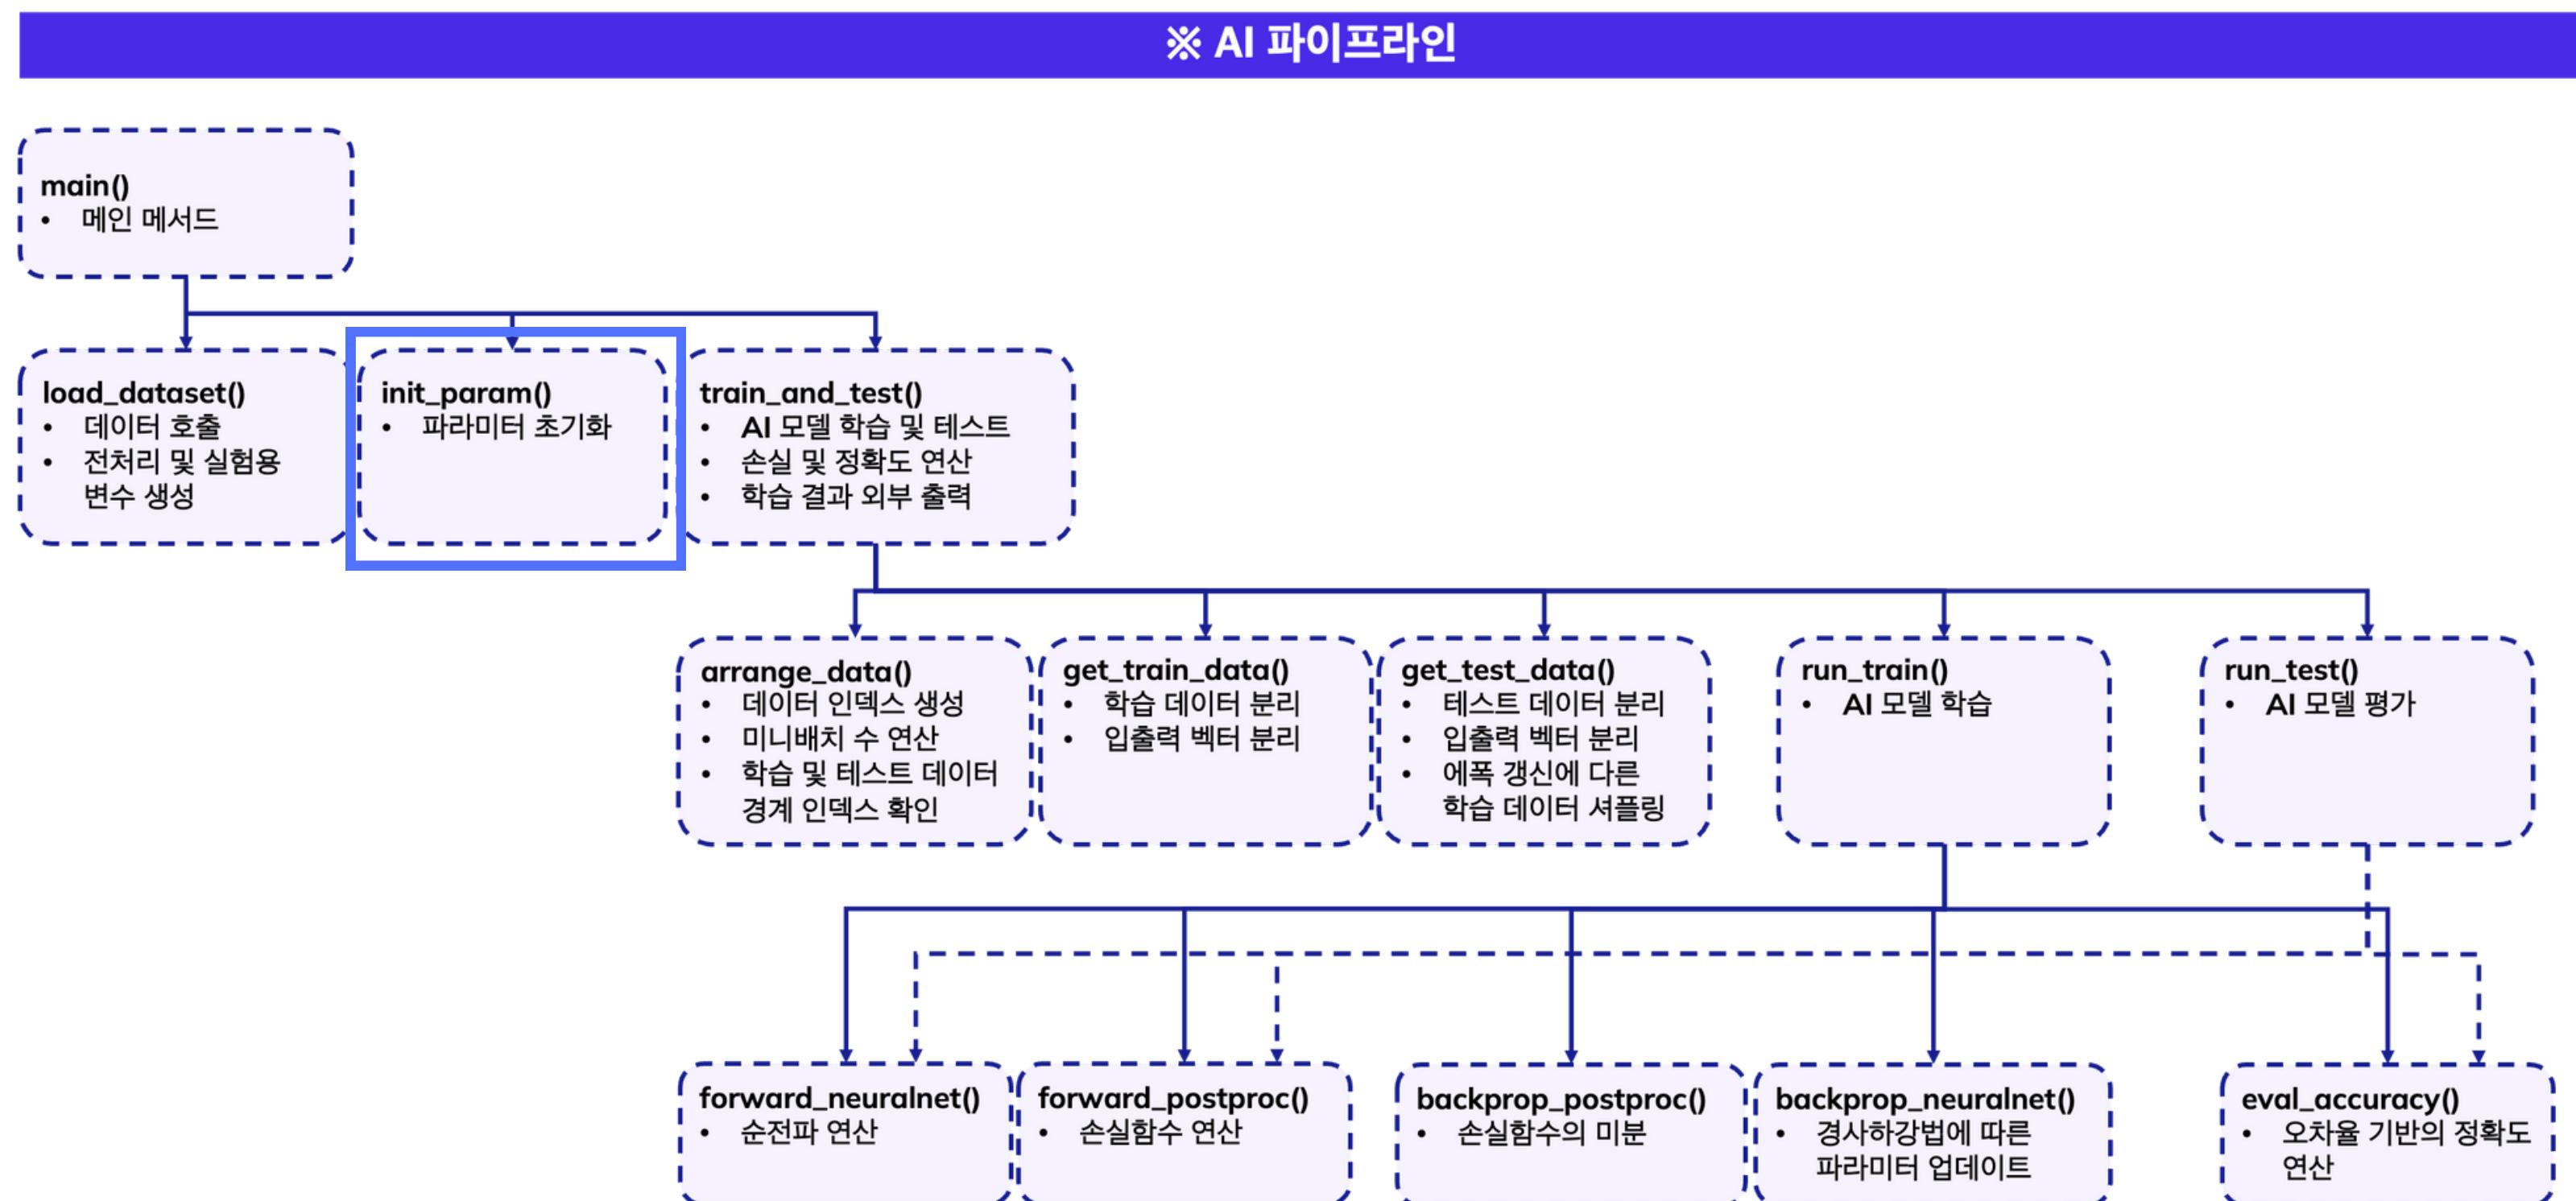
특성공학

옵티마이저 선택

- 전복껍질의 Ring을 통하여 연령 예측
- 크기, 무게, 성별이 전복의 연령을 예측하는 핵심적인 특성
- 이상치로 보이는 데이터에 대한 제거 혹은 스케일링 필요
- 새로운 특성(넓이, 둘레) 생성
 - 넓이(Area) = 가로 \times 세로 $\times \pi$
 - 껍질의 둘레(Perimeter)
$$= 2\pi \times (0.5 \times \sqrt{(\text{가로}^2 + \text{세로}^2)})$$
- 단순모델로 실험한 결과 Adam, Nadam, Adamax 가 좋은 성능
- 가장 범용으로 사용되는 **Adam**을 옵티마이저로 선택

Abalone

Legacy Model

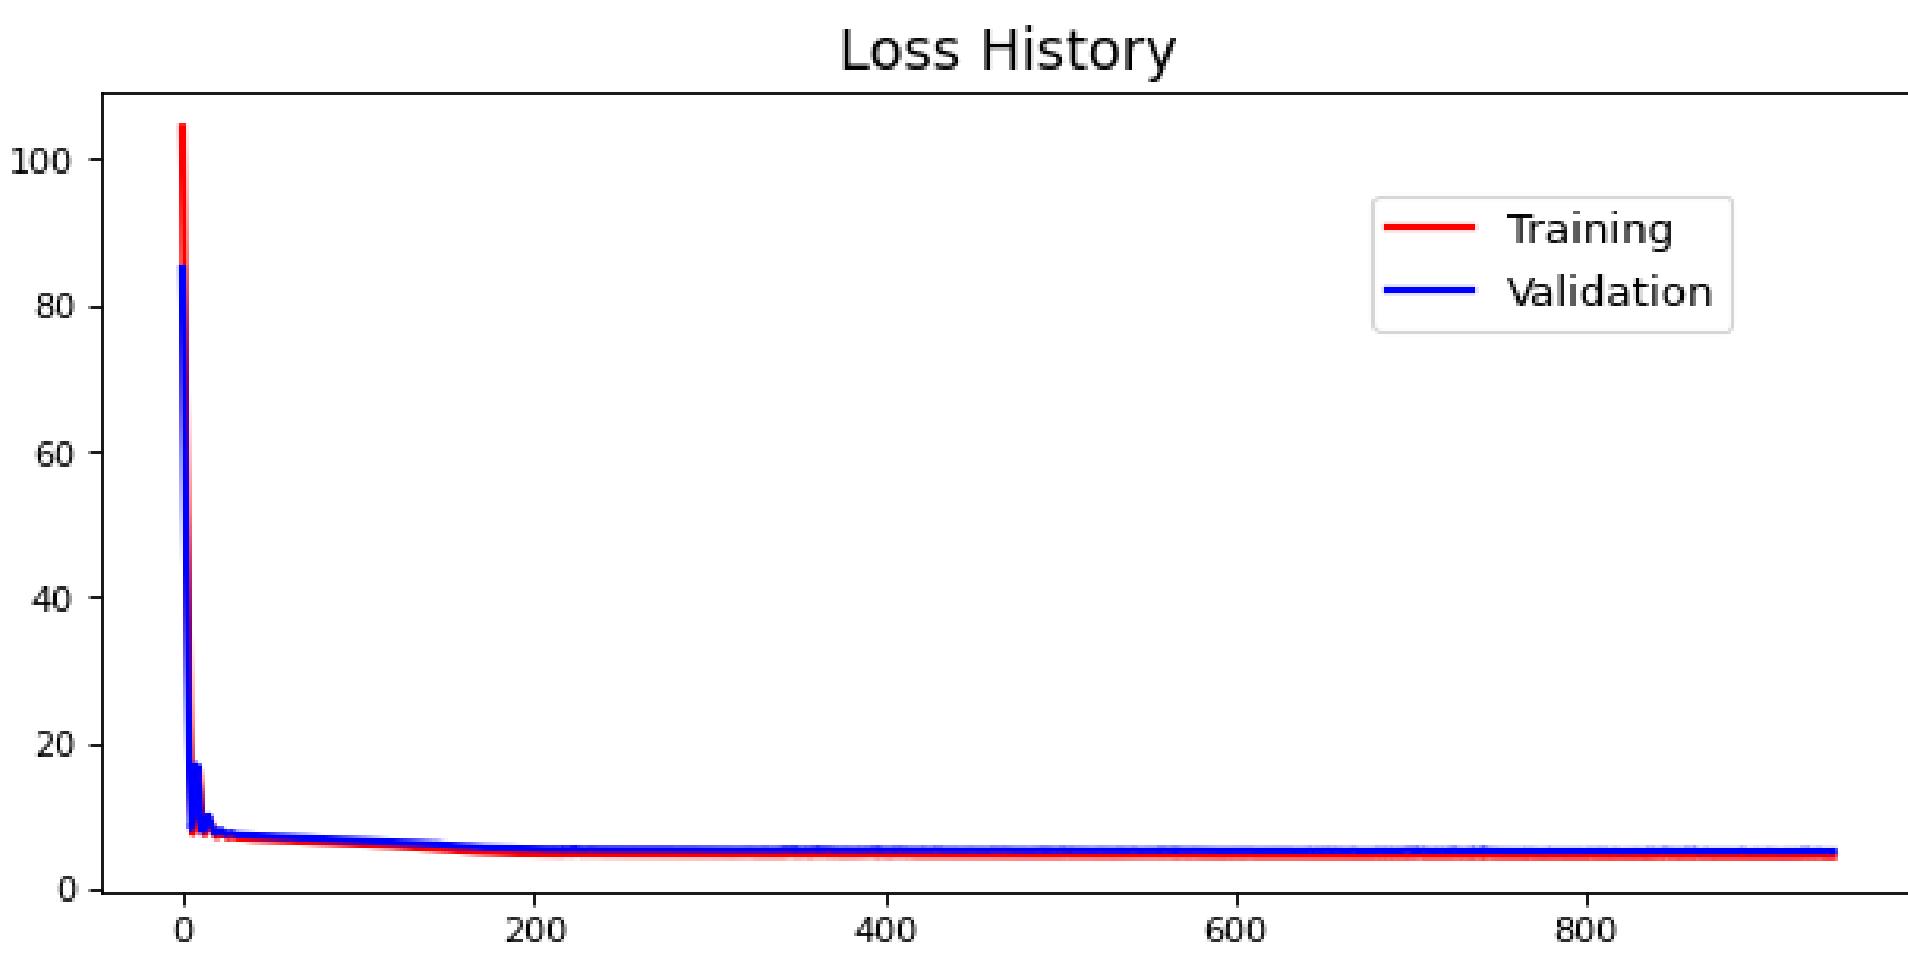
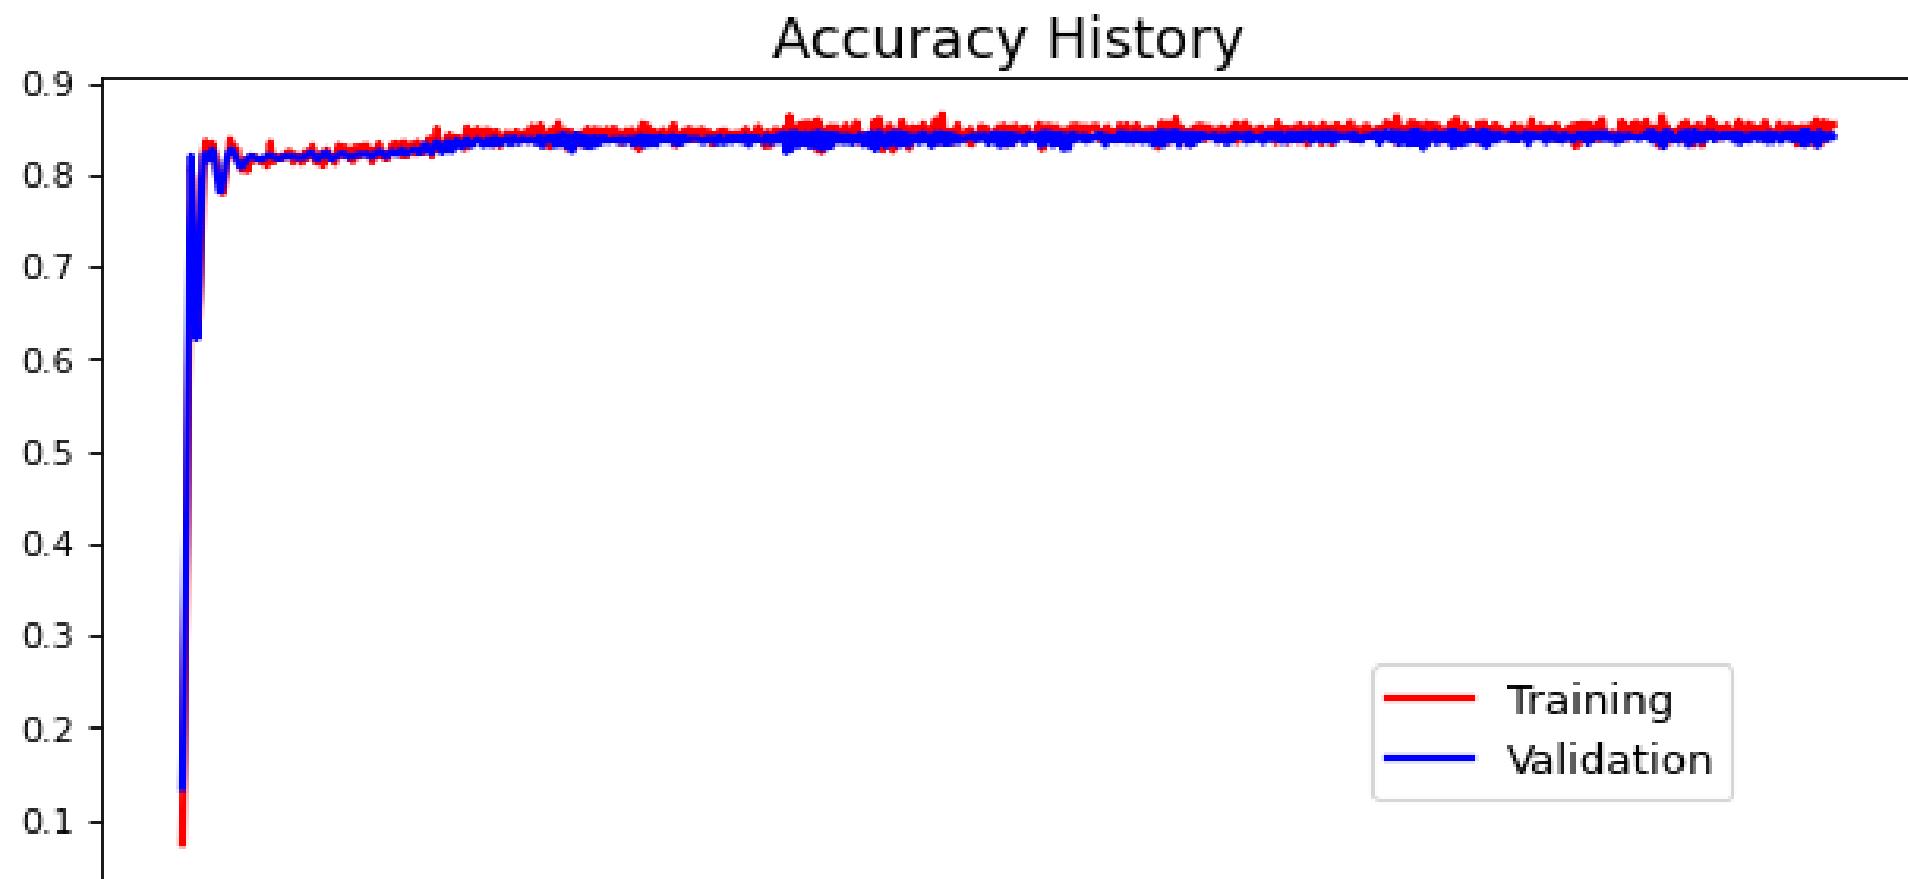


Abalone

Deep learning

모델구성

- 기준모델과 유사하게 구성
 - 은닉층 2개
 - 노드개수 = 특성 수(10개)
- 성별 원핫인코딩
- EDA 결과 적용
- 가중치 초기화 방법 : **Glorot Initialization**(기본값)
- 학습결과
 - Test Loss : 5.313 / Accuracy : 0.899
 - Train Score가 Validation Score와 같거나 오히려 일부 구간에서는 낮게 나타나 **과소적합 의심**
 - 모델의 복잡도를 올리는 방향으로 모델 개선 필요
- 가설 : 은닉층과 노드가 늘어나면 성능이 오를 것
 - 은닉층과 노드를 늘려도 성능에 큰 변화가 없음
 - 오히려 일정 수치가 넘어가면 **차원의 저주**로 학습이 안됨

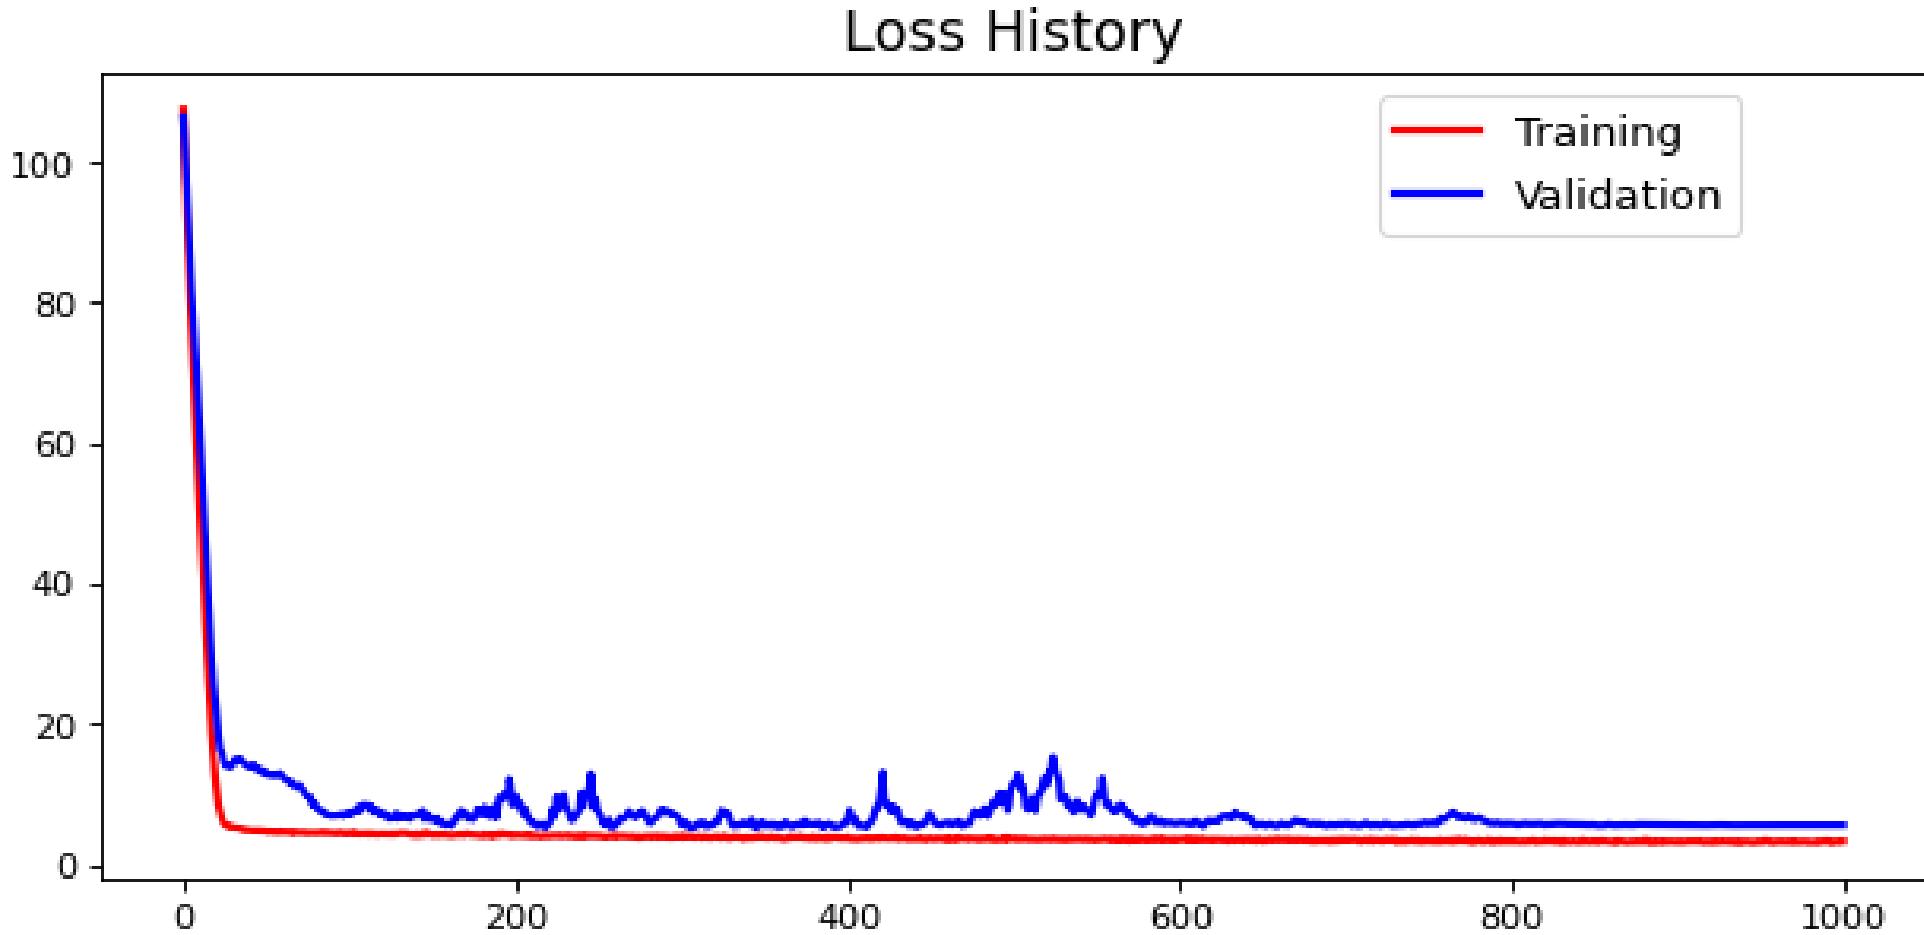
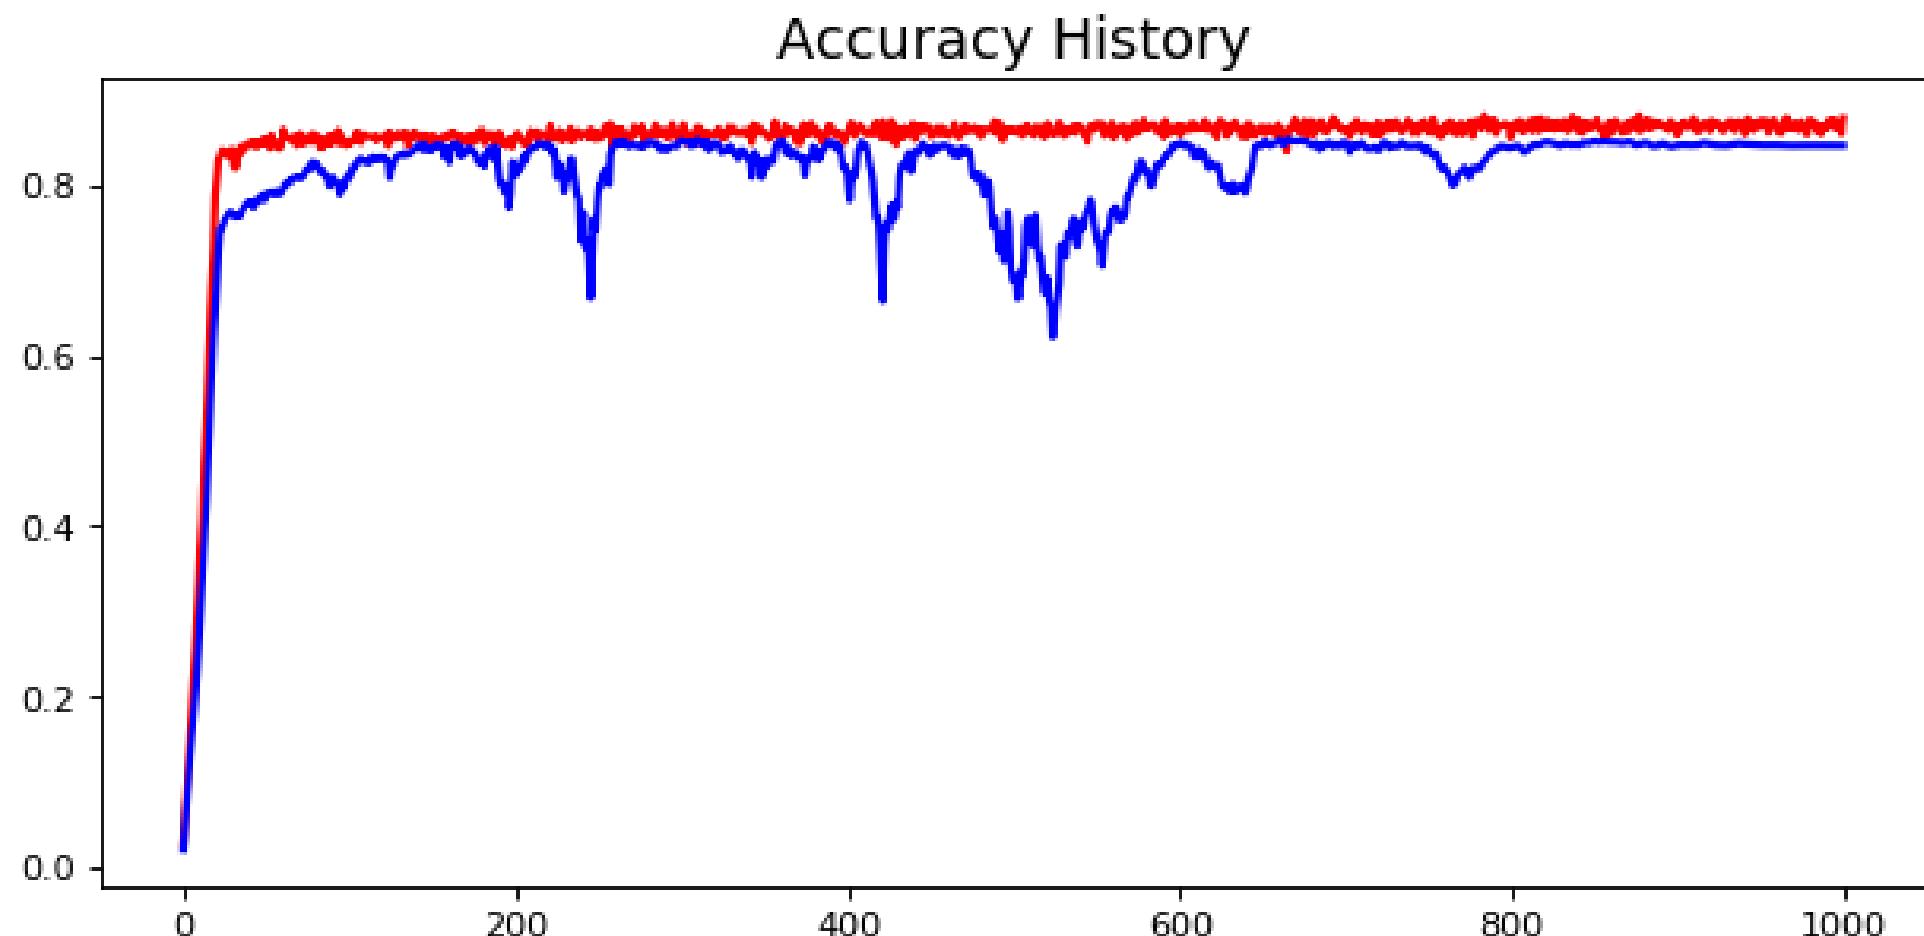


Abalone

Deep learning

모델구성

- 은닉층, 노드 추가
- 배치정규화, 학습률조정, 스킁연결 모델
- 과적합 방지 : 드롭아웃, 가중치패널티(L1,L2), 조기종료
- 학습결과
 - Test Loss : 5.975 / **Accuracy : 0.929**
(SOTA)
 - 검증데이터가 작아서 학습그래프가 불안정함
- 학습률조정의 코사인디케이의 특성상 초기 에포크에는 학습률이 크고, 후기 에포크에는 학습률이 작아서 **후반 에포크로 갈수록 안정된 그래프가 형성됨**



Abalone

Deep learning

업그레이드 모델 사용하러 가기

Pulsar Star



Domain Understanding

1. Mean of the integrated profile. (통합 프로파일의 평균.)
2. Standard deviation of the integrated profile. (통합 프로파일의 표준 편차.)
3. Excess kurtosis of the integrated profile. (통합 프로파일의 과도한 첨도.)
4. Skewness of the integrated profile. (통합 프로파일의 왜도.)
5. Mean of the DM-SNR curve. (DM-SNR 곡선의 평균.)
6. Standard deviation of the DM-SNR curve. (DM-SNR 곡선의 표준 편차.)
7. Excess kurtosis of the DM-SNR curve. (DM-SNR 곡선의 과도한 첨도.)
8. Skewness of the DM-SNR curve. (DM-SNR 곡선의 왜도.)
9. Class (타겟)

1. Pulsar Star 란?:

맥동성(Pulsar Star)은 매우 빠른 속도로 회전하는 중성자 별을 의미. 이들은 극도로 강한 자기장을 가지며, 이로 인해 빔 형태의 방출을 생성함.

이 방출이 지구를 향할 때마다 우리는 펄스 또는 신호를 감지할 수 있는데 이것이 펄서 스타 이름의 기원임.

2. 통합 프로파일 (Integrated Profile):

펄서의 펄스 프로파일은 펄서의 신호 강도를 시간에 따라 표시한 것. '통합 프로파일'은 이러한 펄스의 평균 프로파일을 말함. 평균, 표준 편차, 왜도, 첨도 등은 이러한 프로파일의 통계적 특성을 나타냄.

3. DM-SNR 곡선:

Dispersion Measure-Signal to Noise Ratio의 약자.

Dispersion Measure는 펄서 신호가 우리에게 도달하는 데 걸리는 시간, 즉 신호의 지연을 측정함.

Signal to Noise Ratio는 신호의 강도와 배경 잡음의 강도 사이의 비율을 나타냄.

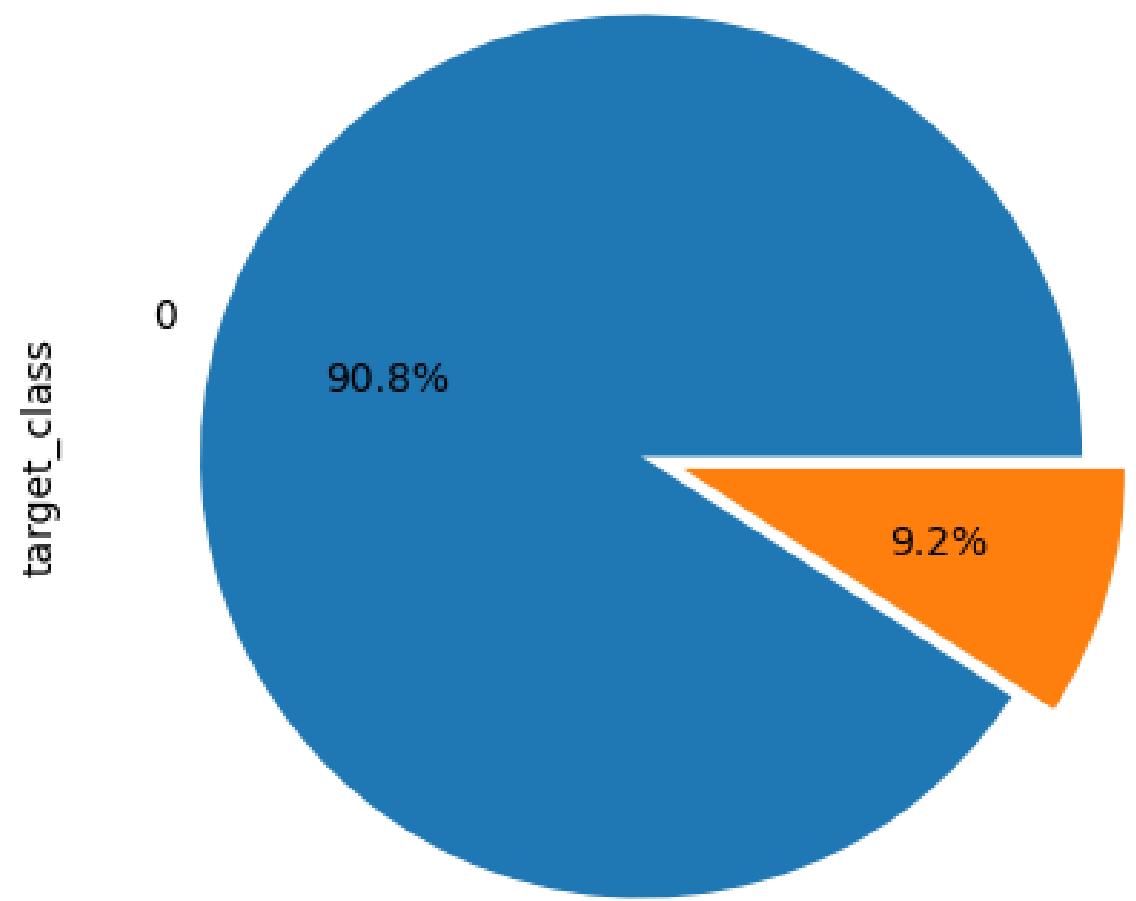
DM-SNR 곡선은 이 두 수치를 결합한 것.

4. target_class (0/1):

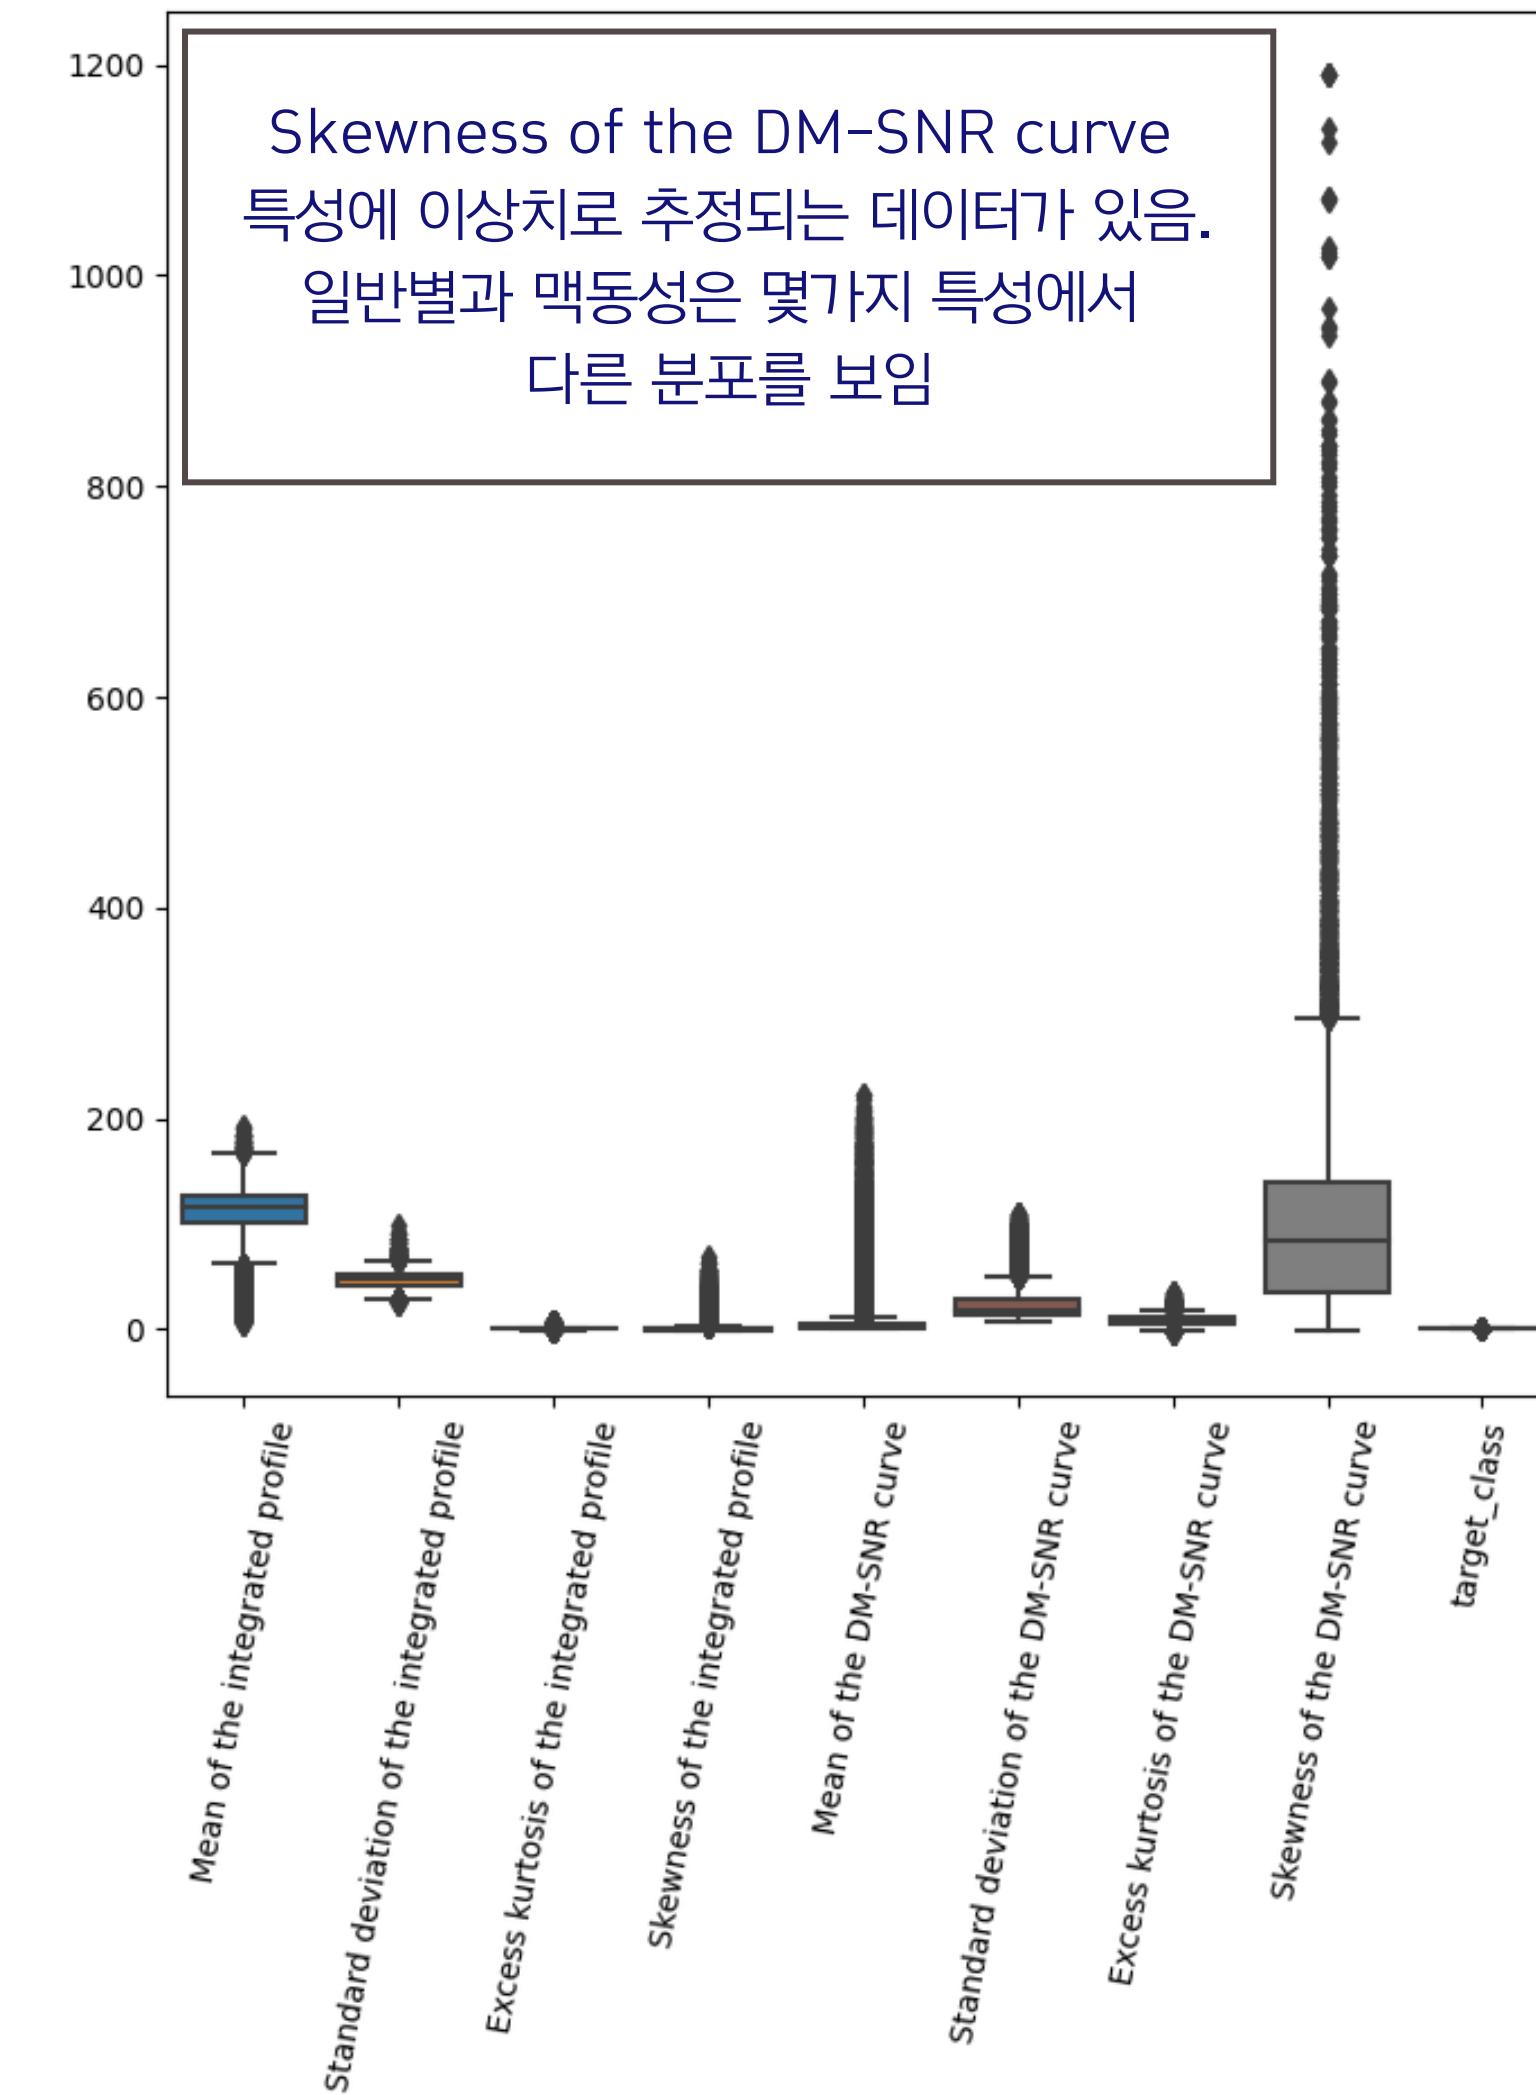
target_class는 우리가 예측하려는 목표 변수이고, 여기서는 별이 맥동성인지(1) 아닌지(0)를 나타냄.

Pulsar Star

Engineering Data Analysis



타겟 가운데 Pulsar는 9.2%가 존재.
타겟의 비율이 9:1로 매우 불균형.
평가지표 Accuracy만 사용하는 것은
유의미하지 않을 것으로 판단



Pulsar Star

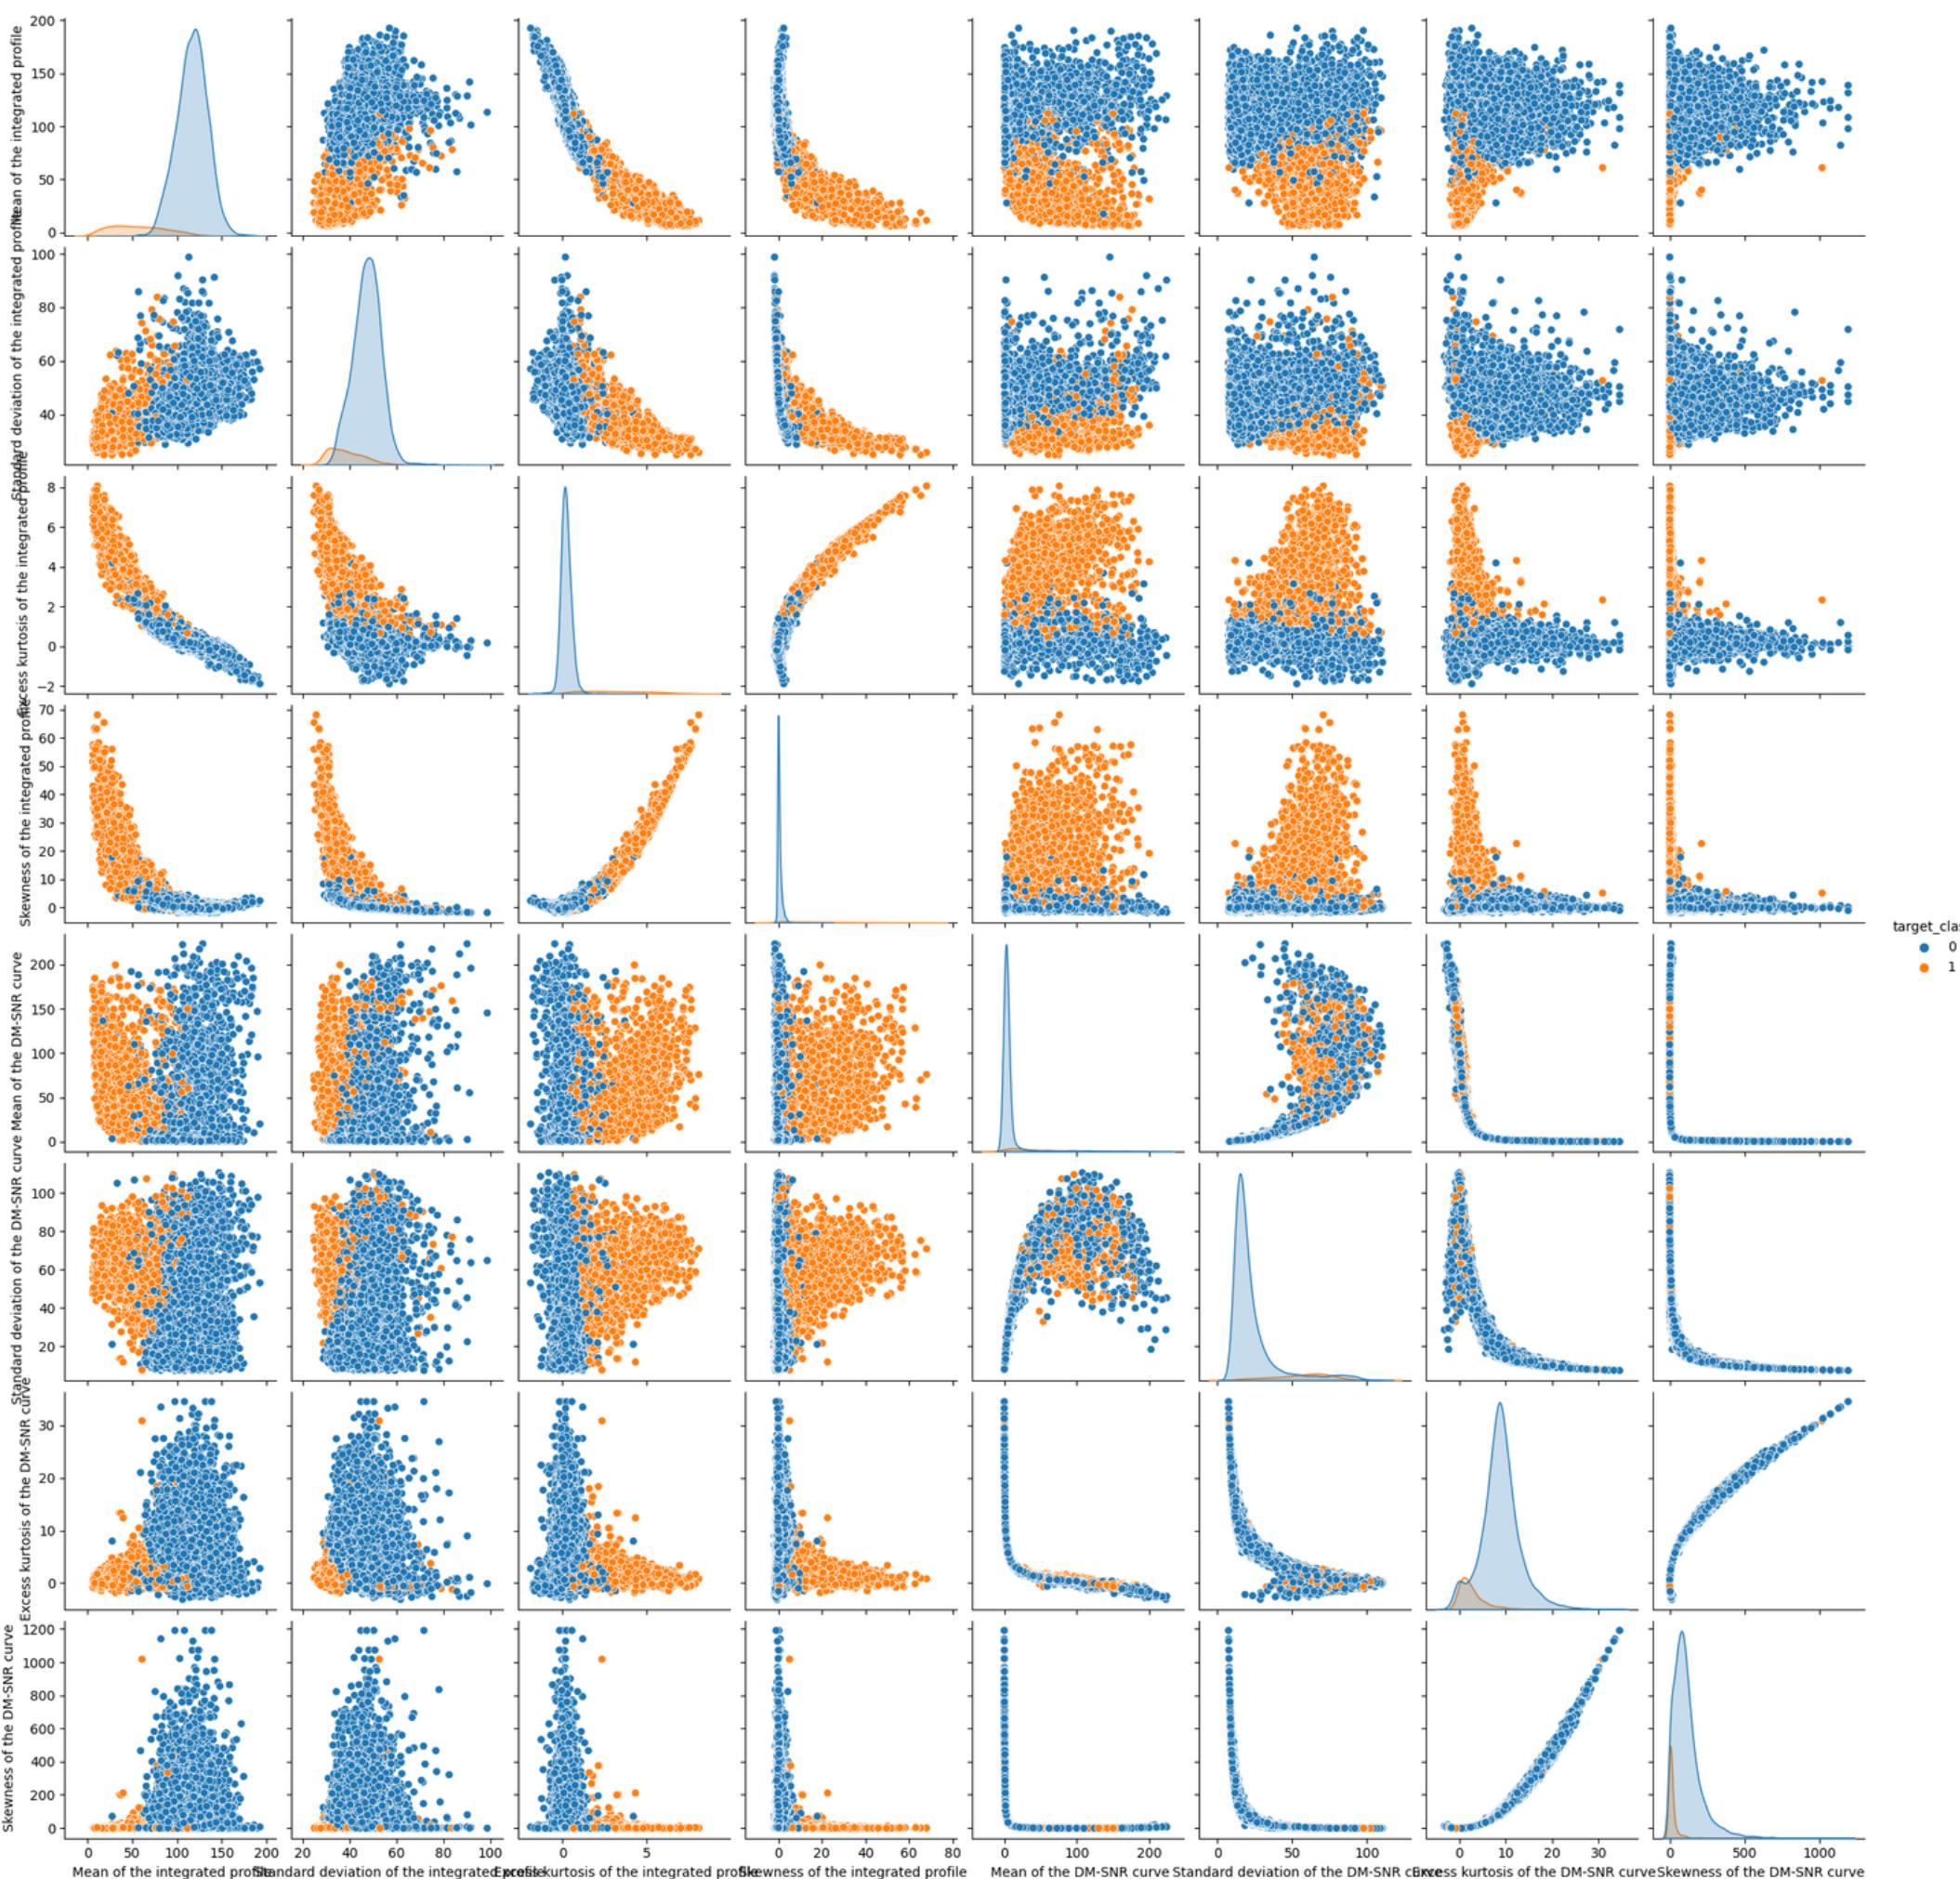
Engineering Data Analysis

통합 프로필 (integrated profile)

- 평균 : 평균 값은 대략 111으로 중앙값과 거의 비슷하며, 최소값과 최대값 사이에는 큰 차이가 있어 표준편차 값이 25.6으로 큽니다.
- 표준 편차 : 평균 표준 편자는 46.6으로 중앙값에 가깝고, 최소값과 최대값을 보면 데이터 세트 전체에 정규 분포가 나타나는 것으로 보입니다.
- 초과 첨도 : 데이터의 75% 이상이 0.5 아래에 있으며, 첨도가 낮은 경우 꼬리가 가벼우거나 이상치가 부족한 경향이 있습니다.
- 비대칭도 : 데이터의 75% 이상이 1.0 아래에 있어 통합 프로필의 대부분은 약간만 비대칭인 것으로 나타납니다.

DM-SNR 곡선 (DM-SNR curve)

- 평균 : 표준 편차가 매우 높은 편입니다. 29로, 값의 75%가 5.6 아래에 있고 최대 값은 극단적으로 높습니다. 대부분의 곡선의 평균 값은 낮은 편이 될 것으로 기대할 수 있습니다.
- 표준 편차 : 이것도 최대 값이 매우 높아 보이며, 값의 75%가 28 아래에 있으며 중앙값은 19이고 평균은 26입니다. 평균의 높은 크기는 극단적으로 높은 값의 영향을 받은 것이지만, 해당 값들이 포함되지 않았다면 표준 편자는 중앙값 주변에 위치할 것으로 예상됩니다.
- 초과 첨도 : 값들은 상당히 높으며, 평균 값은 8.23이고 최대 값은 34입니다. 값들은 정규 분포를 나타내는 것으로 보입니다.
- 비대칭도 : 값들은 상당히 높으며, 평균 값은 102이고 최대 값은 1191으로 매우 높은 값을 가지고 있습니다. 이는 75분위 값과 비교했을 때 극도로 높은 값입니다.

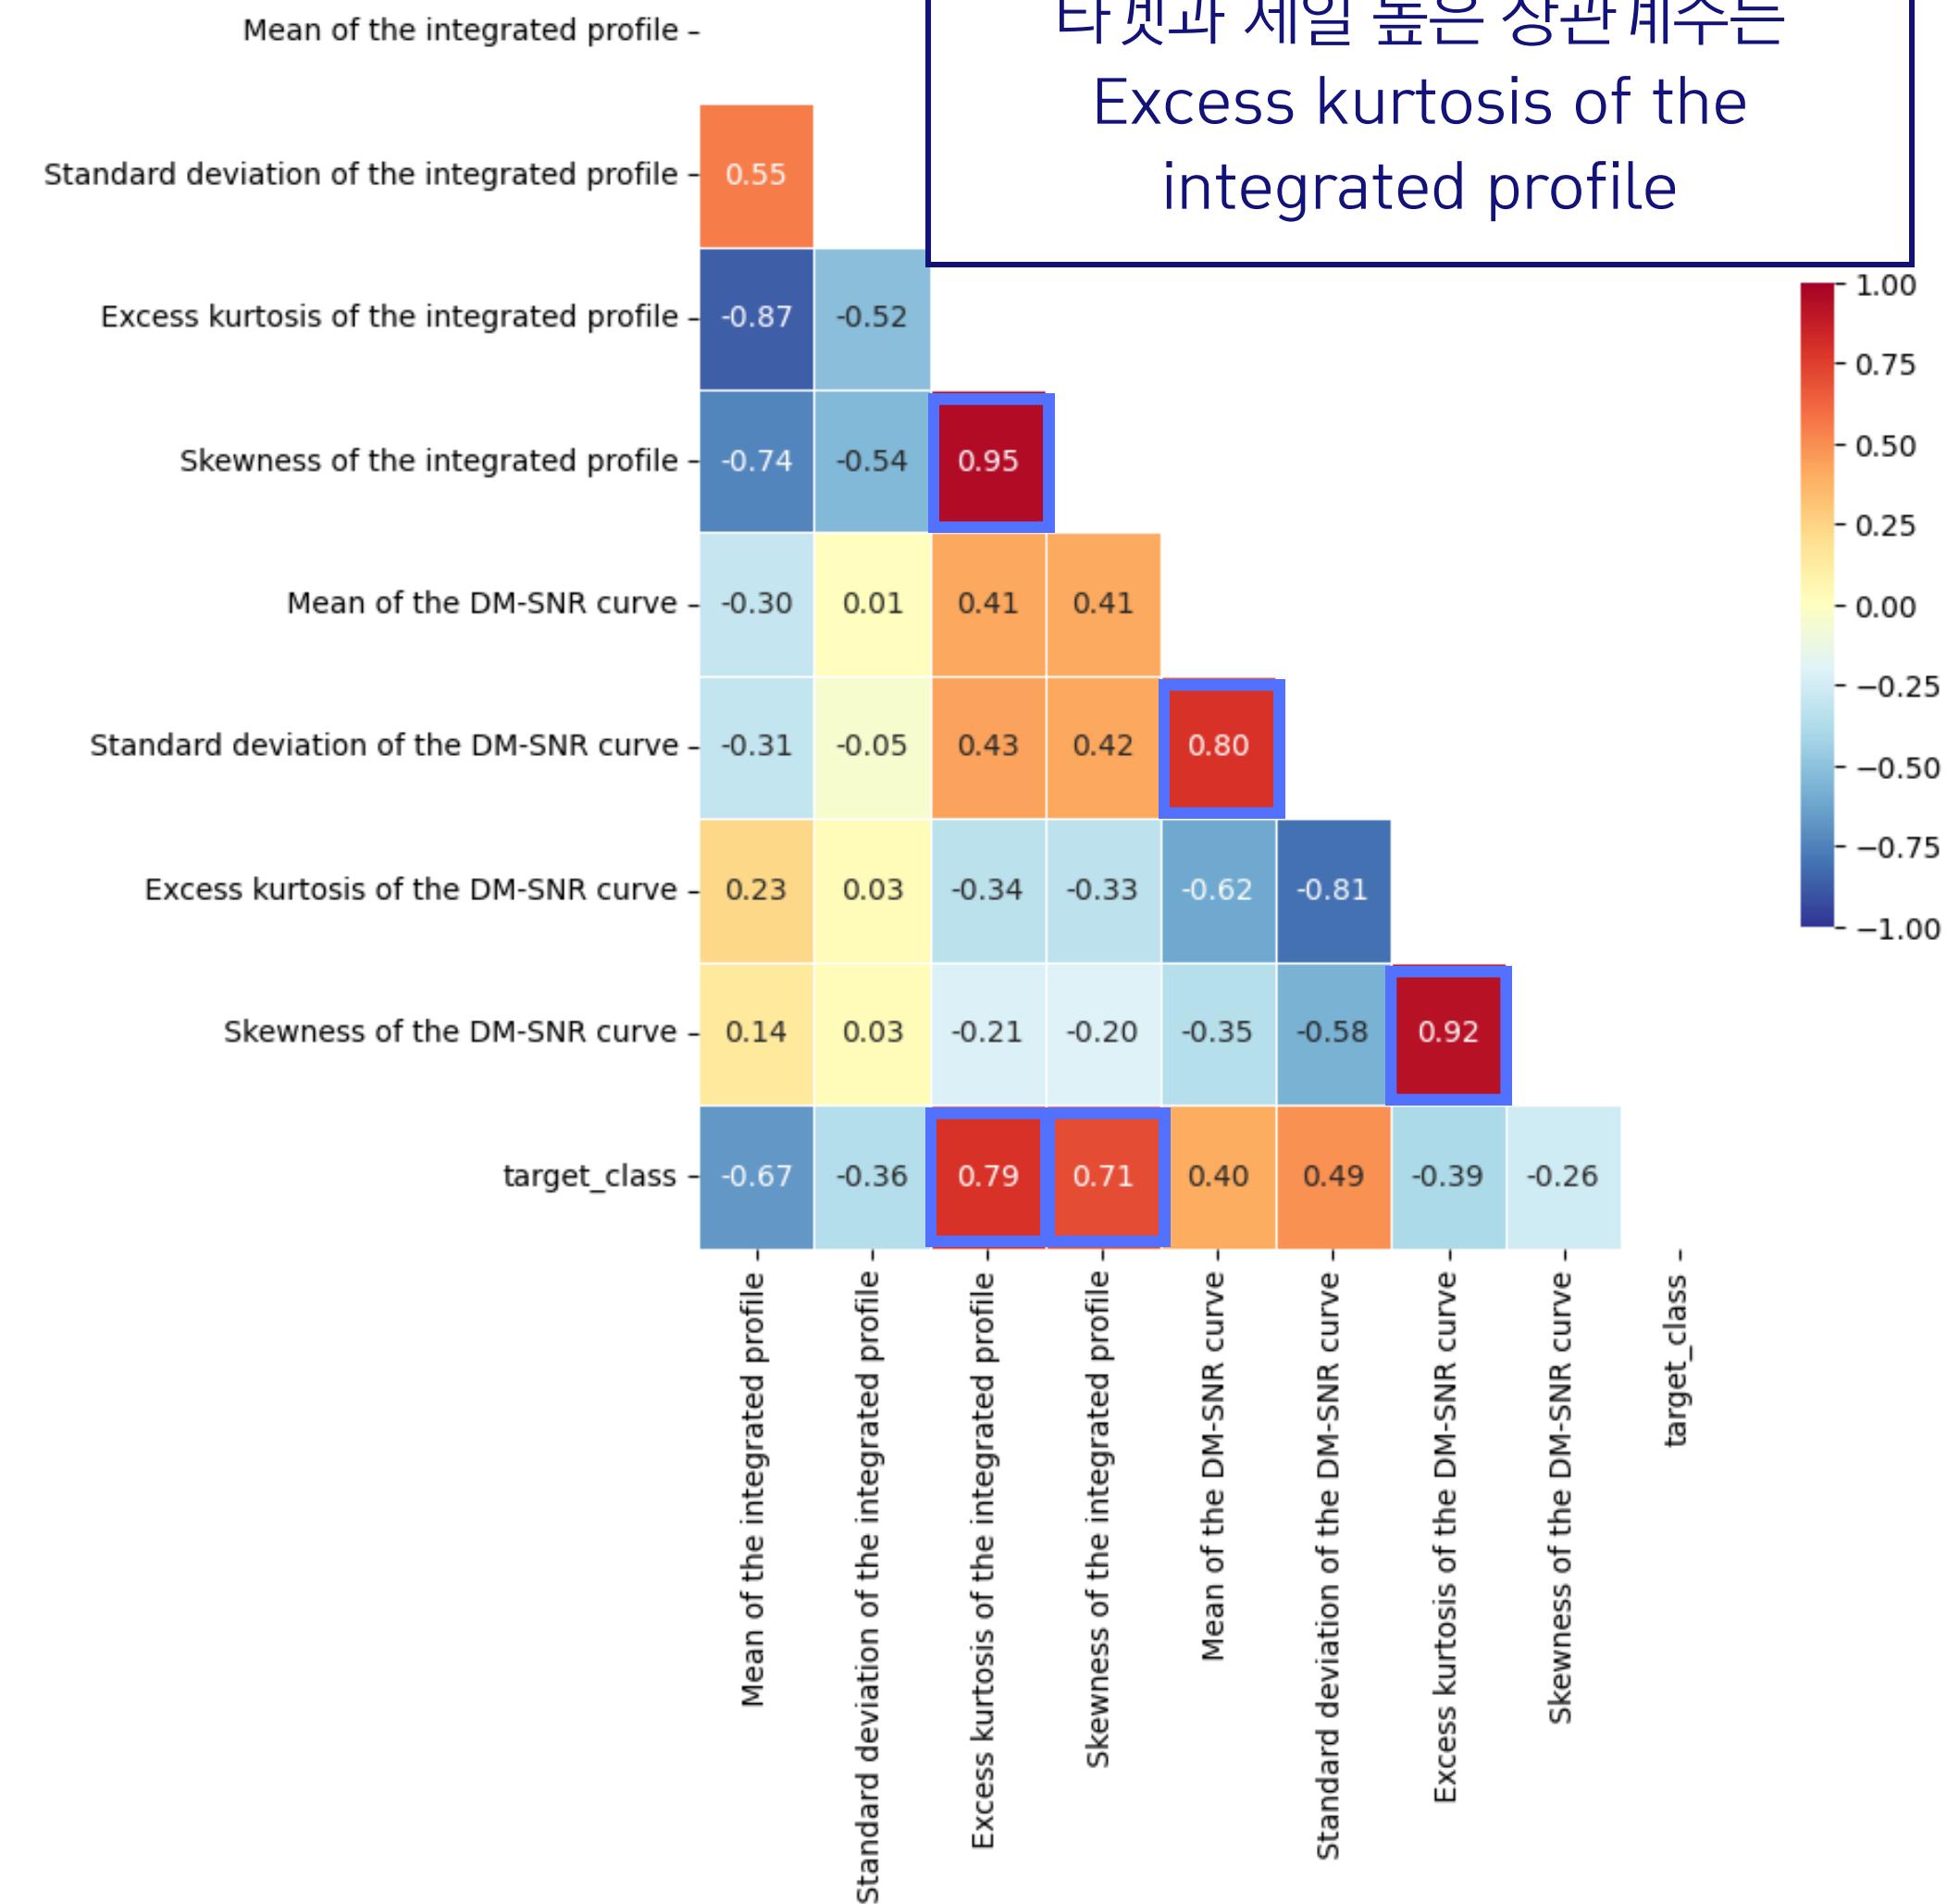


Pulsar Star

Engineering Data Analysis

일부 특성 사이에 강한 상관관계가 있지만,
문제가 되지는 않을 것으로 보임.

□ 모양으로 표시

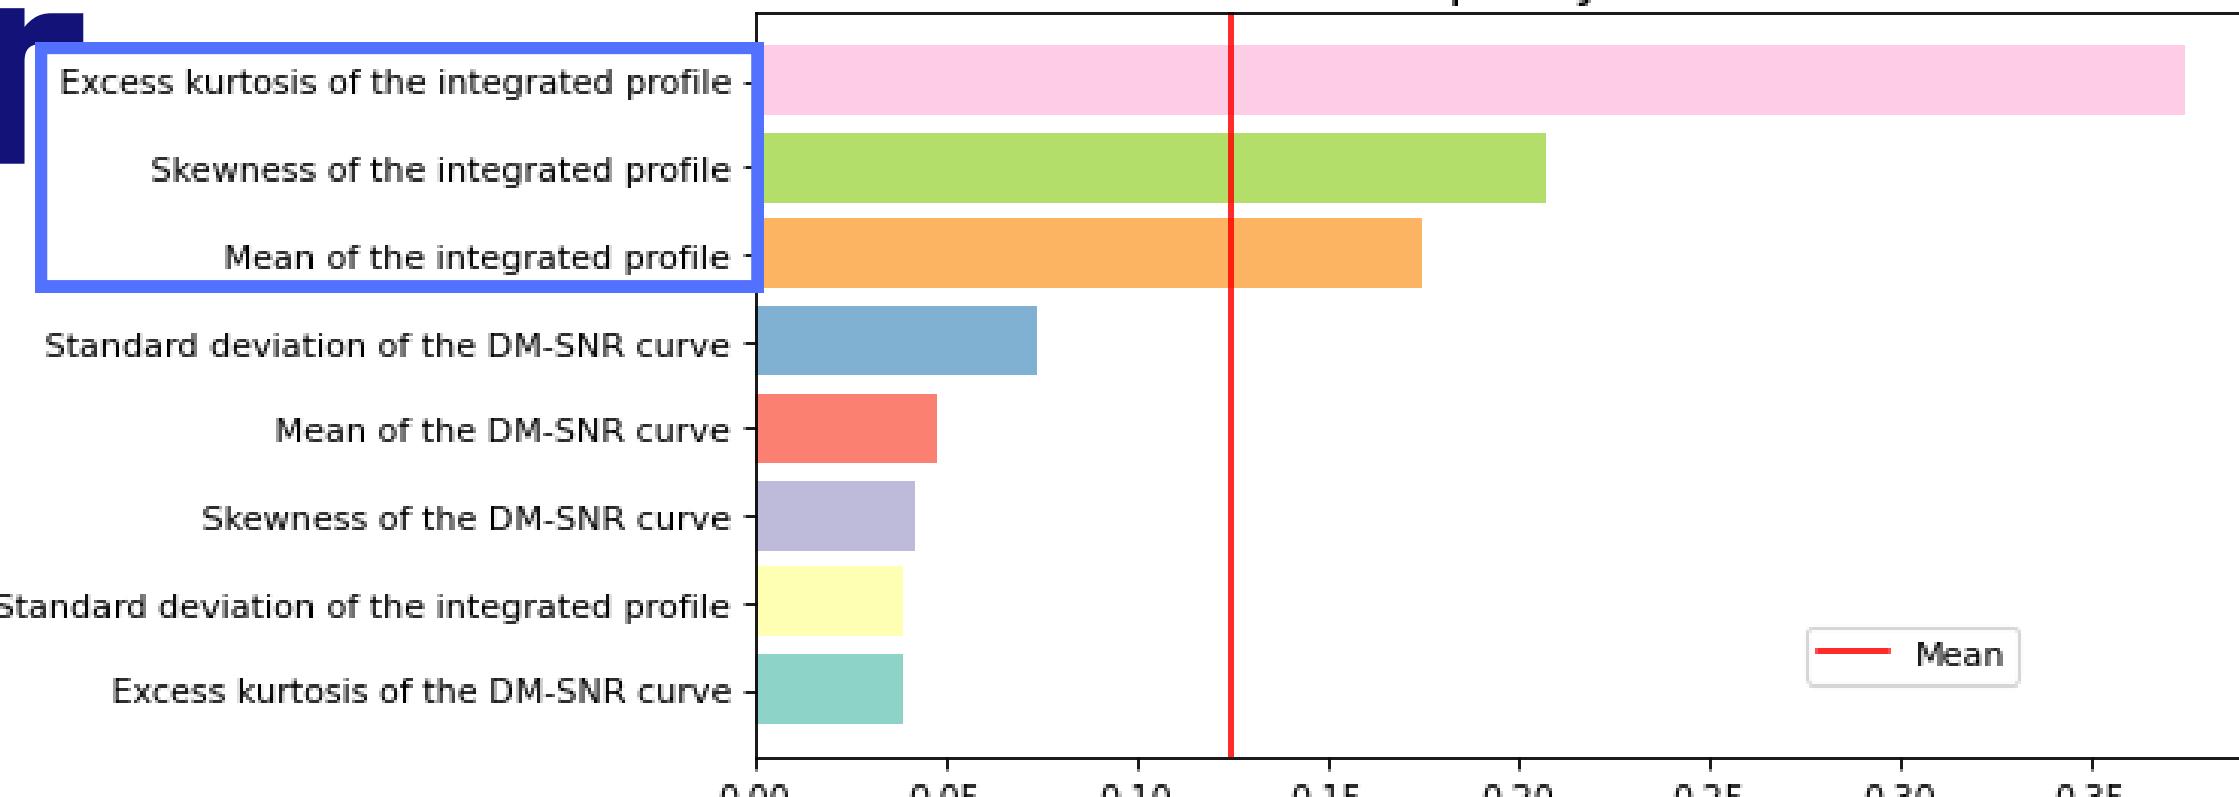


Pulsar Star

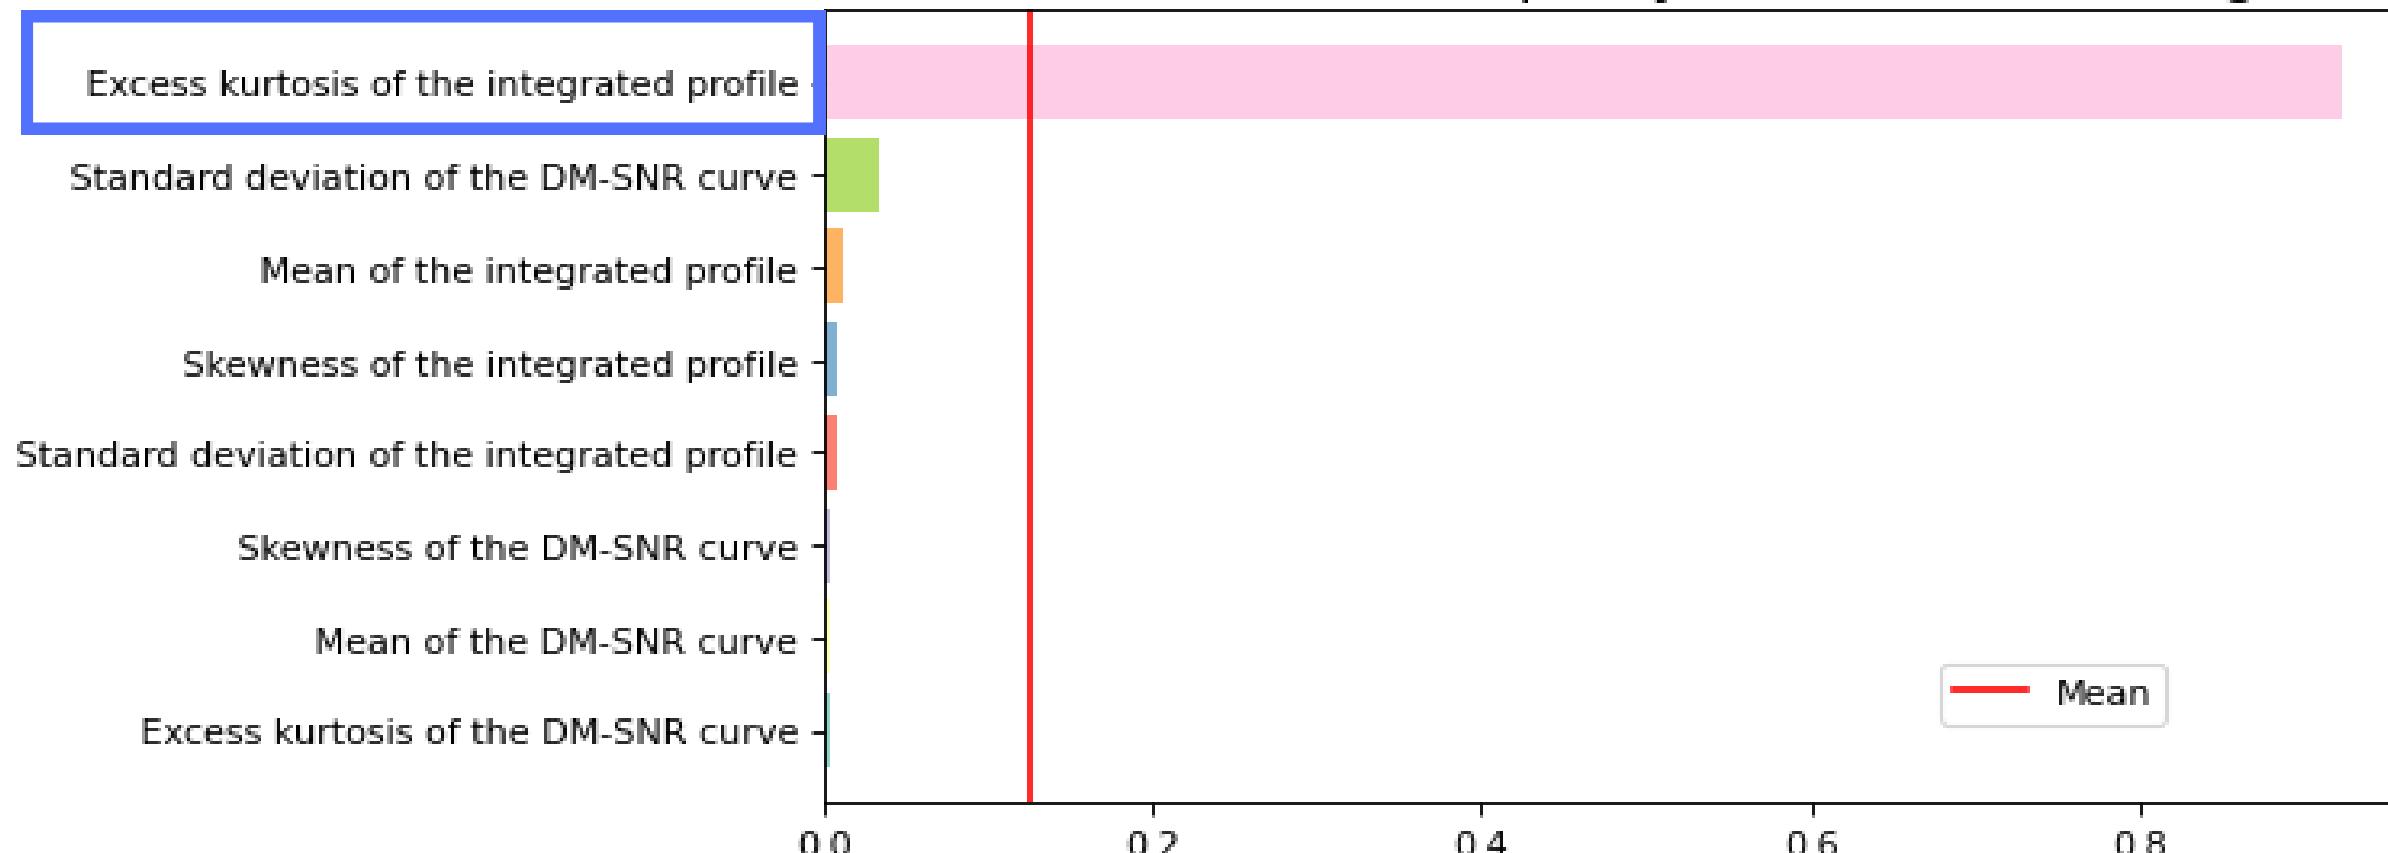
Engineering Data Analysis

상관관계와 마찬가지로
Excess kurtosis of the
integrated profile 특성이
제일 중요하게 나타남

Mean Decrease Impurity : Random Forest



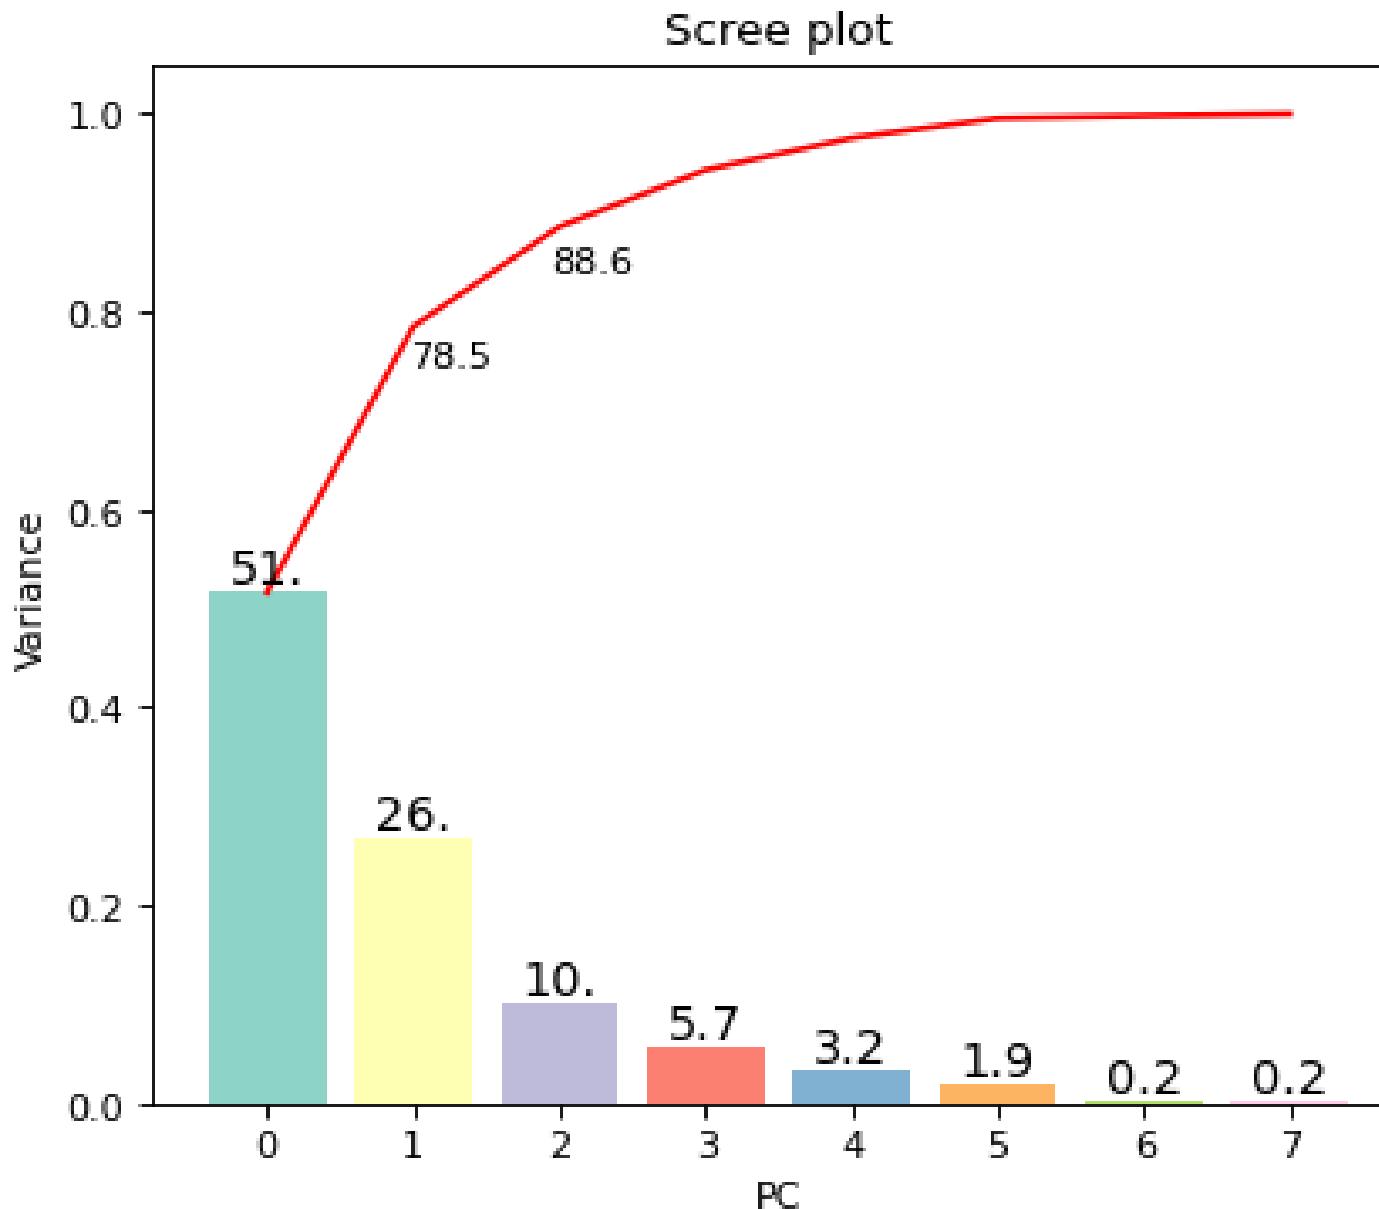
Mean Decrease Impurity : Gradient Boosting



Pulsar Star

Engineering Data Analysis

- PCA 결과 3개 요인이 88%의 분산을 설명
- 5개 특성만으로 주요인분석을 실시한 결과
2개 요인이 90% 설명



PCA의 요인에 따른 머신러닝 성능 비교 결과
기존 모델에 비해 성능 향상이 없음

score_name	model_name	data_name	Whole Features	PCA of Whole Features	PCA of Correlation
Precision	Logistic	Train	0.93993	0.93327	0.93113
	Regression	Test	0.95470	0.96838	0.96565
	Random	Train	1.00000	1.00000	1.00000
	Forest	Test	0.95017	0.94502	0.92308
	Gradient	Train	0.94930	0.94987	0.93692
	Boosting	Test	0.92208	0.93836	0.91883
Recall	Logistic	Train	0.81972	0.74345	0.76040
	Regression	Test	0.80352	0.71848	0.74194
	Random	Train	0.99923	0.99923	0.99923
	Forest	Test	0.83871	0.80645	0.80938
	Gradient	Train	0.89445	0.84669	0.85824
	Boosting	Test	0.83284	0.80352	0.82991
Accuracy	Logistic	Train	0.97891	0.97192	0.97318
	Regression	Test	0.97765	0.97095	0.97291
	Random	Train	0.99993	0.99993	0.99993
	Forest	Test	0.98045	0.97709	0.97542
	Gradient	Train	0.98610	0.98205	0.98191
	Boosting	Test	0.97737	0.97626	0.97682
F1	Logistic	Train	0.87572	0.82762	0.83715
	Regression	Test	0.87261	0.82492	0.83914
	Random	Train	0.99961	0.99961	0.99961
	Forest	Test	0.89097	0.87025	0.86250
	Gradient	Train	0.92106	0.89532	0.89586
	Boosting	Test	0.87519	0.86572	0.87211

Pulsar Star.. Insight!

탐색적 데이터 분석

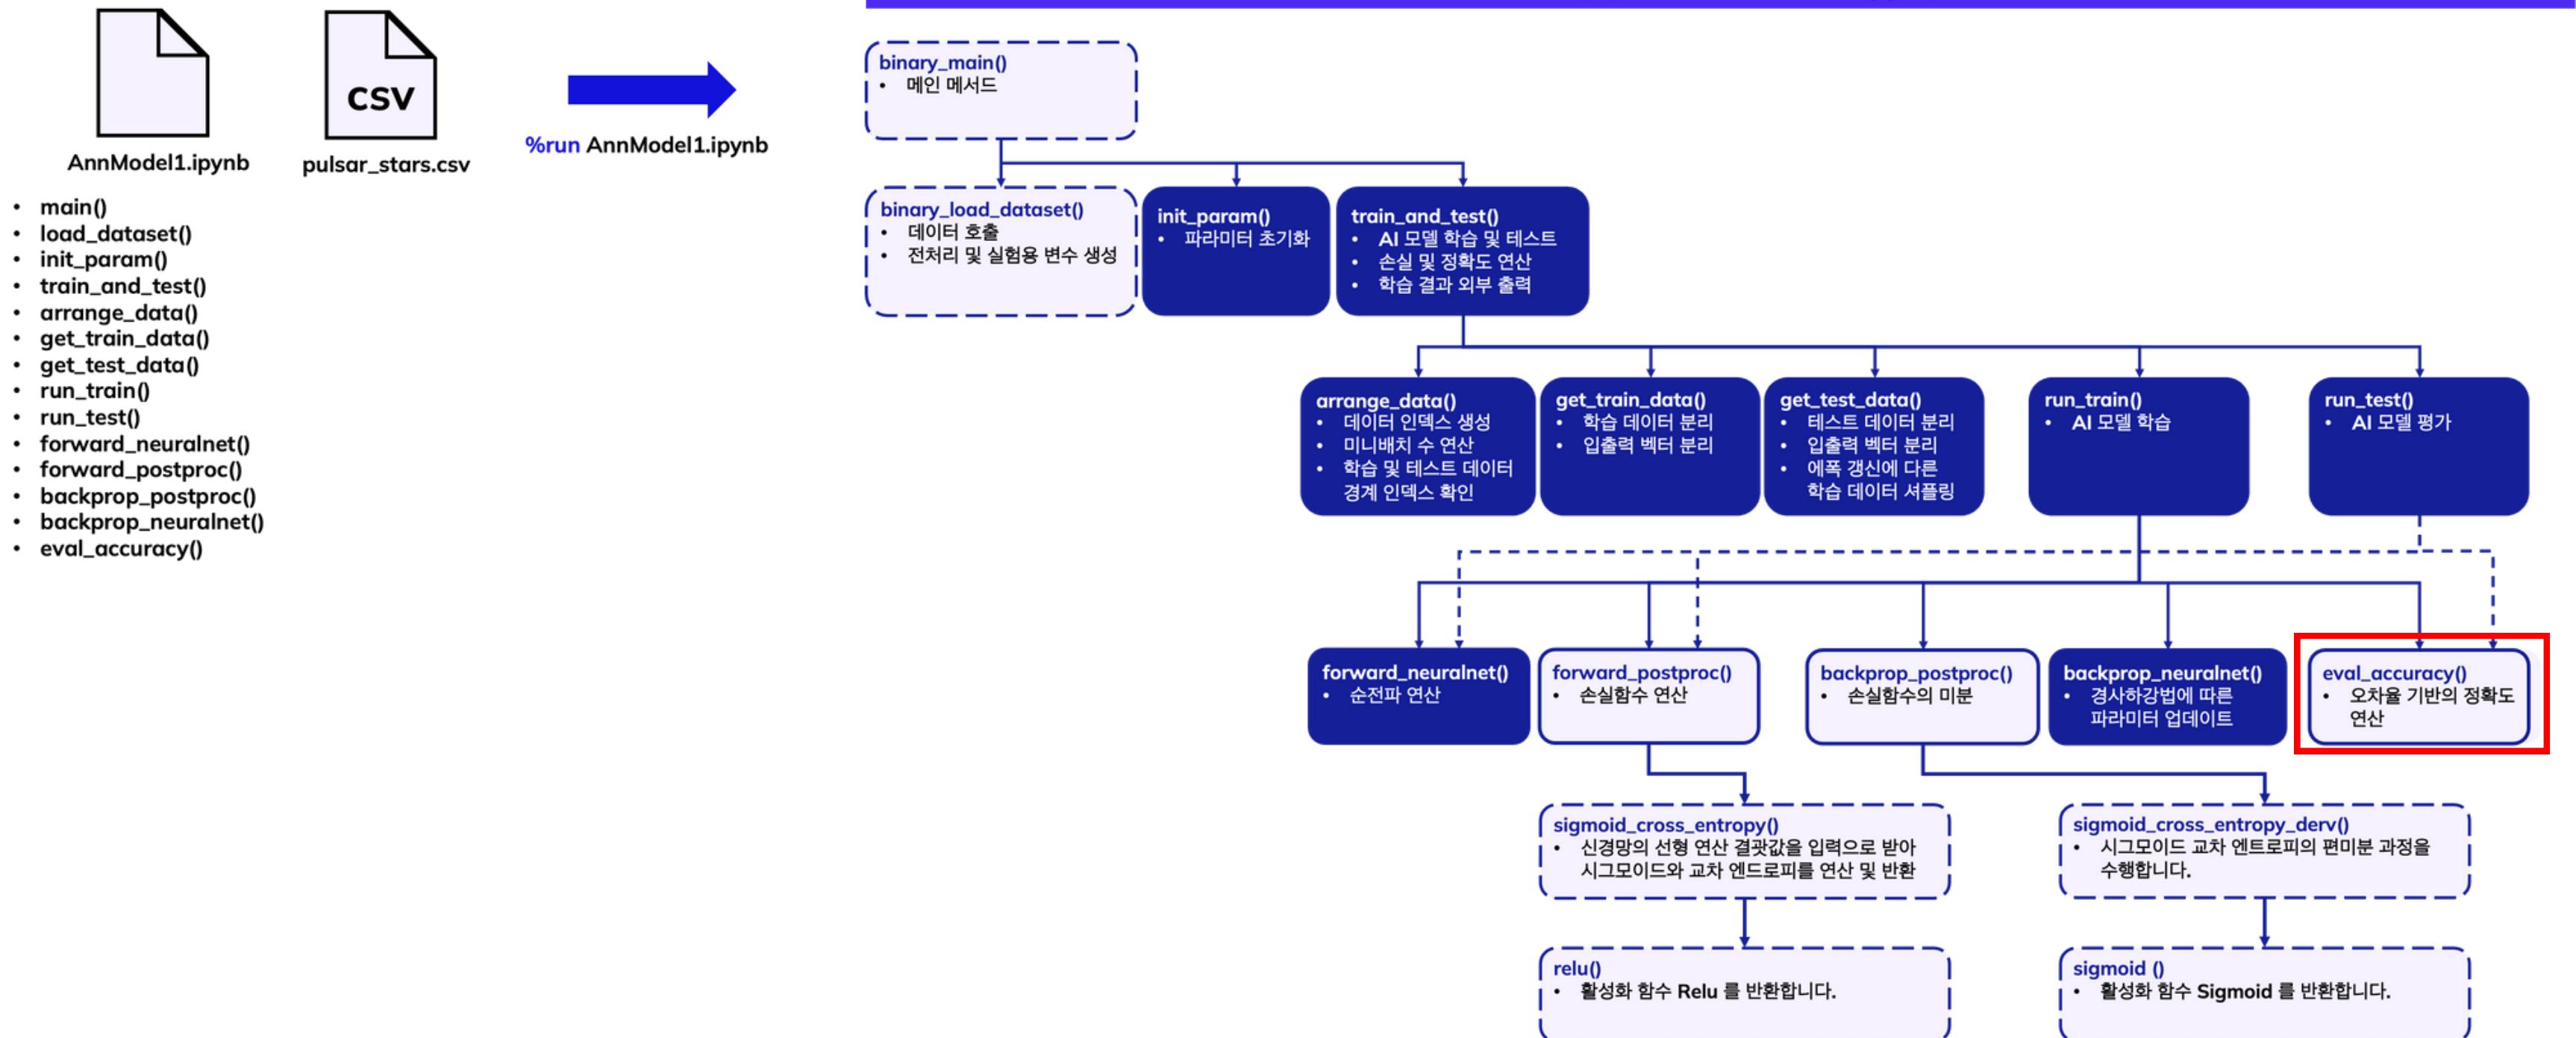
특성공학

옵티마이저 선택

- 타겟이 **불균형**하여 **Accuracy**만으로는 평가가 부적절함
 - **Precision, Recall, F1-score** 도입
- **통합 프로파일의 과도한 첨도**가 중요하게 작용함
- **이상치**로 보이는 데이터에 대한 제거 혹은 스케일링 필요
- 새로운 특성(넓이, 둘레) 생성
 - 넓이(Area) = 가로 x 세로 x π
 - 껍질의 둘레(Perimeter) = $2\pi \times (0.5 \times \sqrt{\text{가로}^2 + \text{세로}^2})$
- 단순모델로 실험한 결과 Adam, Nadam, Adamax 가 좋은 성능
- 가장 범용으로 사용되는 **Adam**을 옵티마이저로 선택

Pulsar Star

Legacy Model

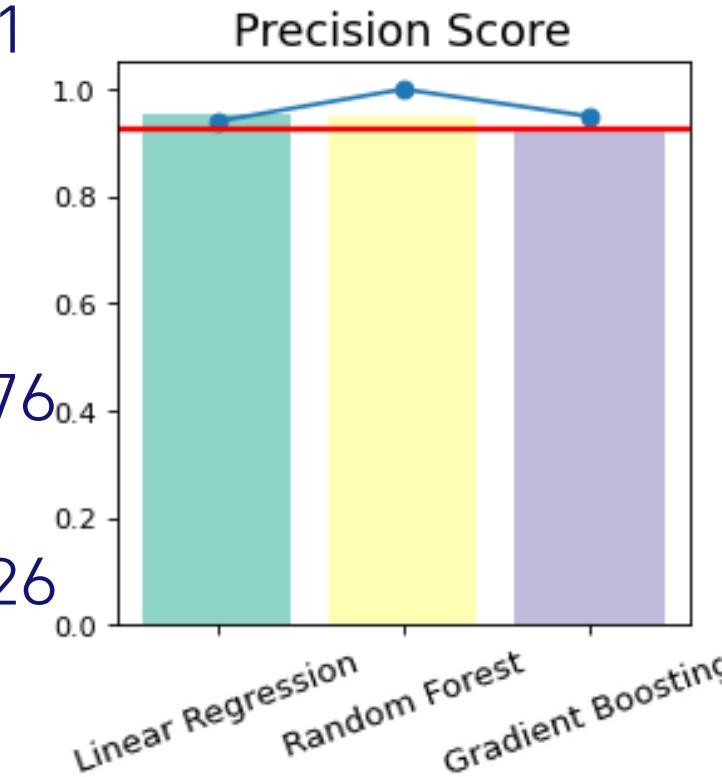


Pulsar Star

Legacy Model

- 기존 모델의 성능

- Epoch : 10 , lr : 0.001



- Train Loss : 1.014

- Test Accuracy = 0.976

- Test Precision = 0.926

- Test Recall = 0.789

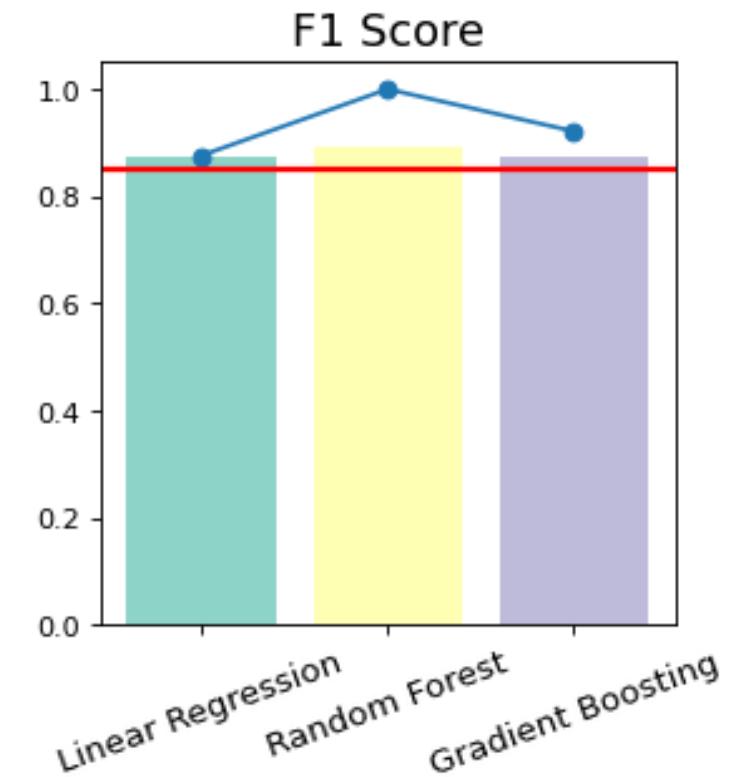
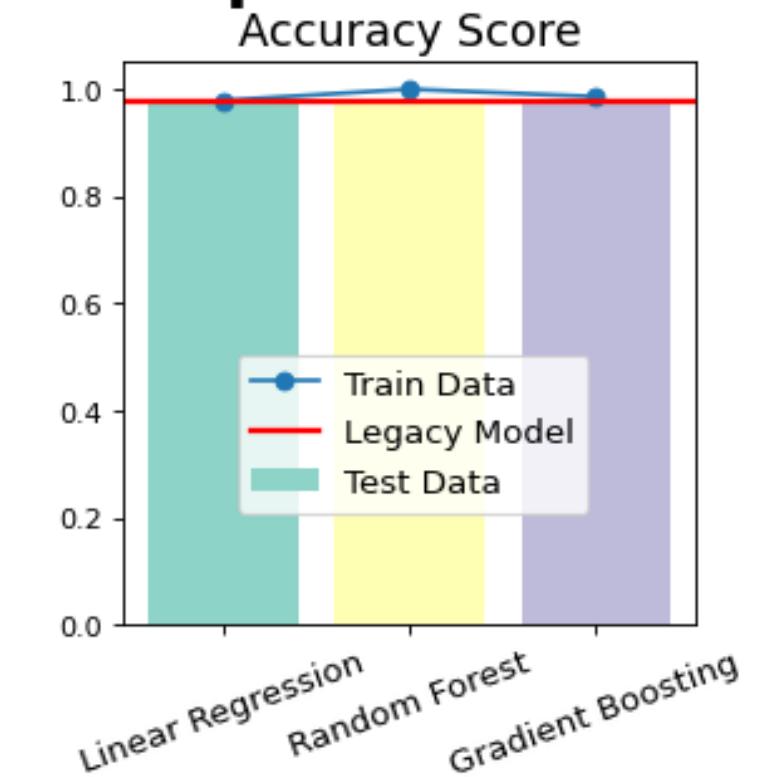
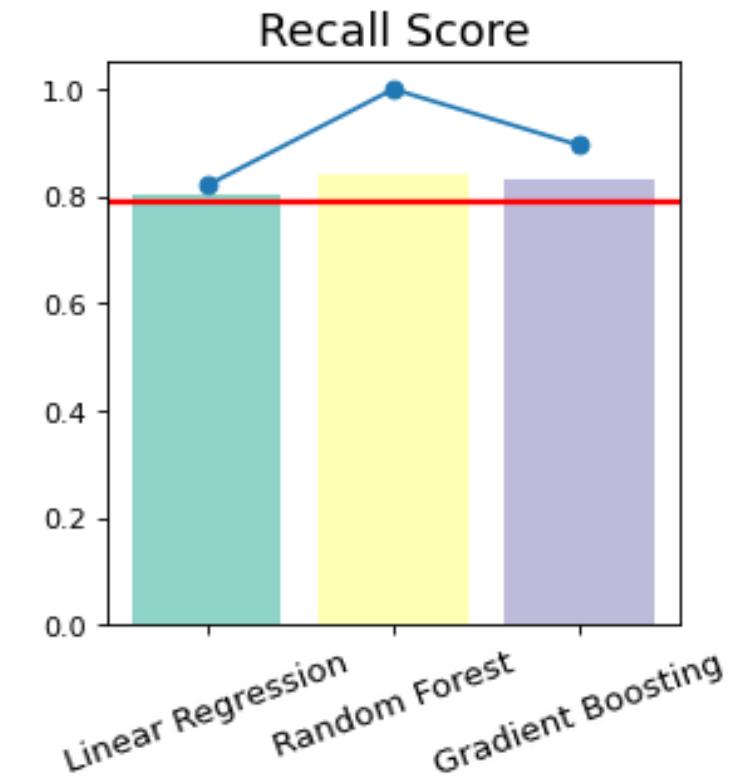
- Test F1 = 0.852

- 기존 모델과 머신러닝 모델과 성능 비교

- 대표적인 머신러닝 모델인 Logistic Regression, Random Forest, Gradient Boosting 사용

머신러닝 모델들의 평가지표는
기준모델과 비슷한 수준

ML Model Compare

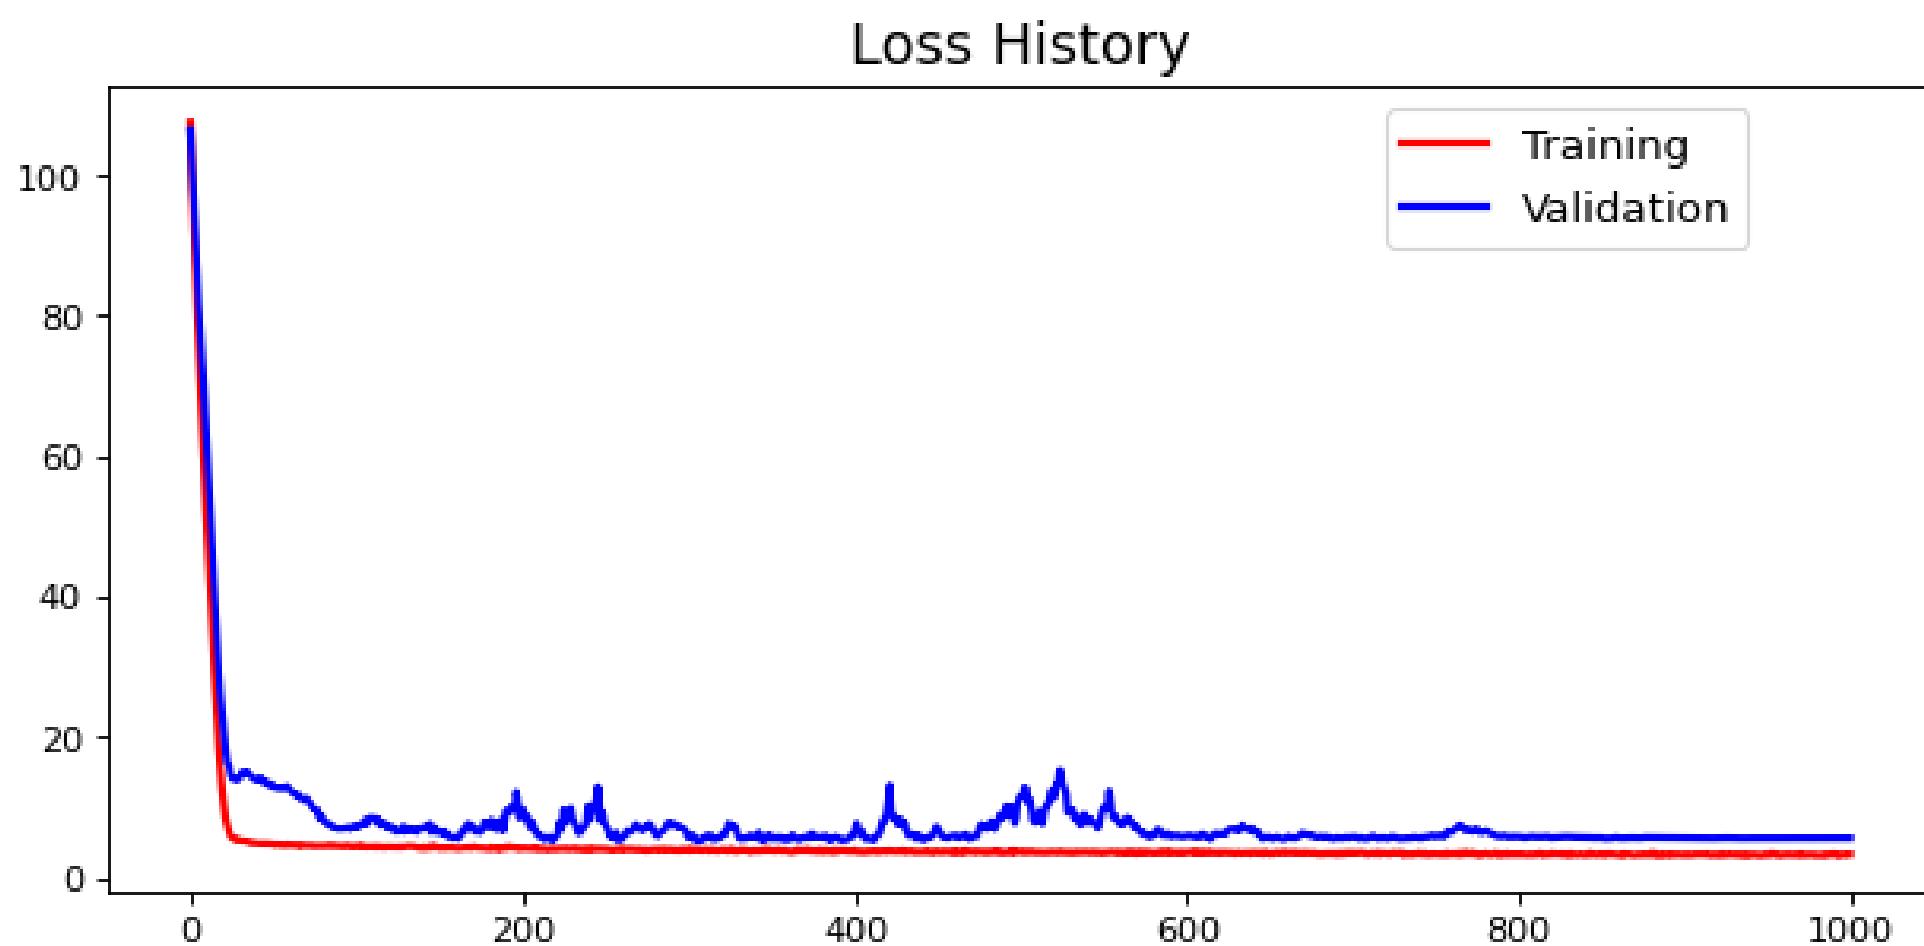
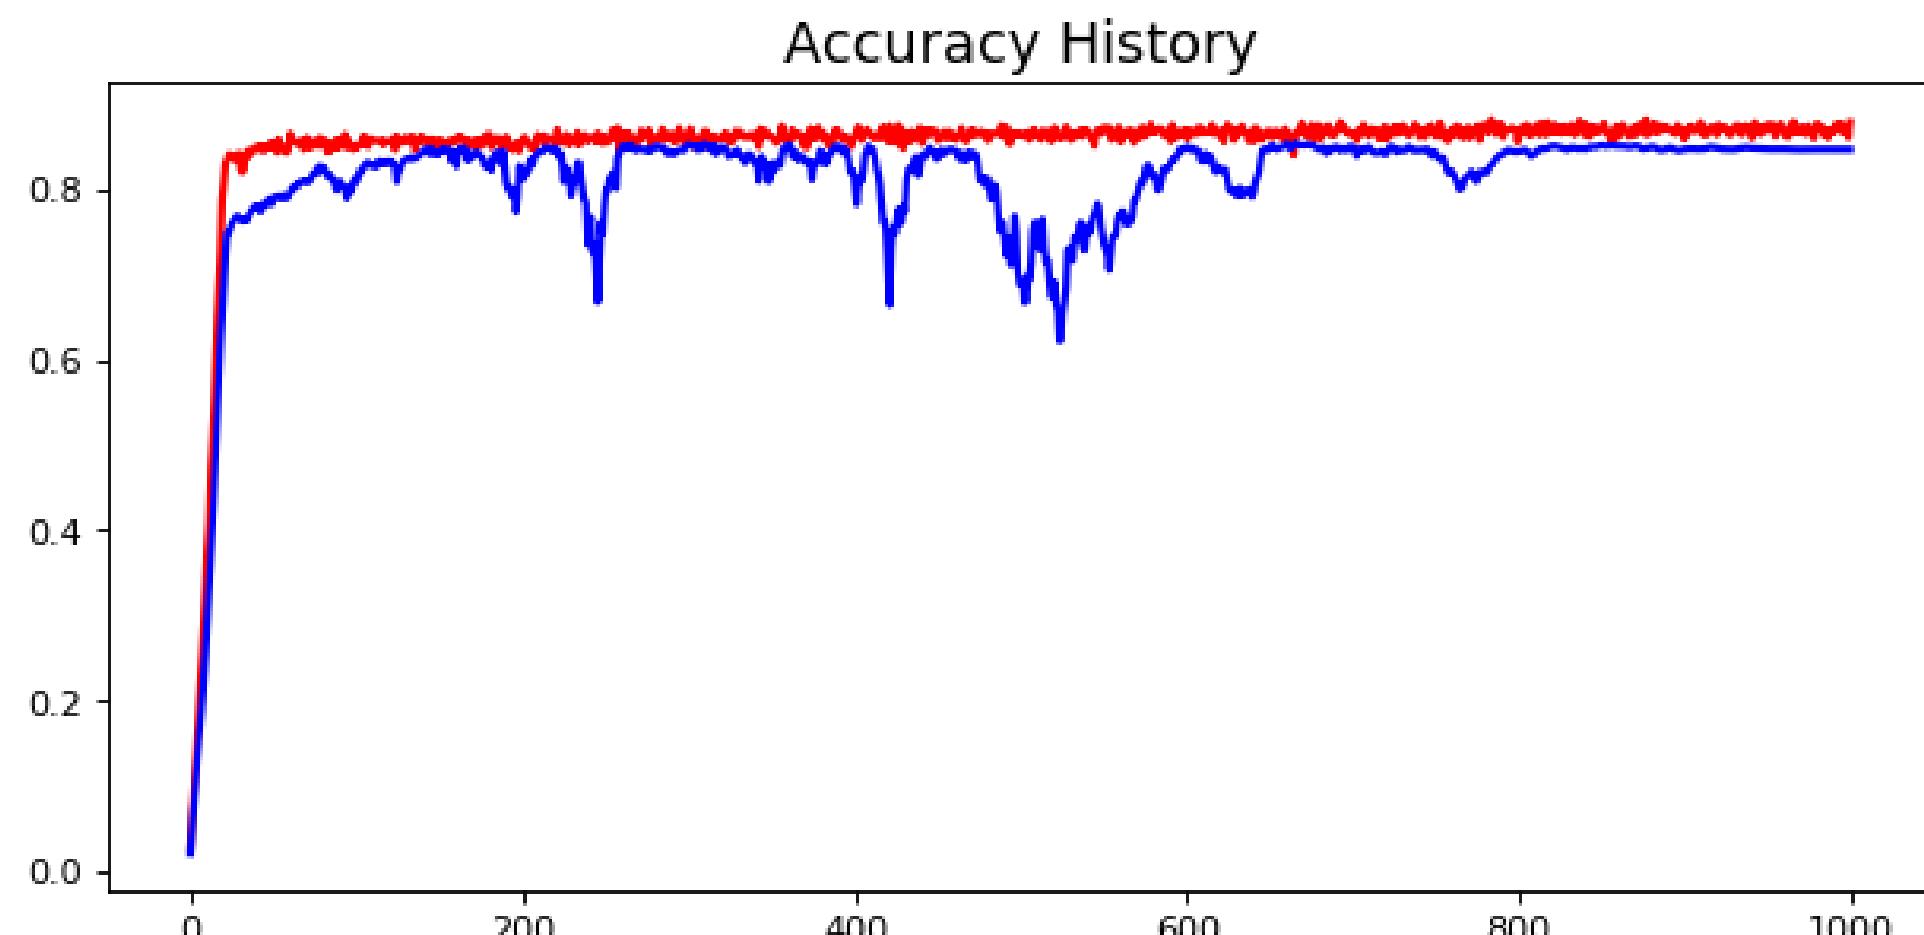


Pursal Star

Deep learning

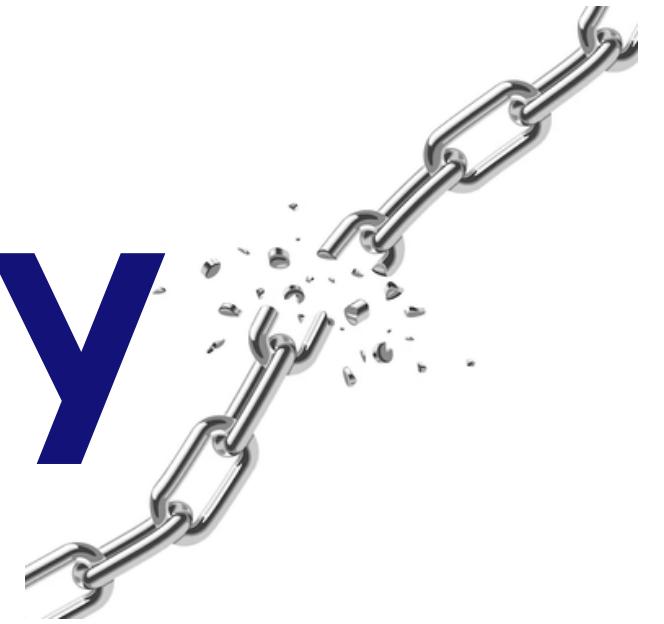
모델구성

- 은닉층, 노드 추가
- 배치정규화, 학습률조정, 스킁연결
- 과적합 방지 : 드롭아웃, 가중치패널티(L1,L2), 조기종료
- 학습결과
 - Test Loss : 5.313 / Accuracy : 0.899
 - Train Score가 Validation Score와 갖거나 오히려 일부 구간에서는 낮게 나타나 과소적합 의심
 - 모델의 복잡도를 올리는 방향으로 모델 개선 필요
- 가설 : 은닉층과 노드가 늘어나면 성능이 오를 것
 - 은닉층과 노드를 늘려도 성능에 큰 변화가 없음
 - 오히려 일정 수치가 넘어가면 차원의 저주로 학습이 안됨



Faulty Steel

Domain Understanding



Target

1. Pastry : 강판의 특정 부분이 너무 얇아져 결함이 발생한 경우
2. Z_Scratch : 강판에 'Z' 모양의 스크래치가 생긴 경우
3. K_Scratch : 강판에 'K' 모양의 스크래치가 생긴 경우
4. Stains : 강판에 얼룩이나 불순물이 생긴 경우
5. Dirtiness : 강판이 더러워진 경우
6. Bumps : 강판에 돌기나 울퉁불퉁한 부분이 생긴 경우
7. Other_Faults : 위의 카테고리에 속하지 않는 기타 다른 종류의 결함

강판 결함 분석은 제조 공정에서 중요한 부분.

강판은 건축, 자동차, 선박, 가전제품 등 다양한 산업에서 사용되는 주요 소재이기 때문에, 그 품질은 최종 제품의 품질에 직접적인 영향을 미치고 제조 효율성, 안전성, 그리고 경제성을 높이는 데 매우 중요함.

1. 강판의 특성:

강판의 결함은 종류와 크기에 따라 다양하게 나타남. 결함의 유형에는 표면상의 불규칙한 부분, 두께의 불규칙, 재질 결함, 구조적 결함 등이 있을 수 있음.

2. 제조 공정:

강판 제조 공정에서의 다양한 단계에서 결함이 발생할 수 있음. 예를 들어, 제련, 주조, 압연, 열처리, 표면 마무리 등의 단계에서 결함이 발생할 수 있으며, 이는 최종 제품의 품질에 영향을 미침.

3. 감지 기술:

강판 결함 감지는 시각 검사, 자동 결함 감지 시스템, 비파괴 검사 등 다양한 방법으로 수행될 수 있음. 머신 러닝 및 AI는 이러한 결함 감지 작업을 자동화하고 정확성을 높이는 데 도움이 될 수 있음.

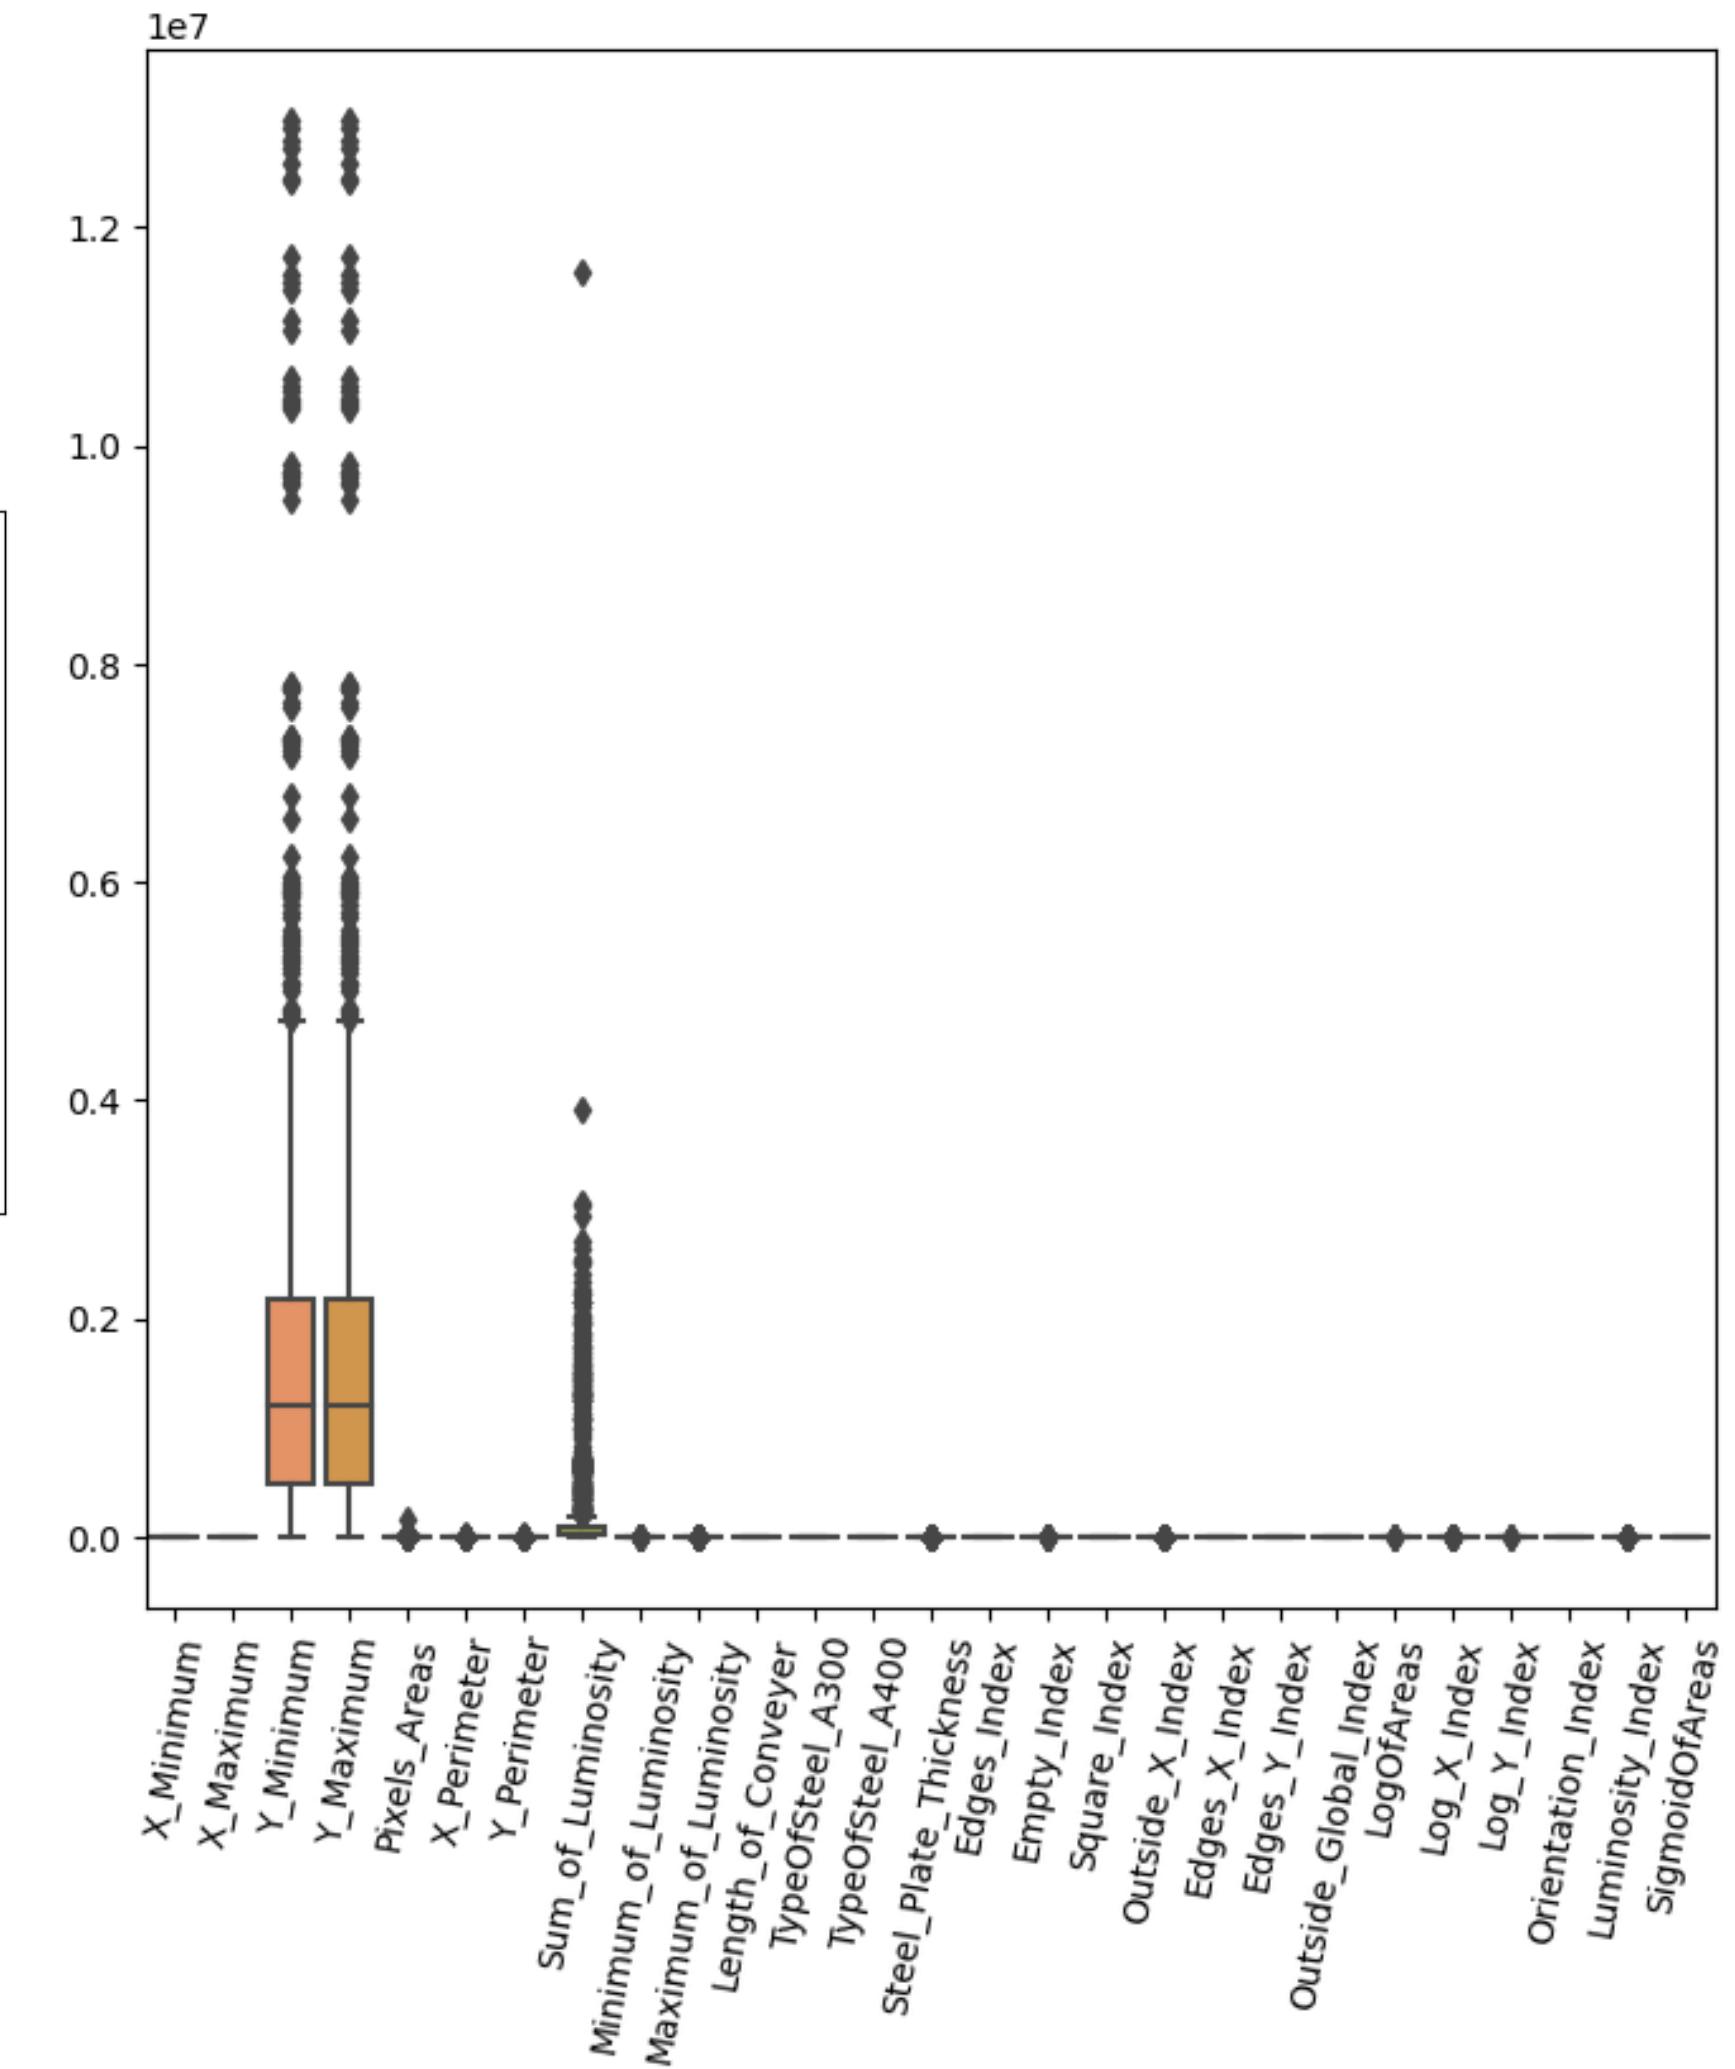
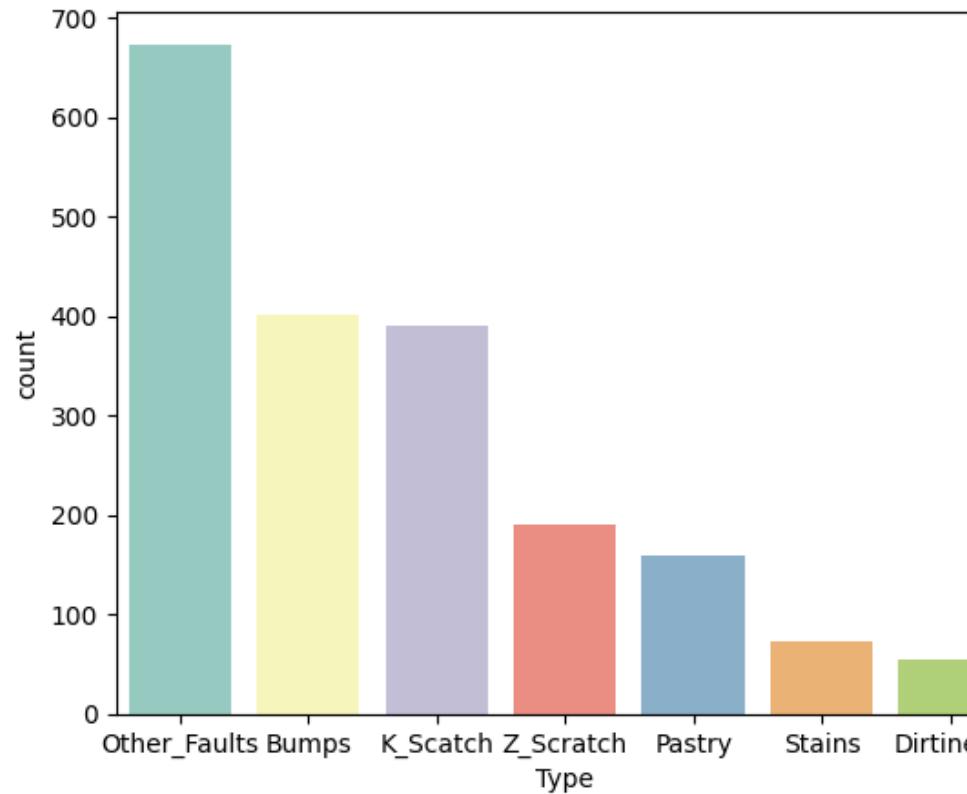
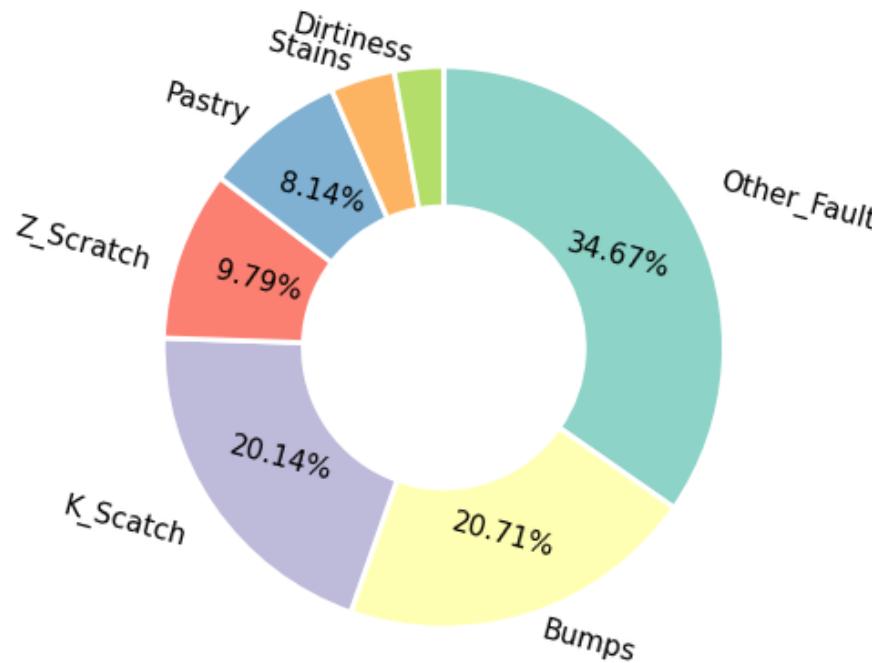
4. 분석 및 품질 관리:

결함 분석은 결함의 원인을 찾고, 제조 공정을 개선하여 향후 결함을 방지하는 데 사용됨.

강판의 품질은 ISO 등의 국제 표준에 따라 평가되고 관리됨.

Faulty Steel

Engineering Data Analysis



Target : 'Pastry', 'Z_Scratch', 'K_Scratch', 'Stains',
'Dirtiness', 'Bumps', 'Other_Faults'

**'Other Faults', 'Bumps', 'K_Scratch'가
대부분의 비율을 차지하고 있음.**

Faulty Steel

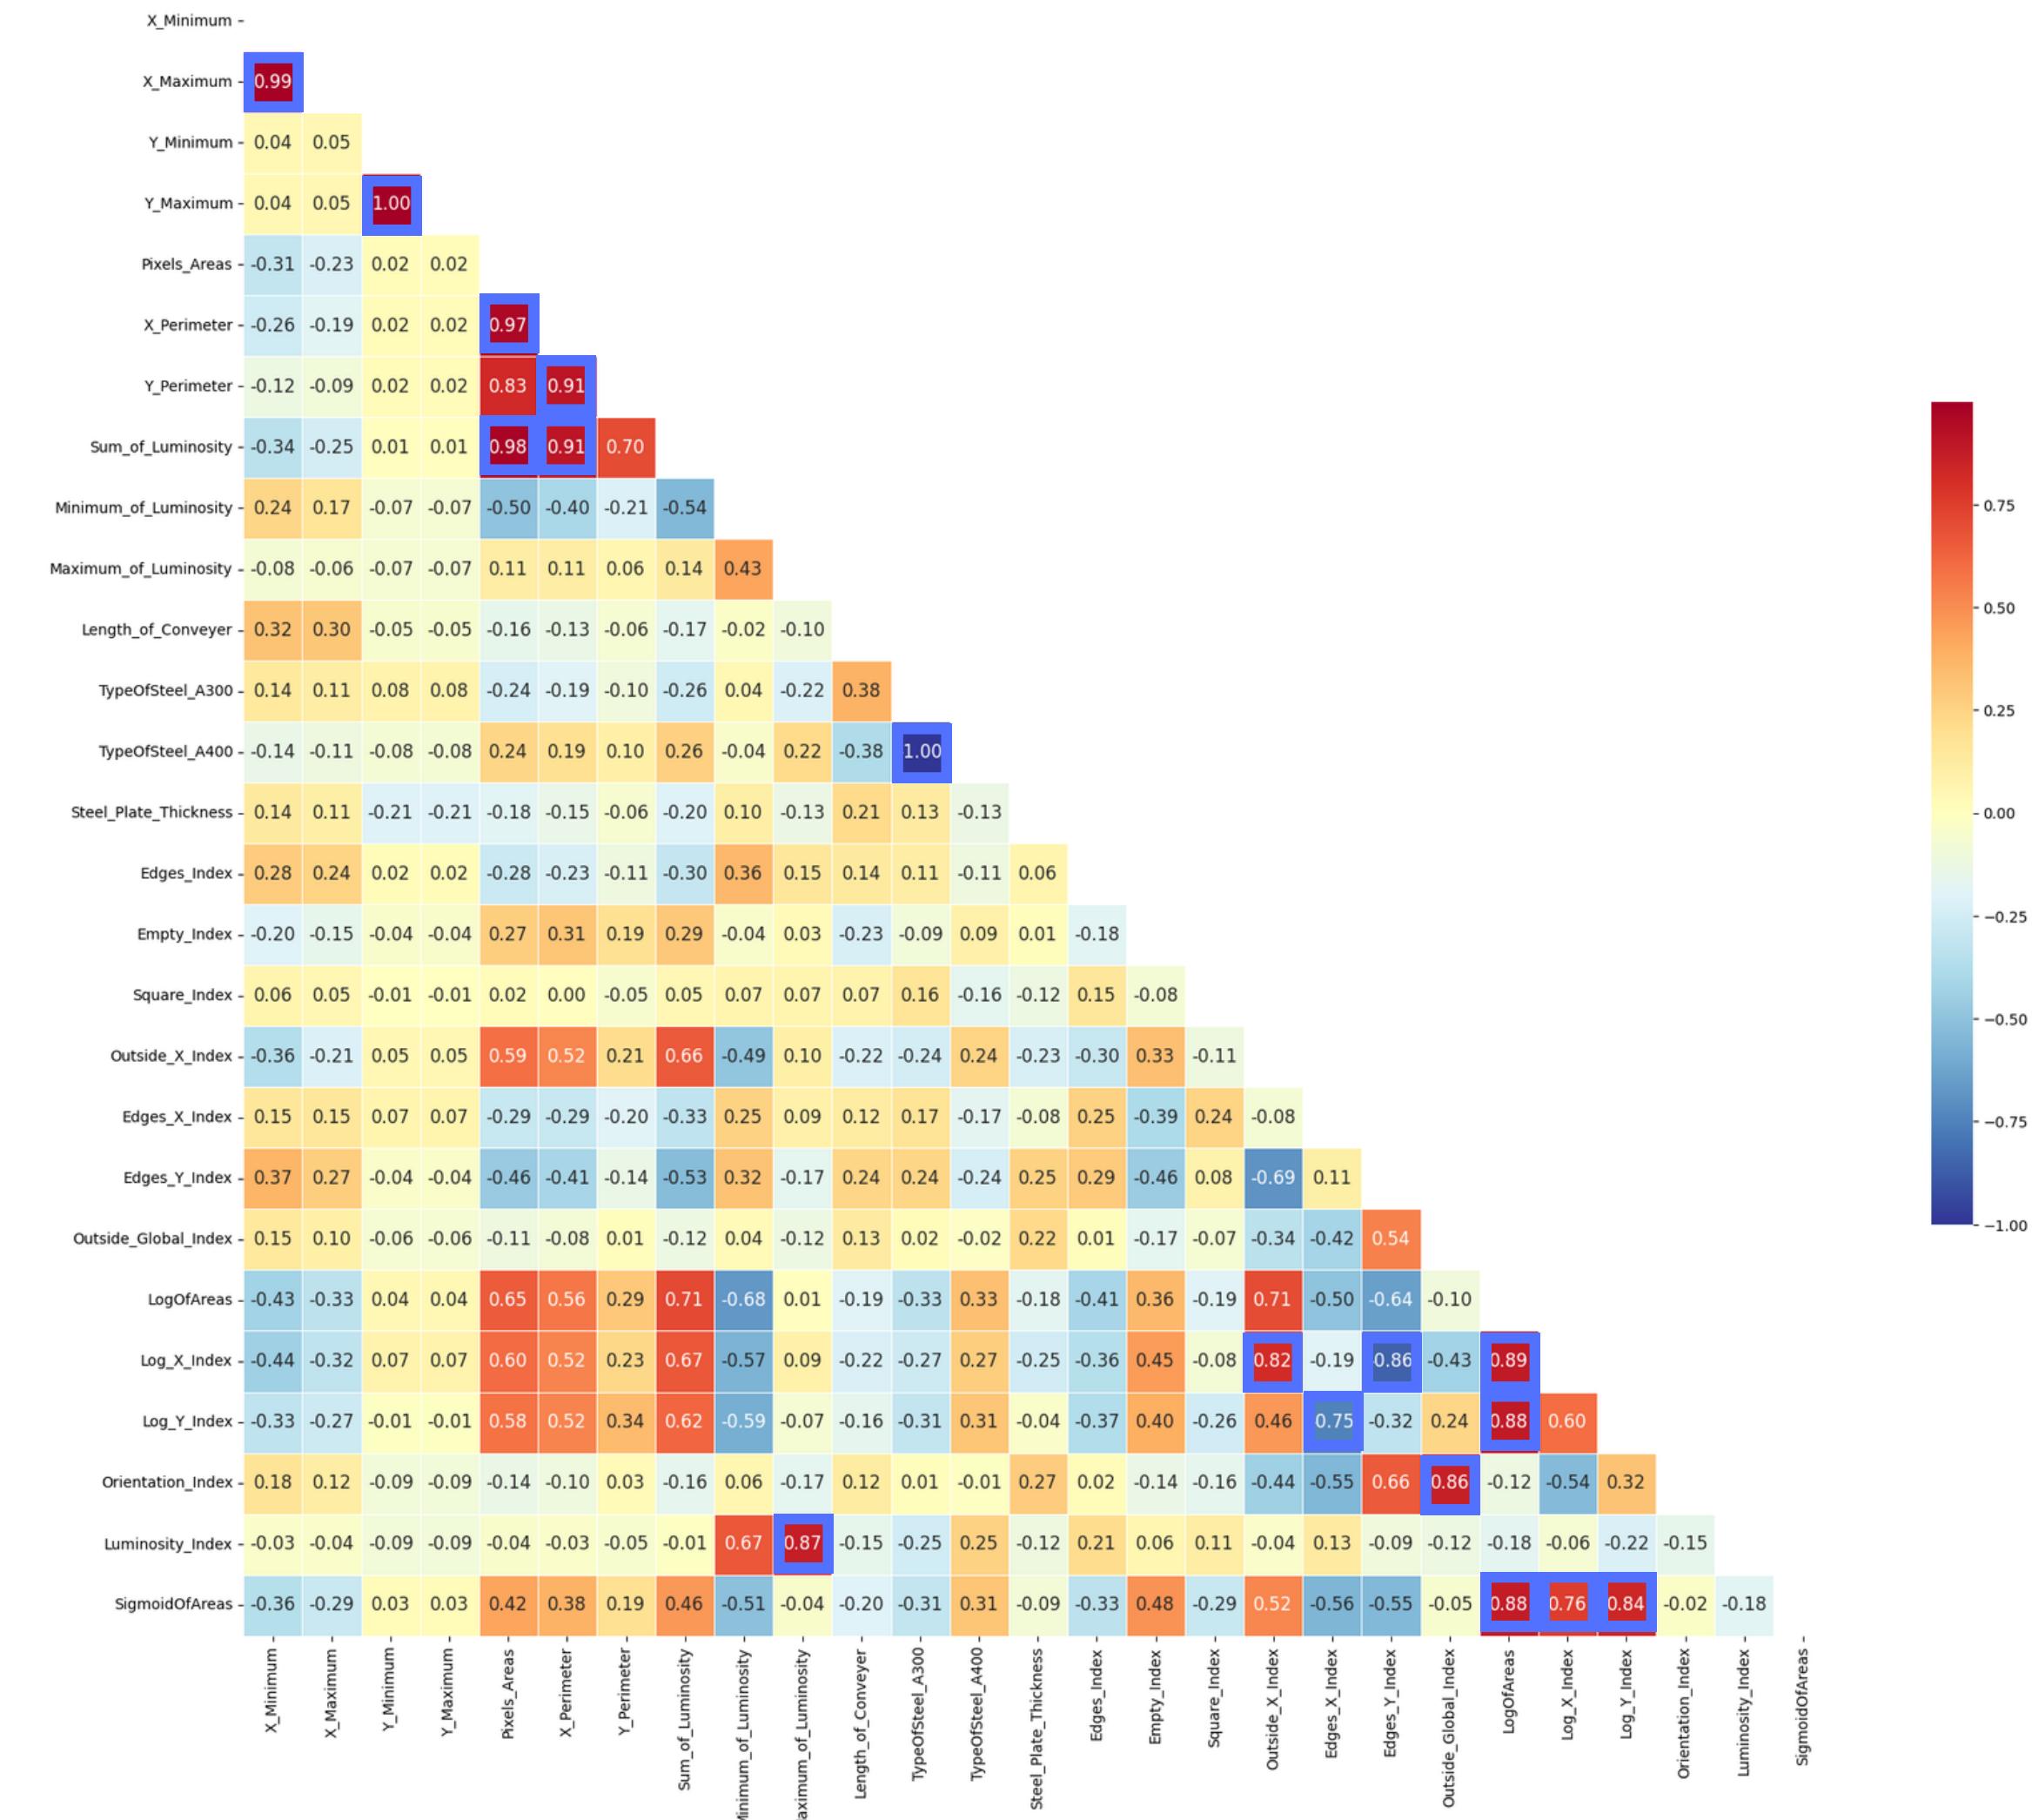
Engineering Data Analysis

일부 특성 사이에 강한 상관관계가 있어 **다중공선성의 문제**를 해결해야 함

□ 모양으로 표시

다중공선성 문제 : 독립변수들이 서로 독립적이지 않고 어느 정도 이상 연관성이 있을 때 발생하는 문제

- 계수 추정의 불안정성
 - 해석의 어려움
 - 과적합 문제



Faulty Steel

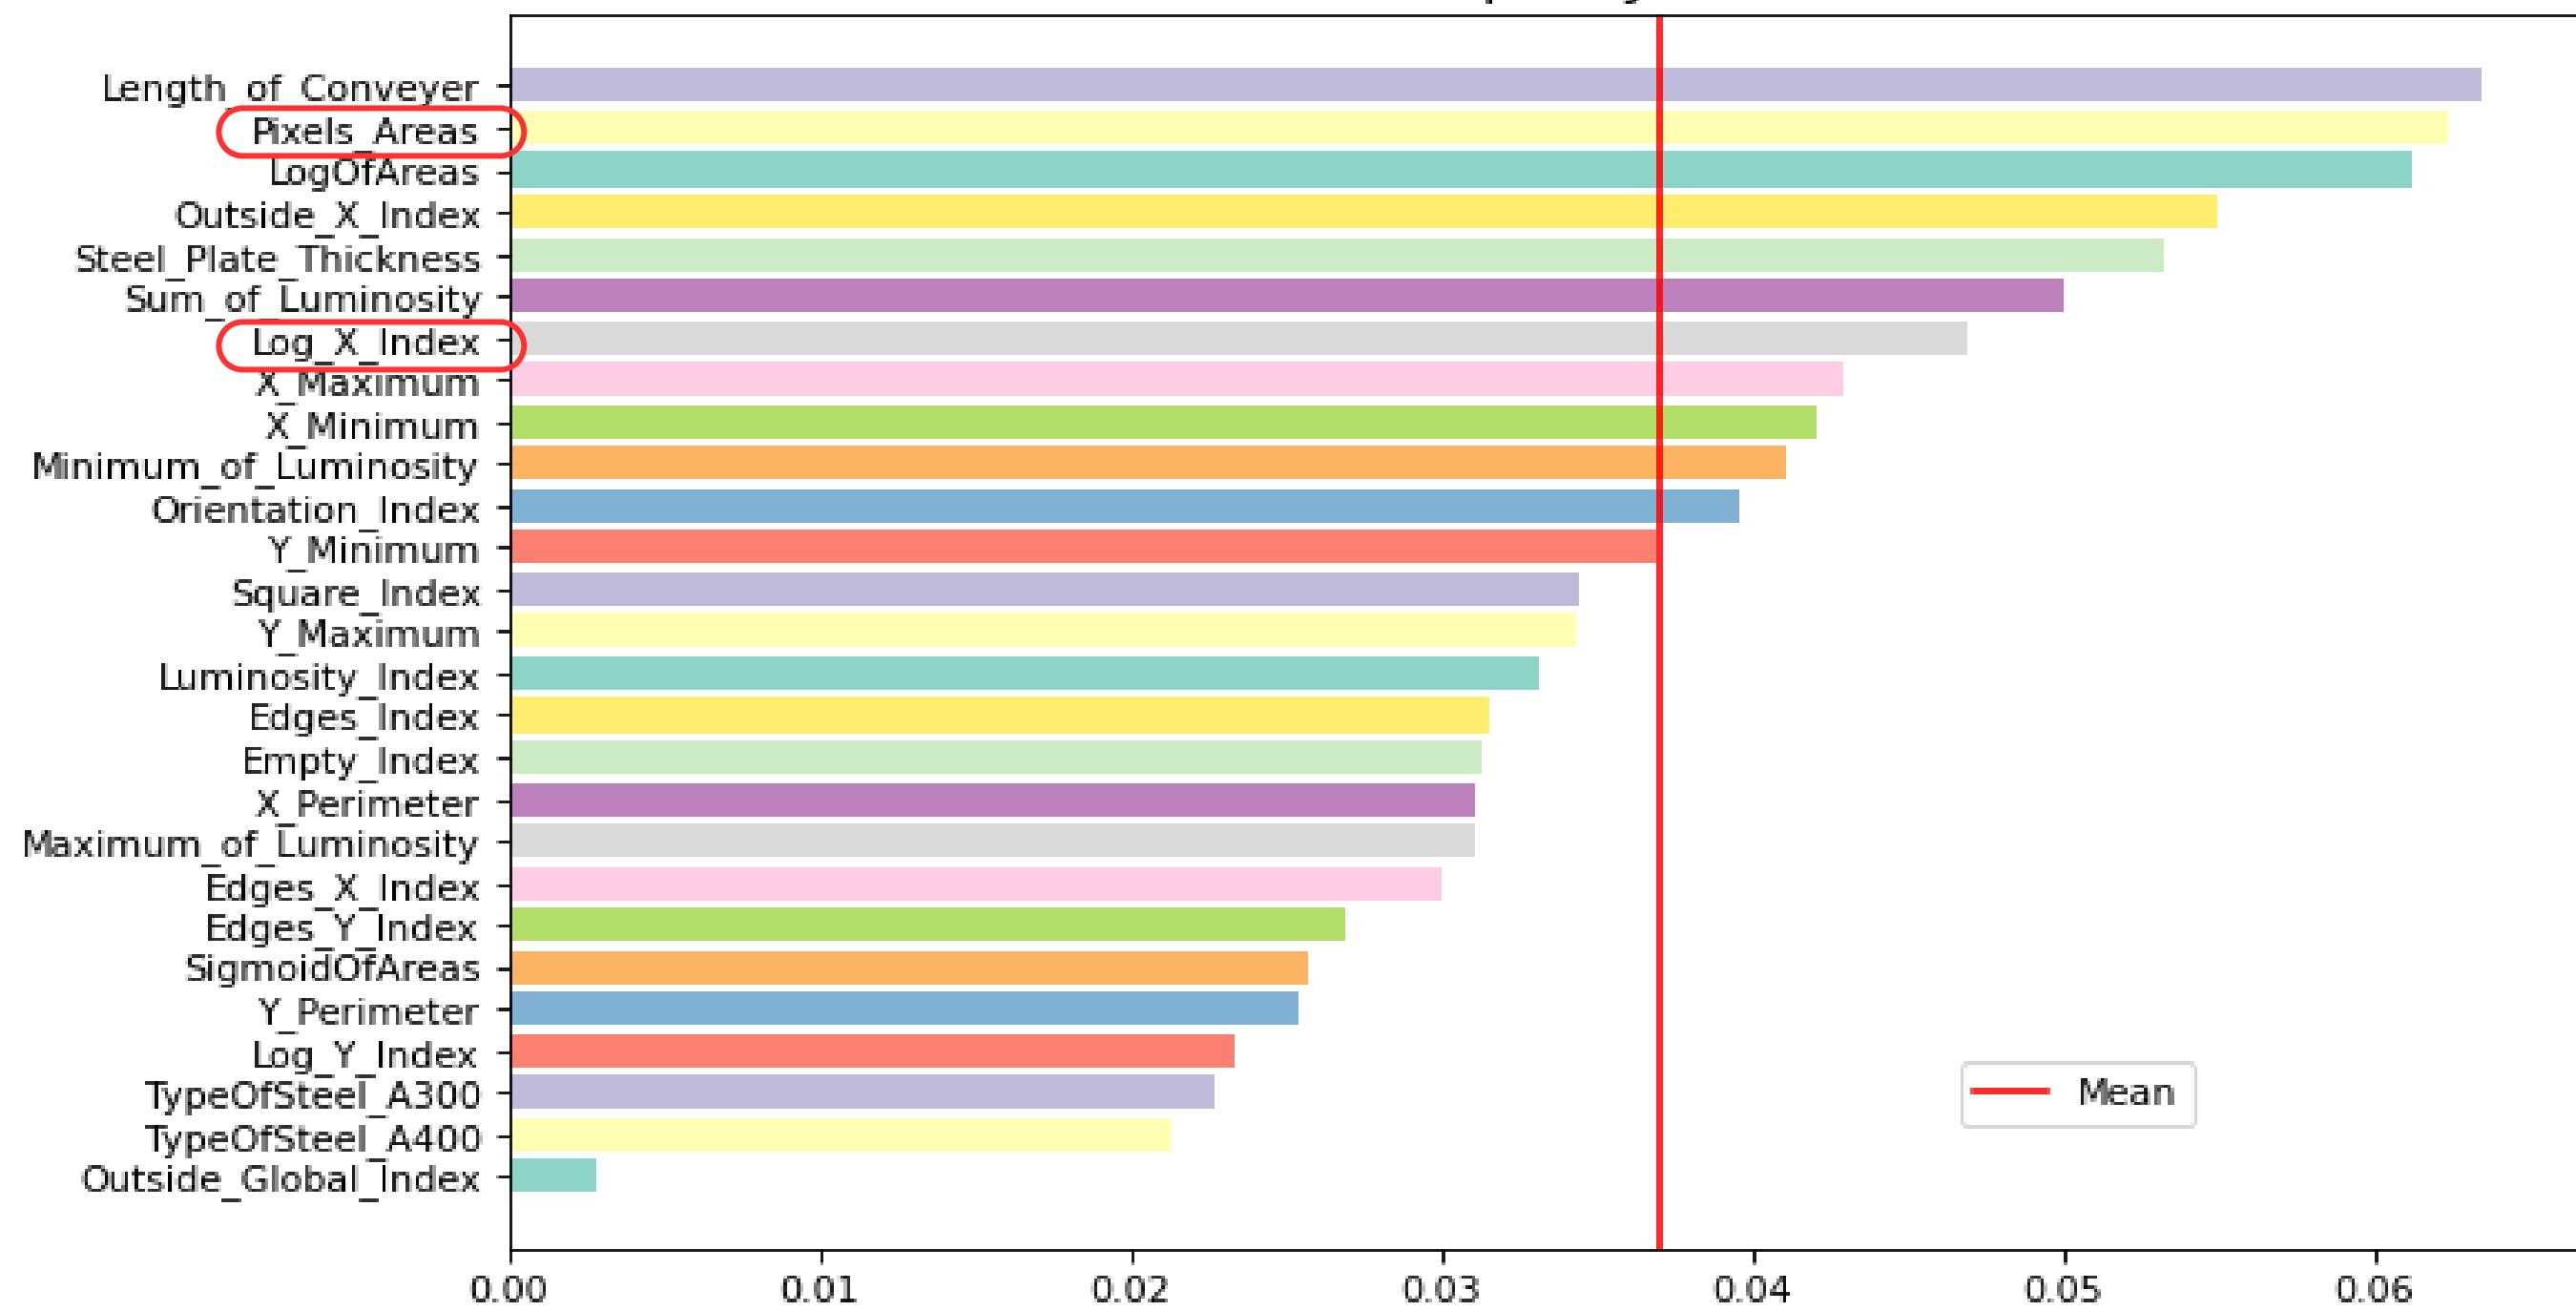
Engineering Data Analysis

▪ 특성 중요도

- 양상블모델에 영향을 미치는 특성중요도를 계산합니다.

- Mean Decrease Impurity
방식의 특성중요도를 사용합니다.

Mean Decrease Impurity : Random Forest



Faulty Steel

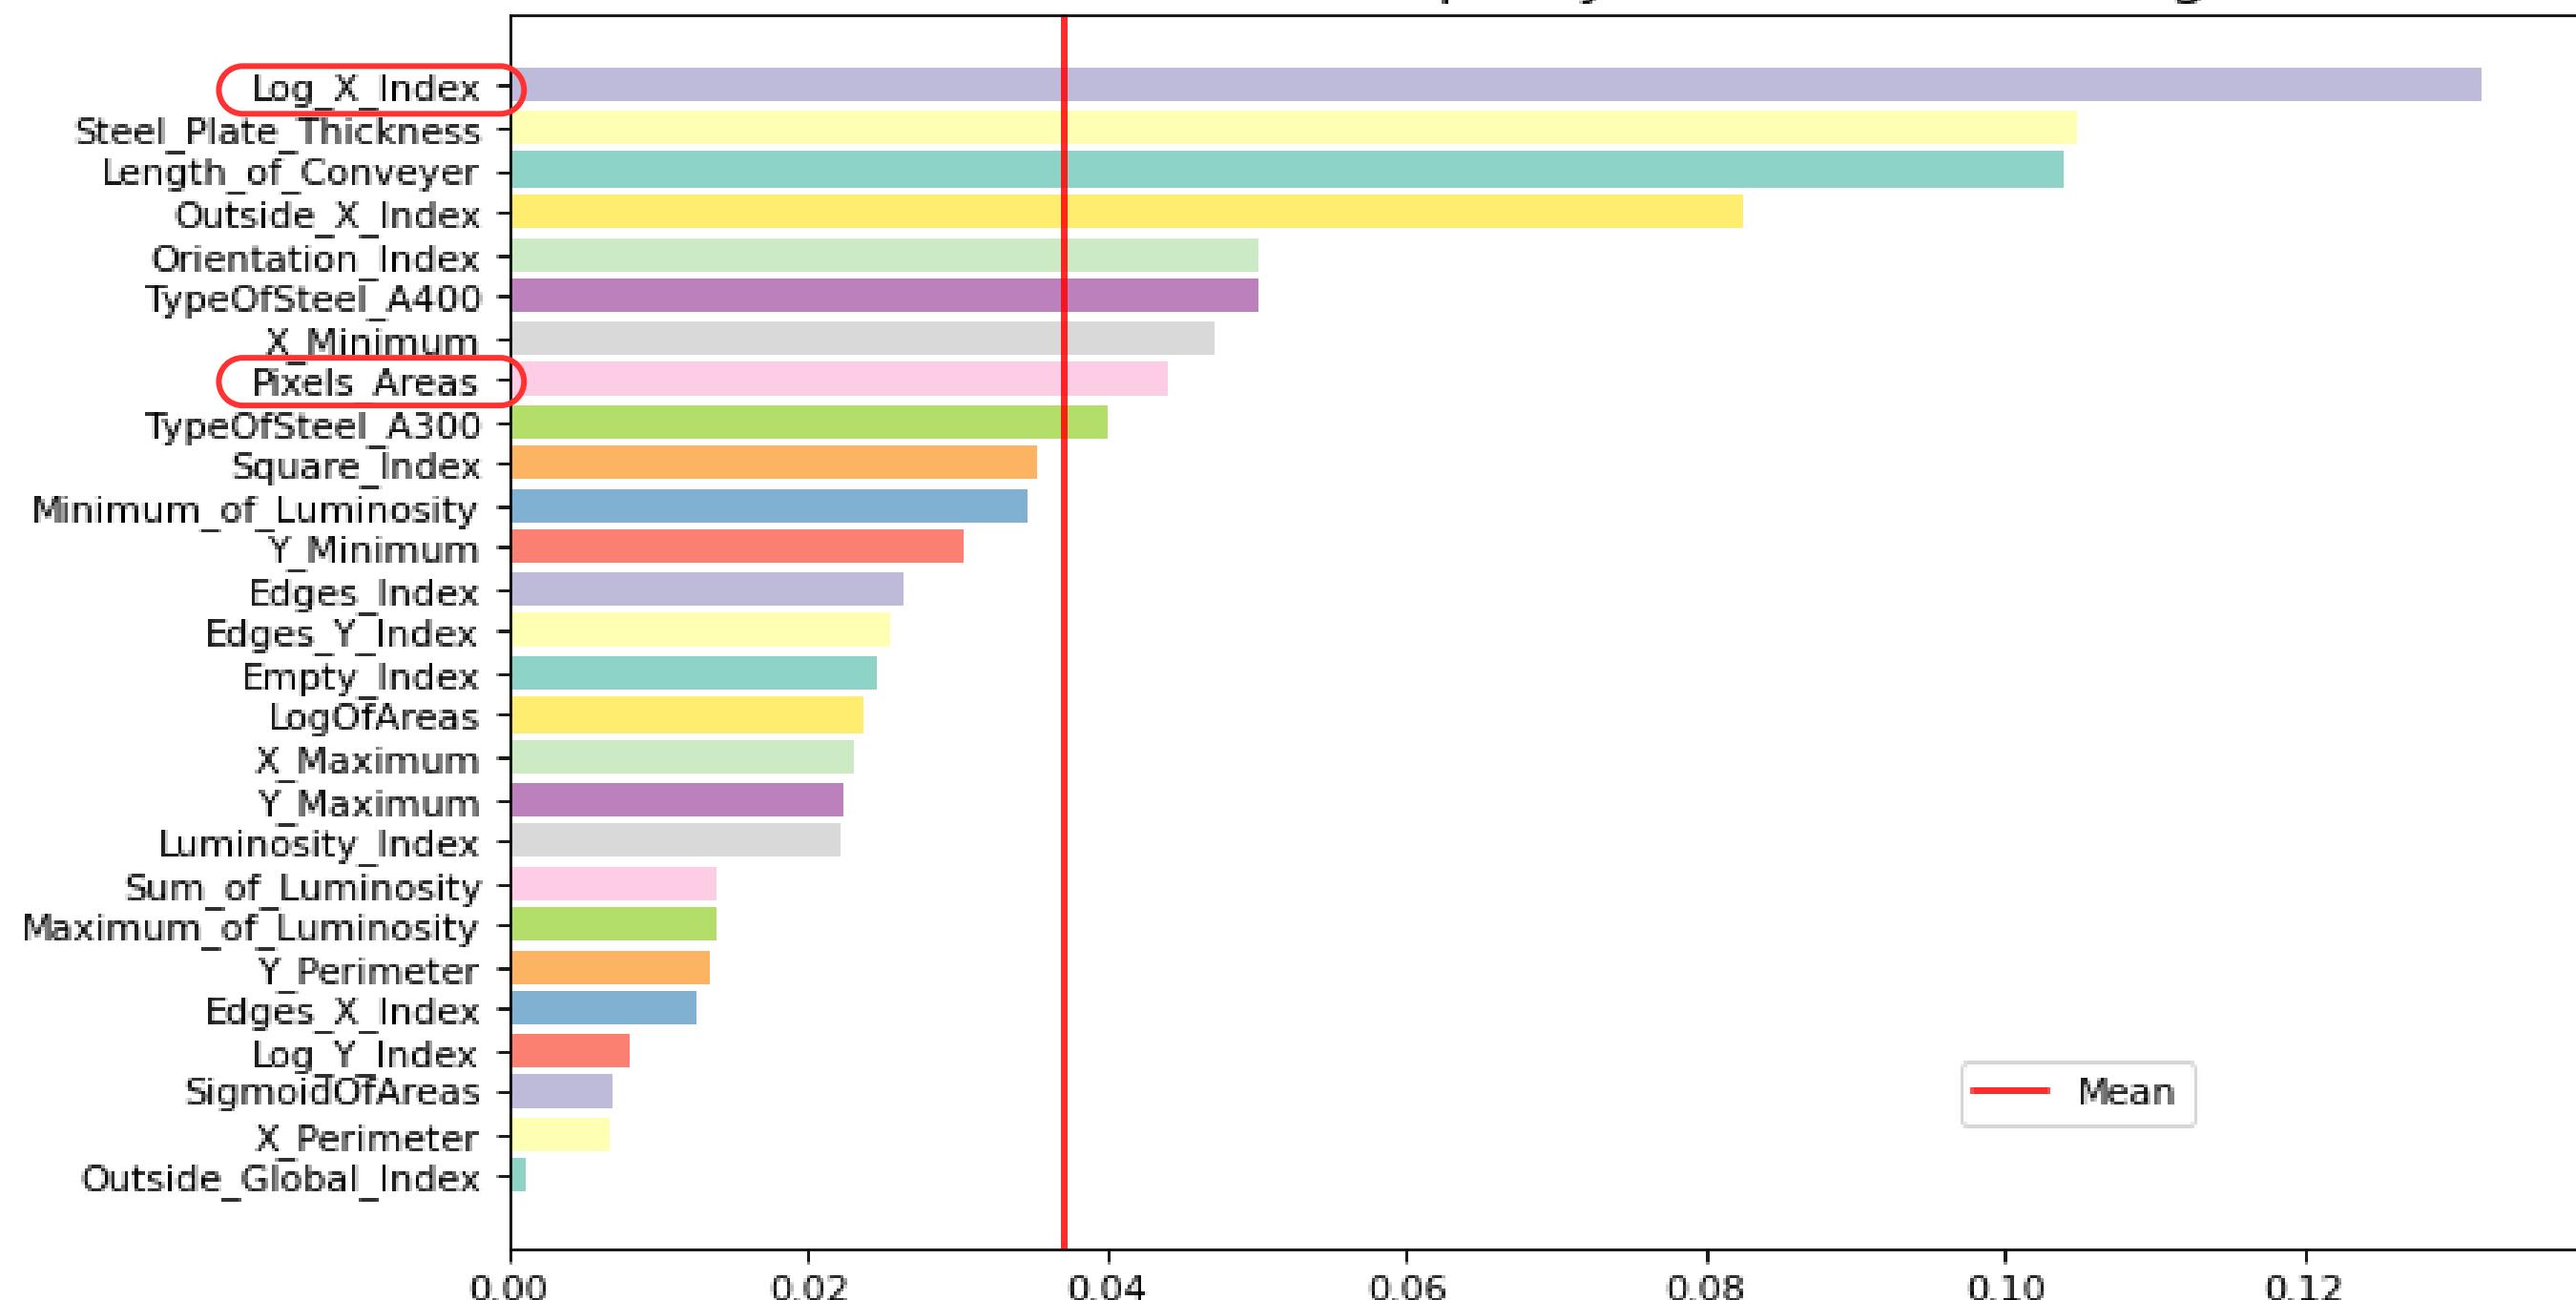
Engineering Data Analysis

- 특성 중요도

- 양상블모델에 영향을 미치는 특성중요도를 계산합니다.

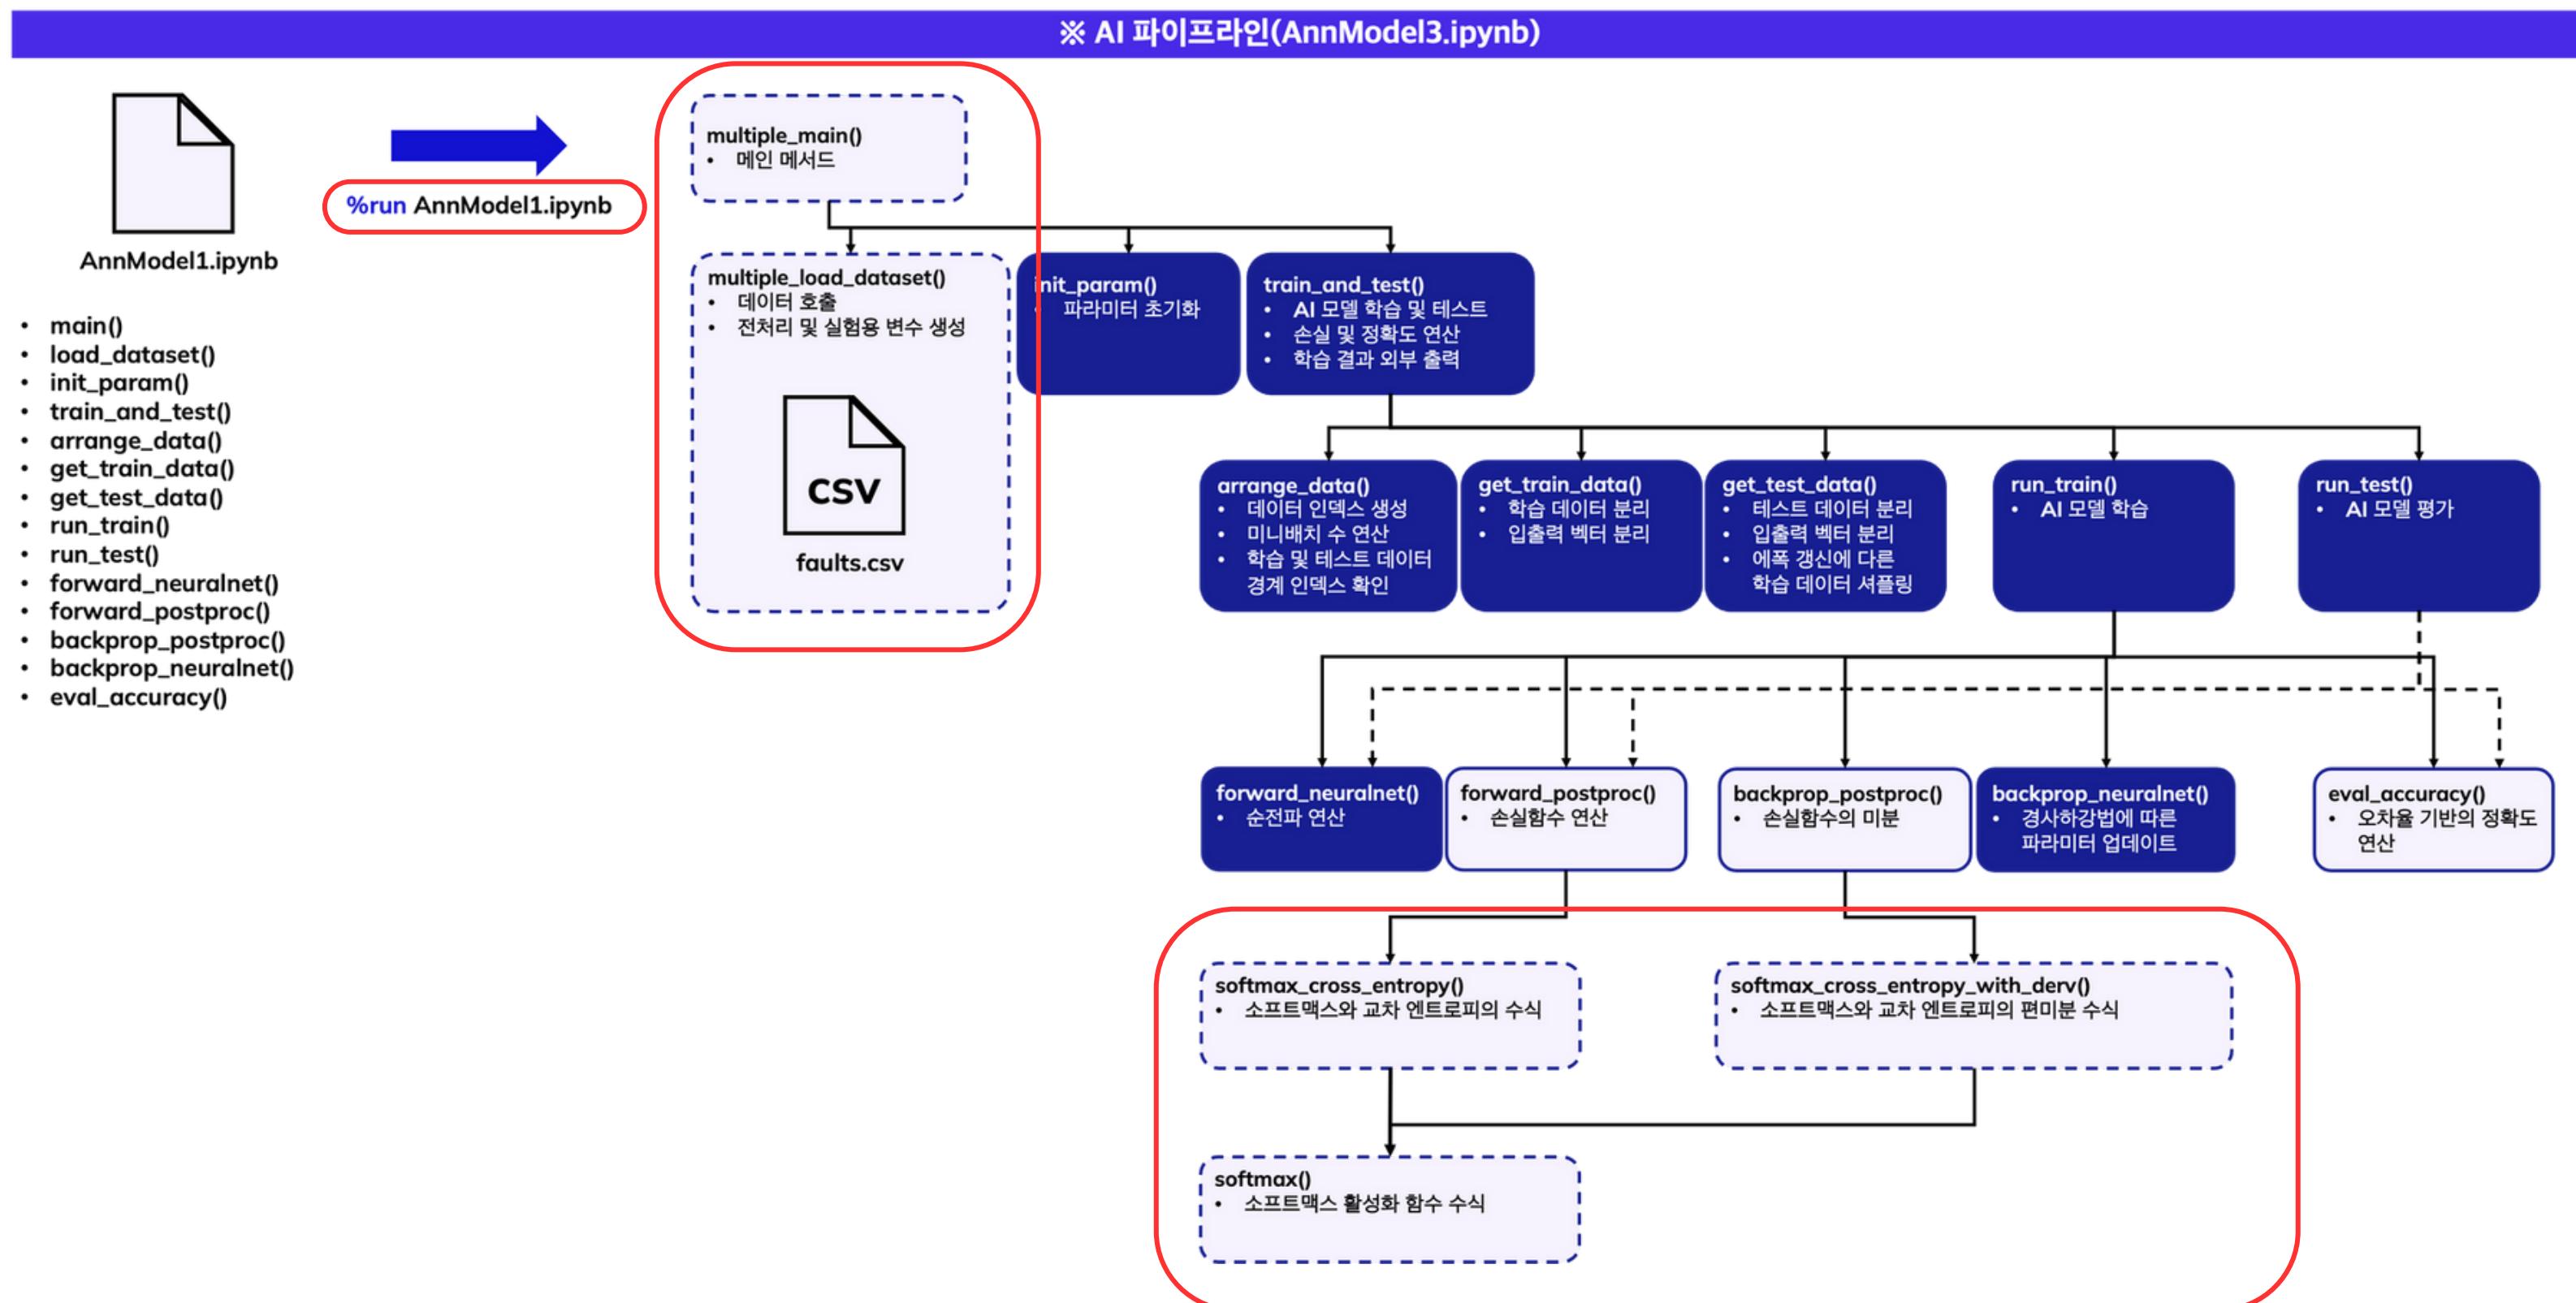
- Mean Decrease Impurity 방식의 특성중요도를 사용합니다.

Mean Decrease Impurity : Gradient Boosting



Faulty Steel

Legacy Model



Faulty Steel

Legacy Model

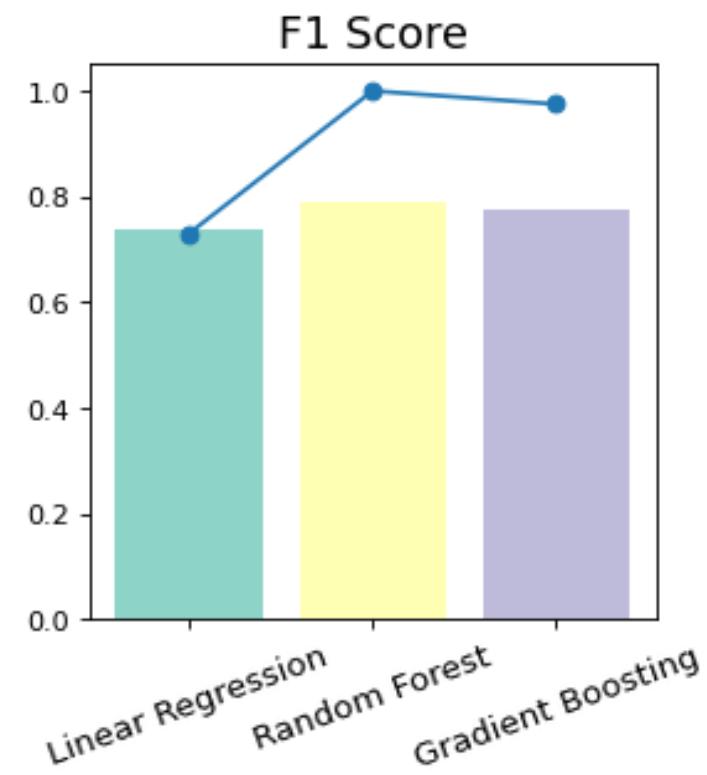
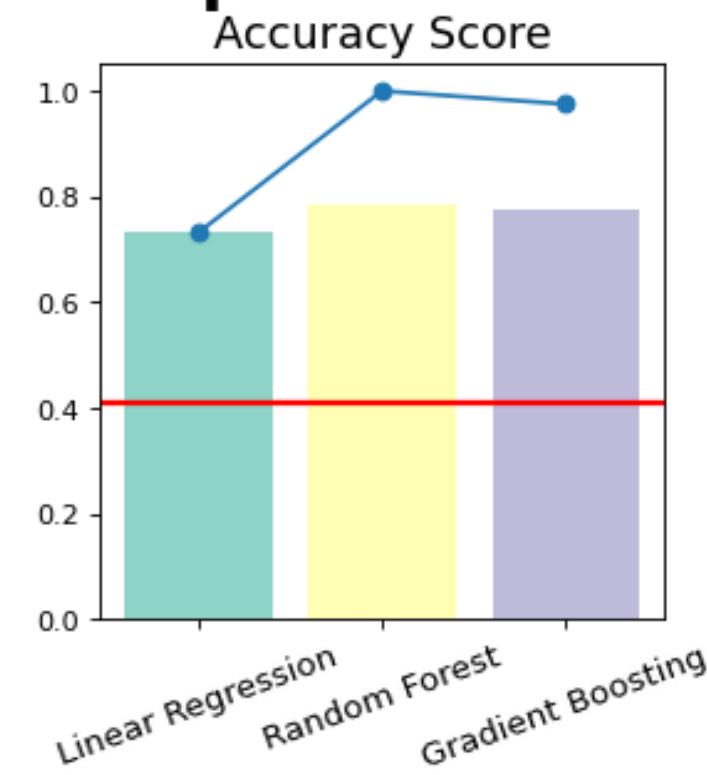
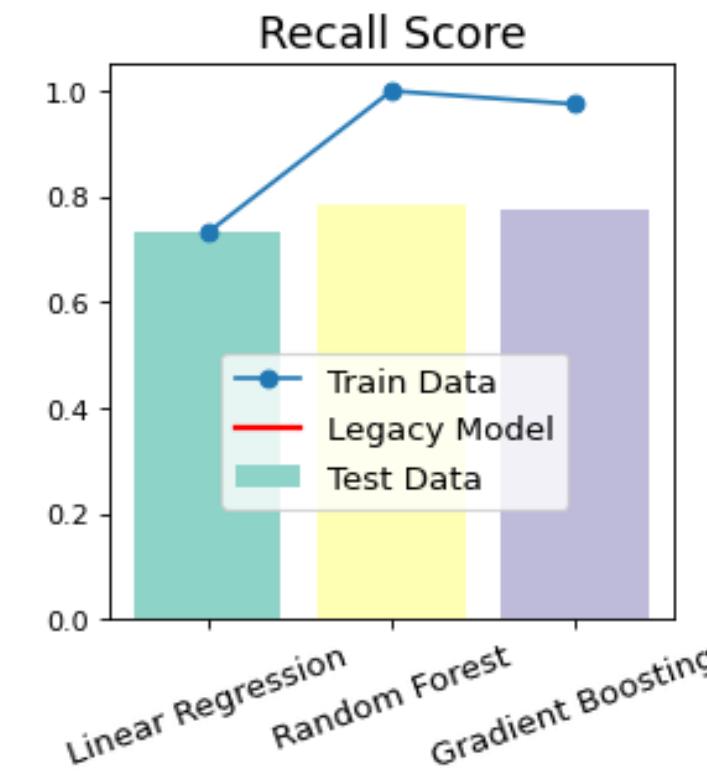
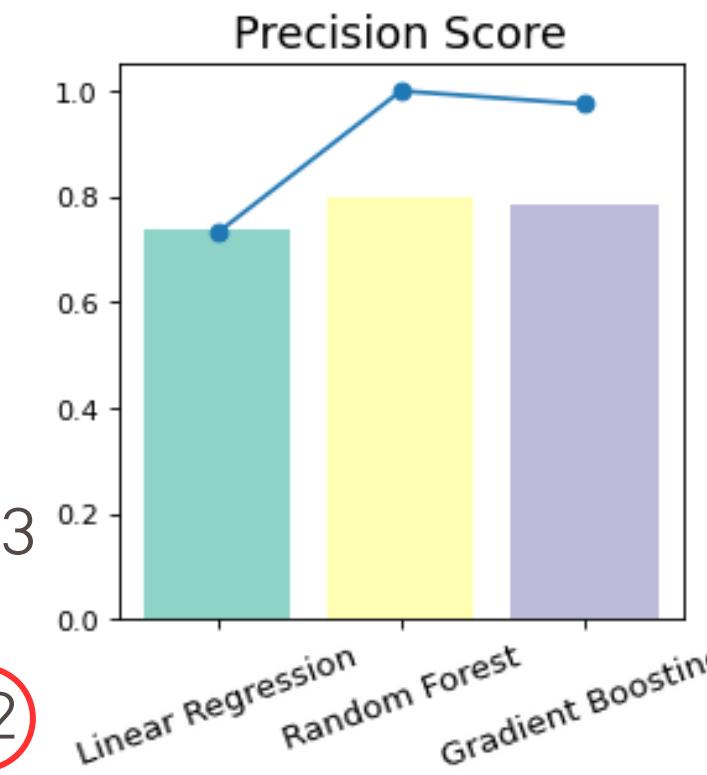
- 기존 모델의 성능

- Epoch : 10 , lr : 0.001

- Train Loss : 16.039

- Train Accuracy : 0.303

- Test Accuracy = 0.412



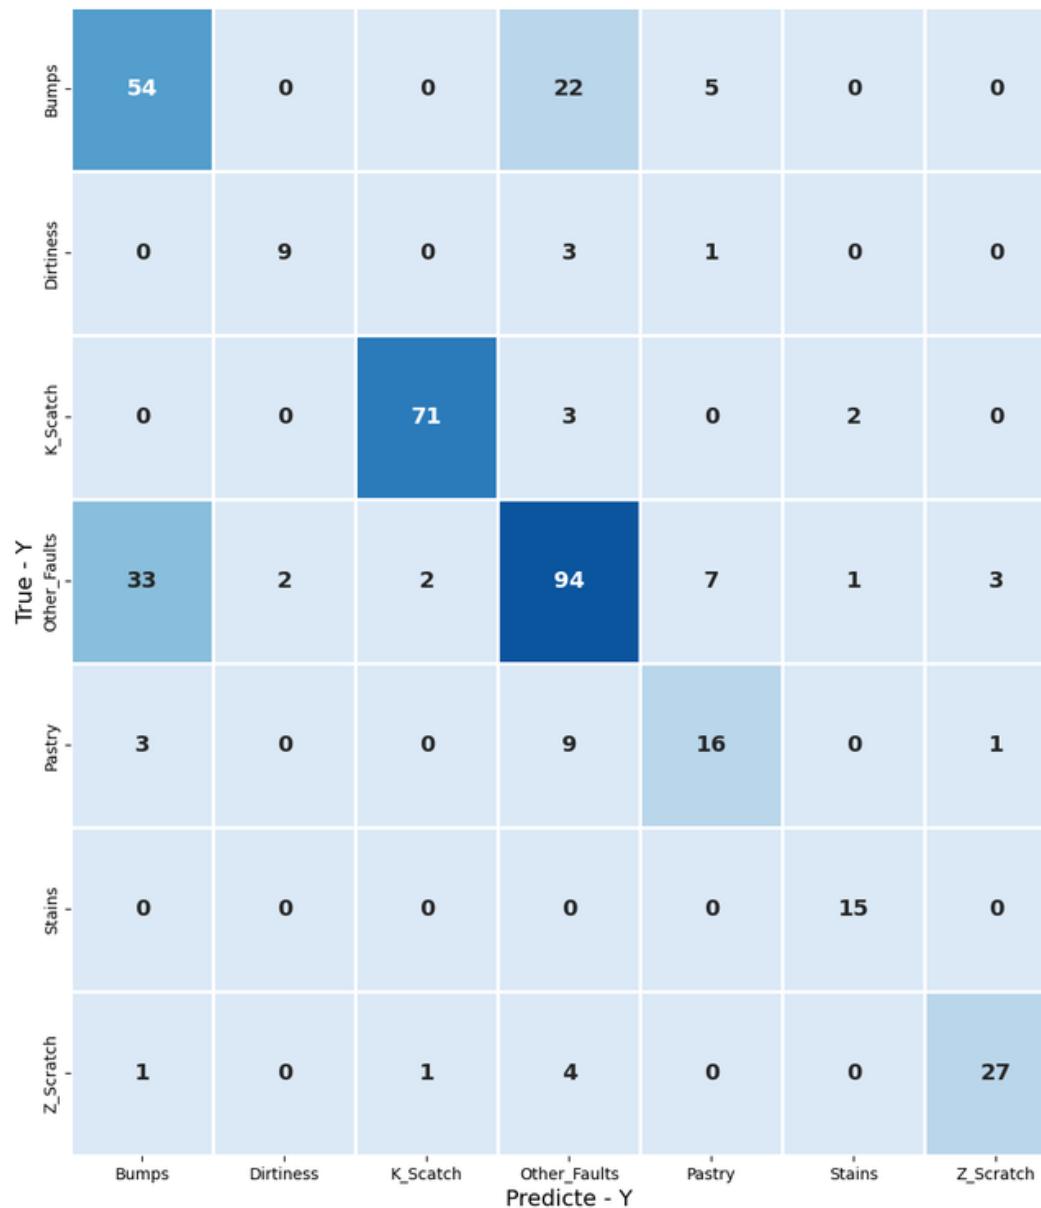
- 기존 모델과 머신러닝 모델과 성능 비교

- 대표적인 머신러닝 모델인 Logistic Regression, Random Forest, Gradient Boosting 사용

Faulty Steel

ML Model

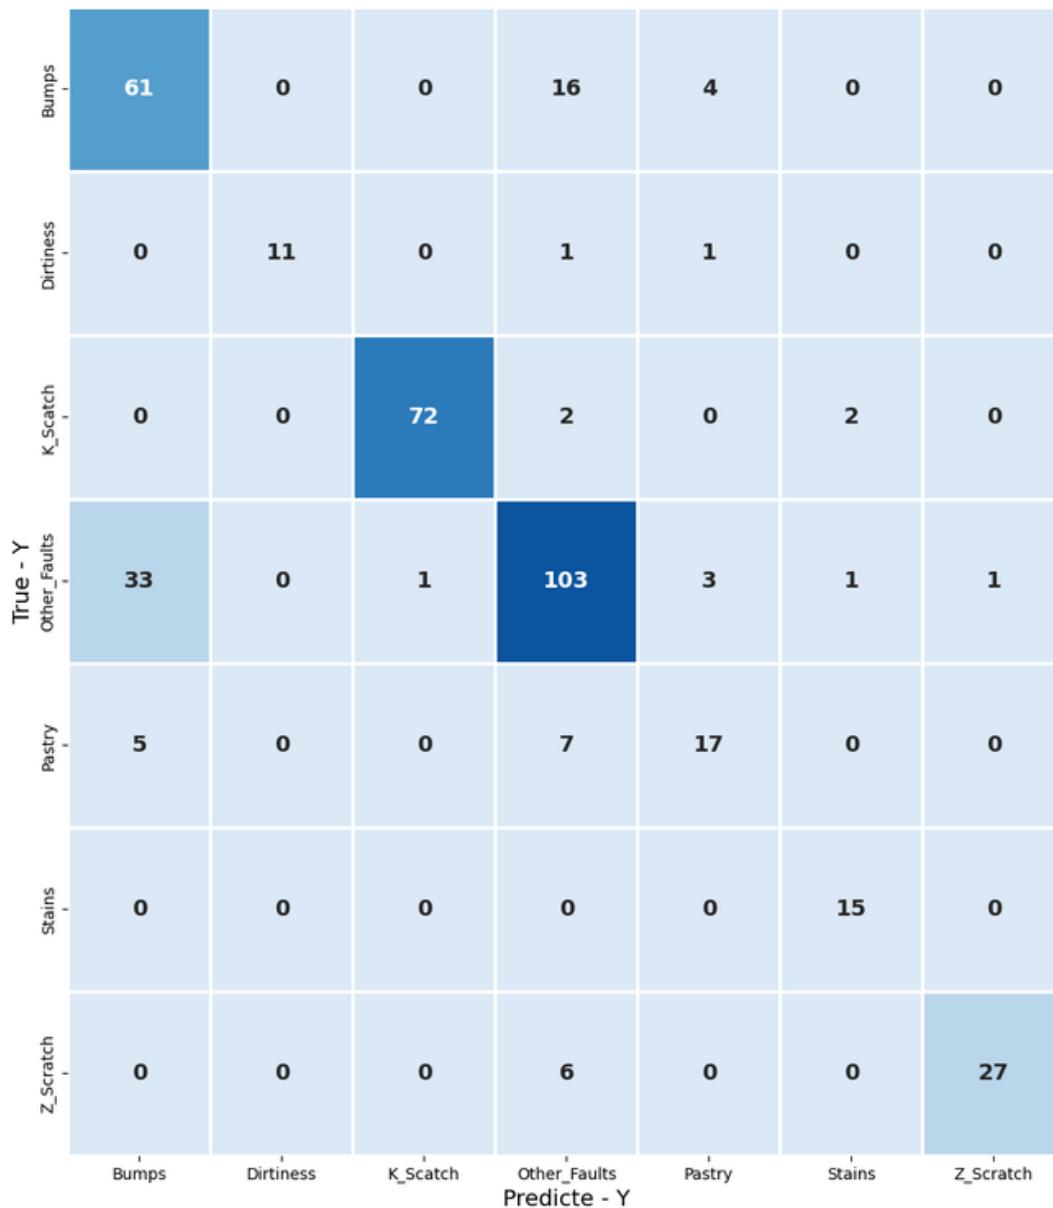
Confusion Matrix



Logistic Regression Model

Accuracy Score : 0.732

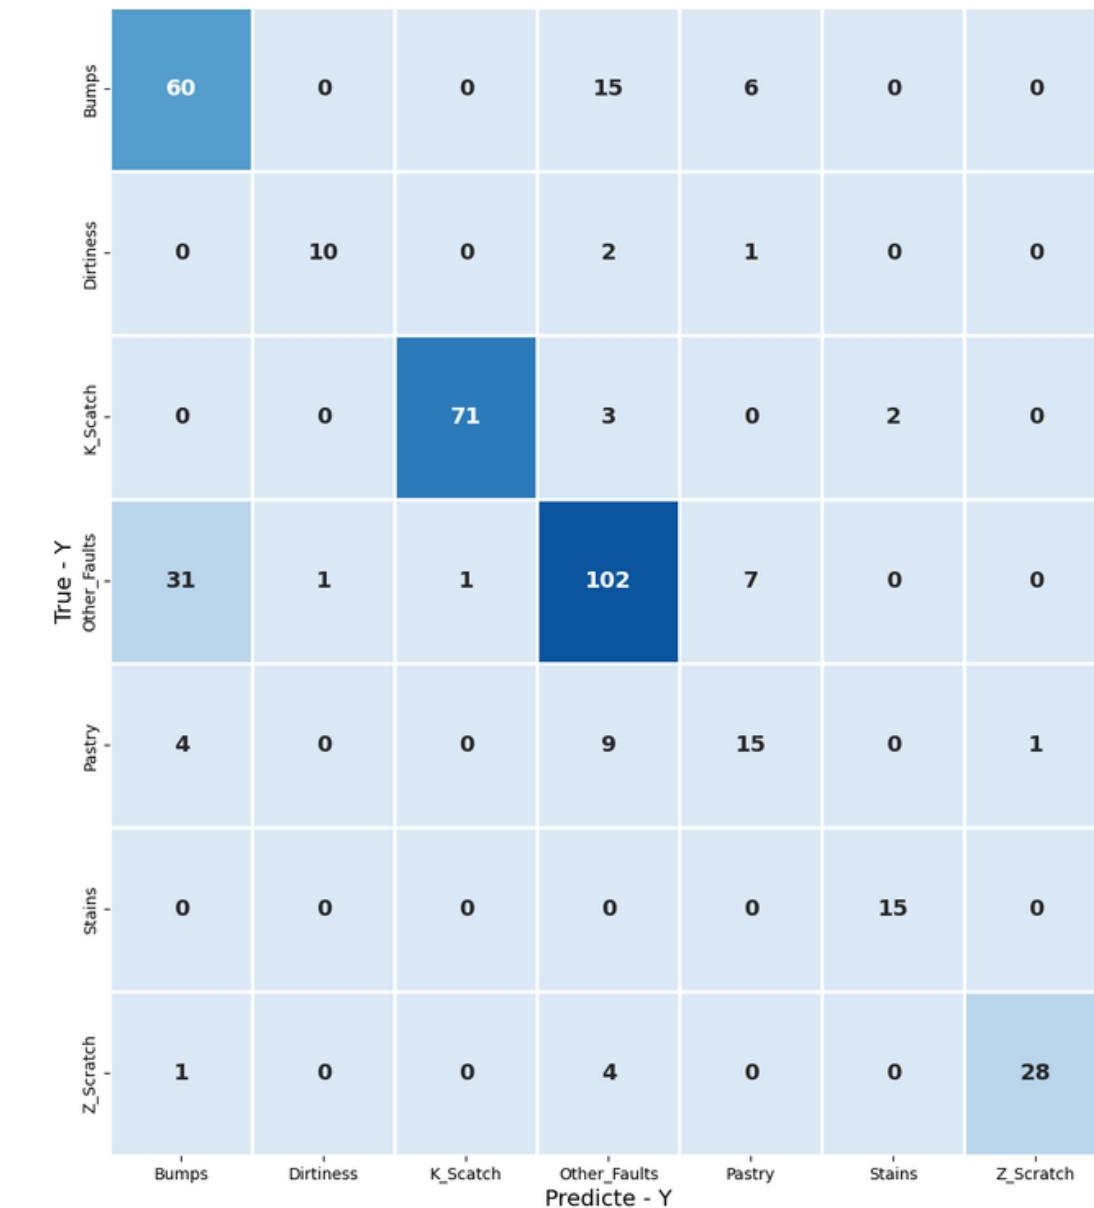
Confusion Matrix



Random Forest Classifier Model

Accuracy Score : 0.787

Confusion Matrix



Gradient Boosting Classifier Model

Accuracy Score : 0.774

Faulty Steel ... Insight!

탐색적 데이터 분석

- 불균형 타겟이므로 오버샘플링 필요
- 다중공선성이 의심되는 특성들이 있음
- 관측치 측정 범위가 너무 넓어서 학습에 방해되는 특성들이 있음
- 이상치 제거

특성공학

- 상관계수 절대값 0.9이상인 특성 중 중요도가 더 높은 것 선택
- 관측치 측정 범위가 넓은 특성 **로그 스케일링**
- 중요도 낮은 특성 제거

옵티마이저 선택

- 단순모델로 실험한 결과 Adam, Nadam, Adamax 가 좋은 성능
- 가장 범용으로 사용되는 **Adam을 옵티마이저로 선택**
- 하이퍼파라미터 미세조정

Faulty Steel

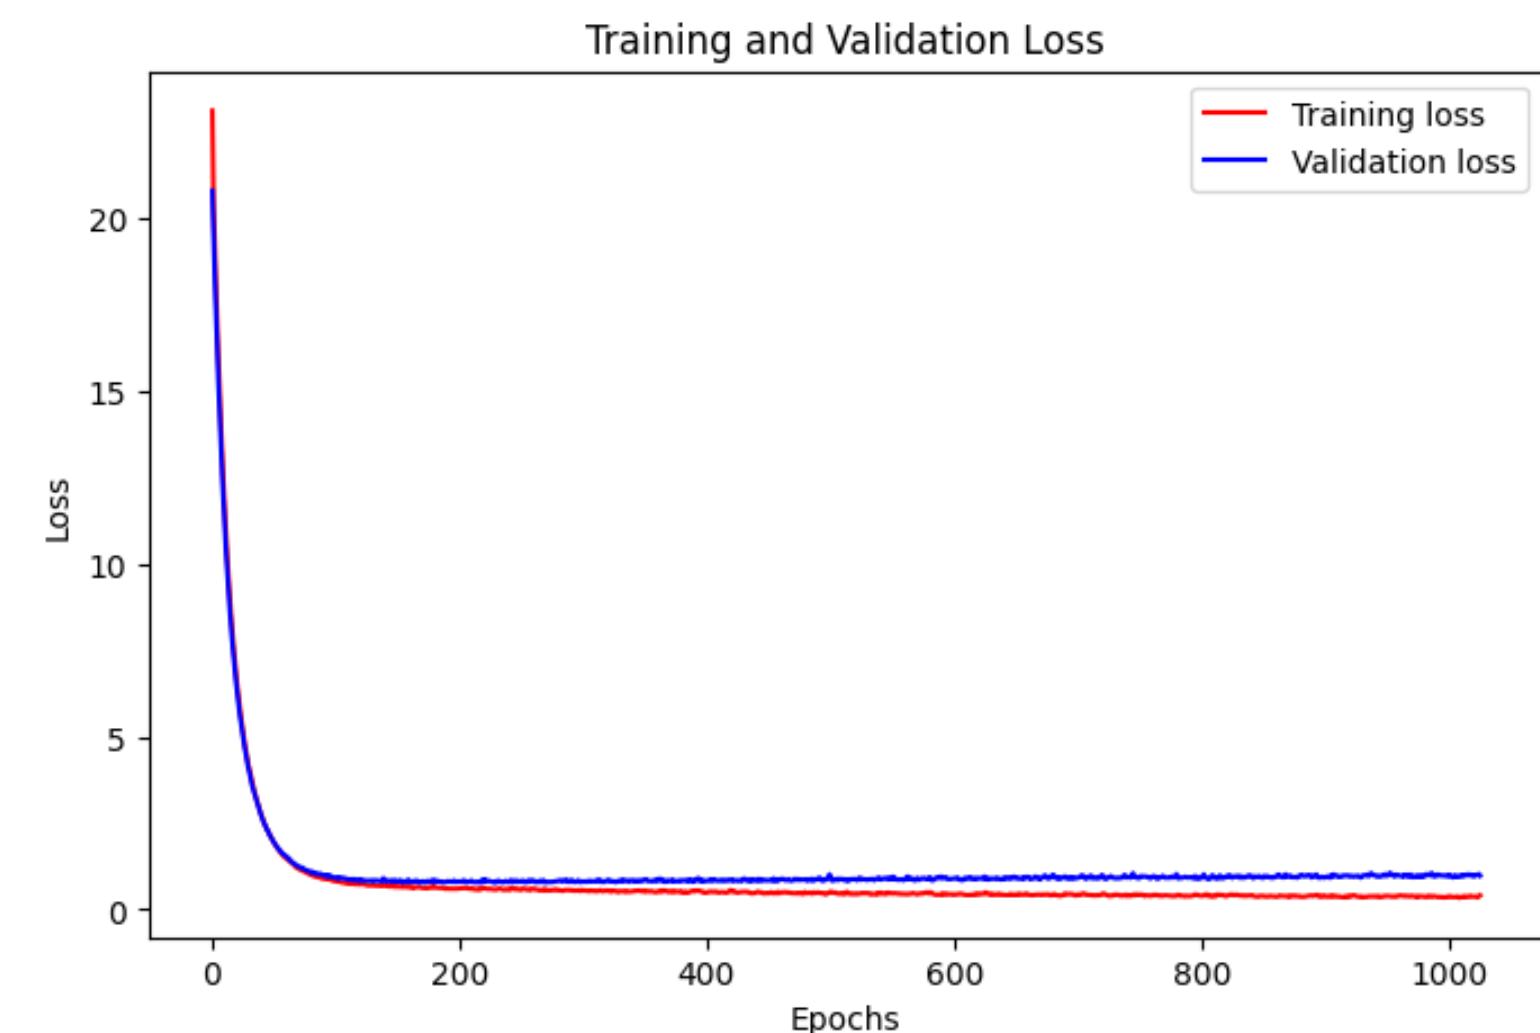
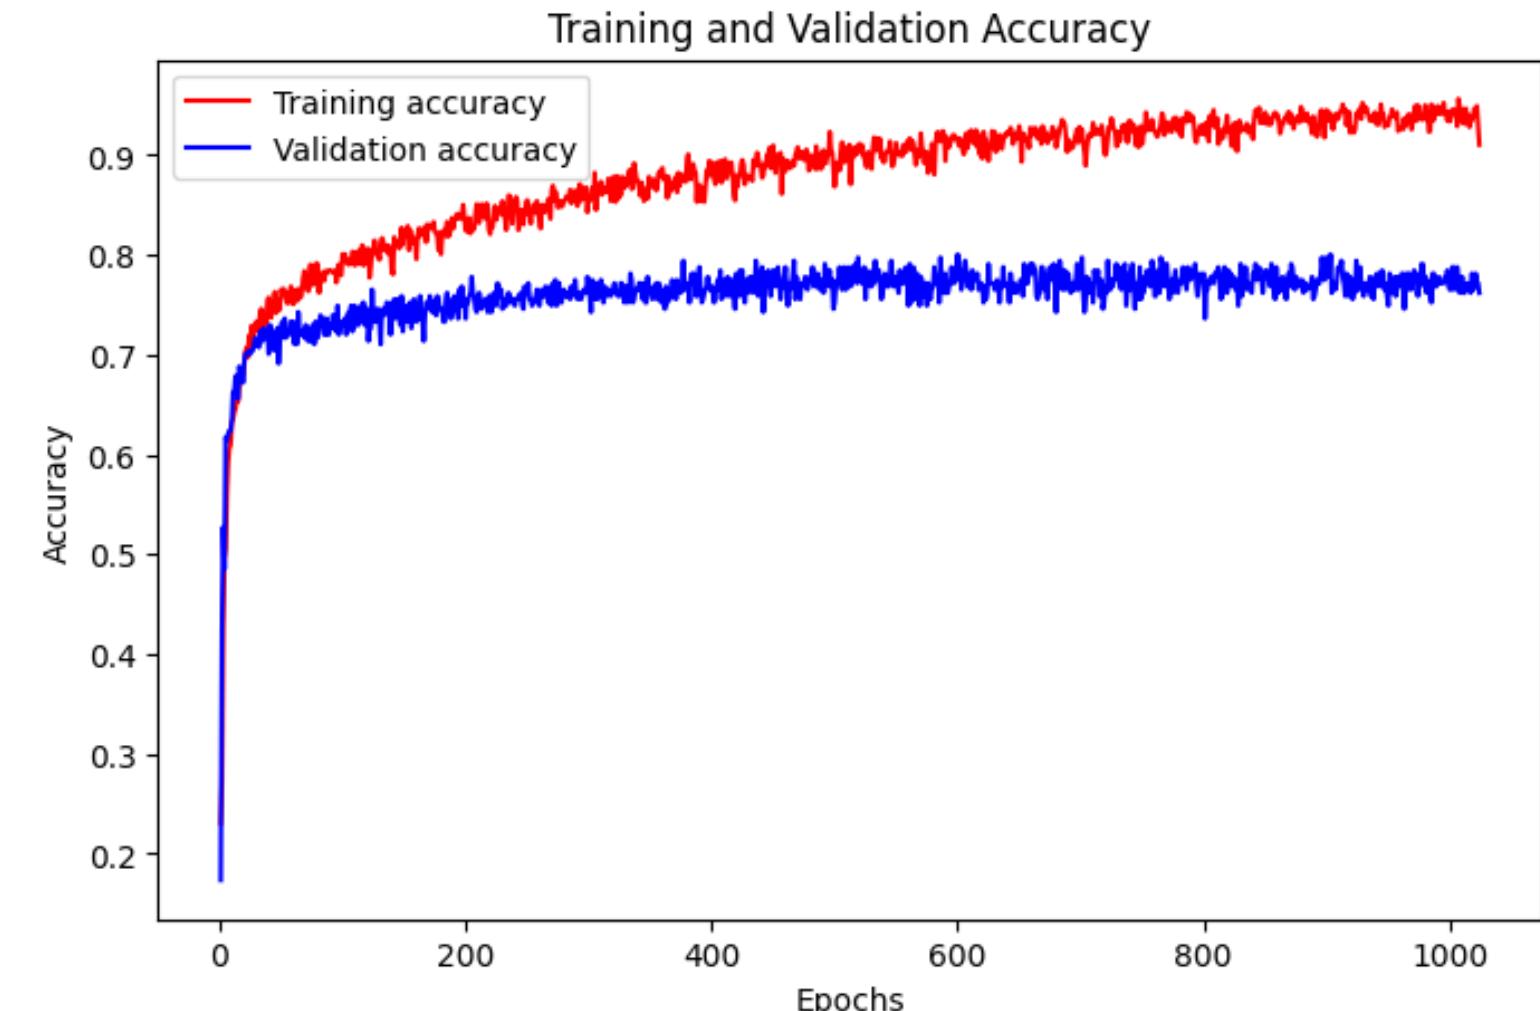
DL Model

모델구성

- 7개 종속변수(타겟)을 **하나의 타겟으로 통합**
- EDA 및 특성공학 적용
- 가중치 초기화 방법 : Glorot Initialization(기본값)
- 가설 1 : 특성이 많으므로 **신경망의 복잡성**이 증가해야 함
 - 은닉층 8 ~ 16개
 - 노드개수 = 64 ~ 1024

→ 정확도가 올랐지만 **과적합 발생**
- 가설 2 : **배치정규화**로 일반화 성능 향상 가능
 - 은닉층마다 배치정규화 적용

→ 훈련과 검증 정확도 차이는 줄었지만 **전체 성능 하락**



Faulty Steel

DL Model

모델구성

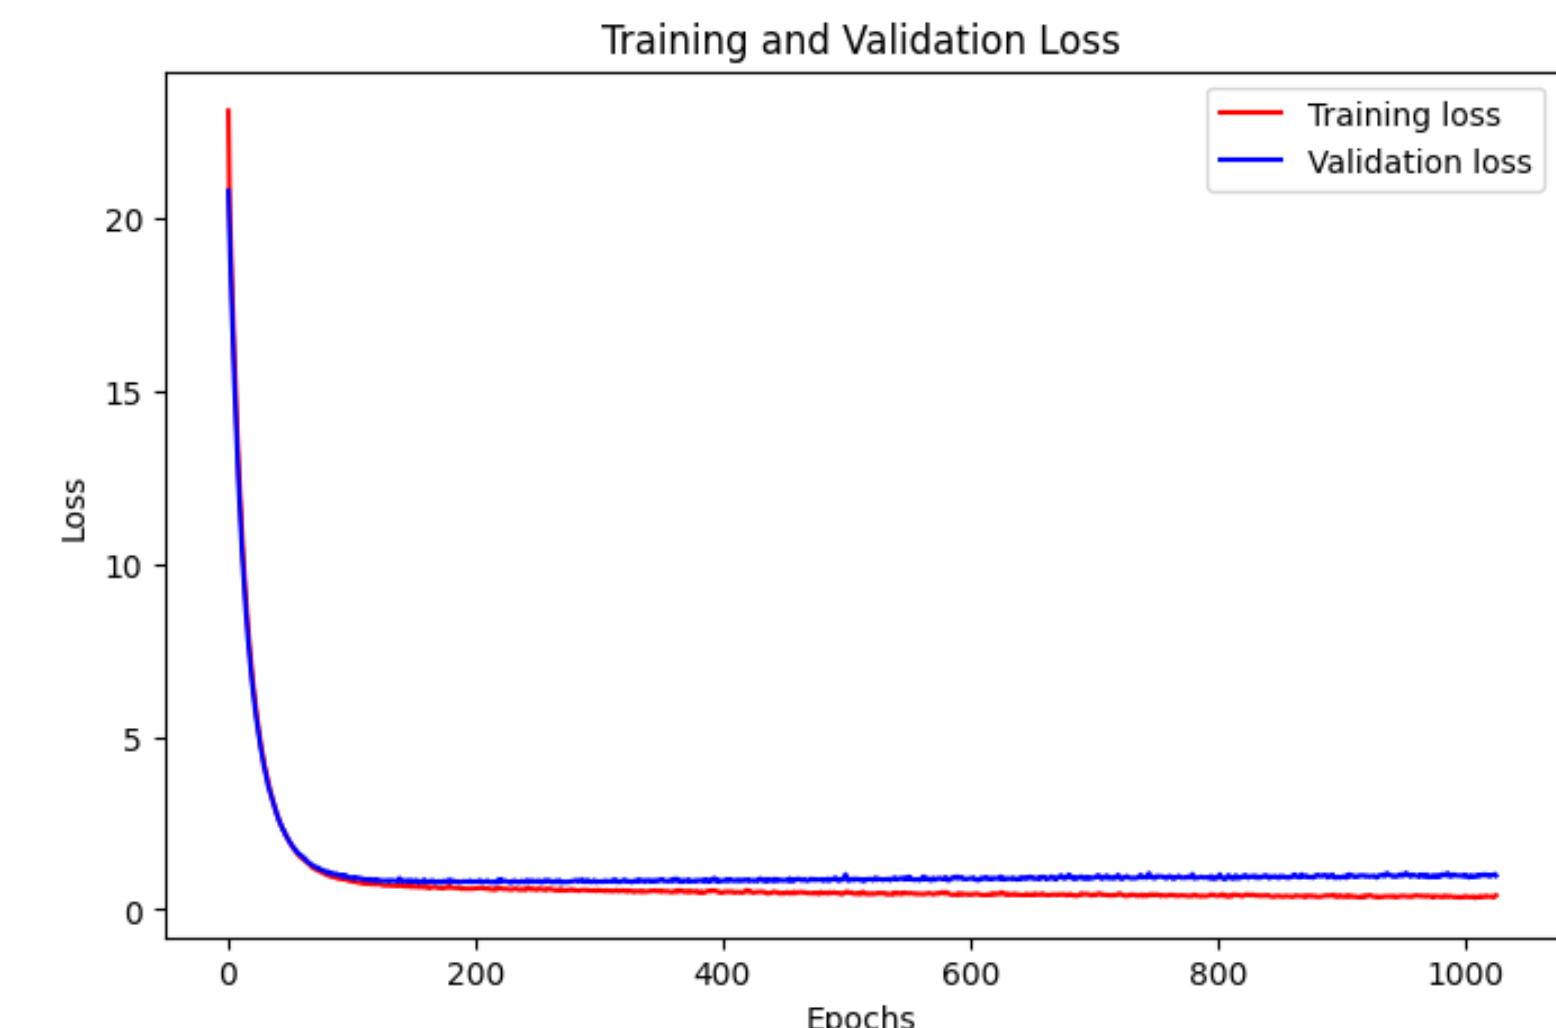
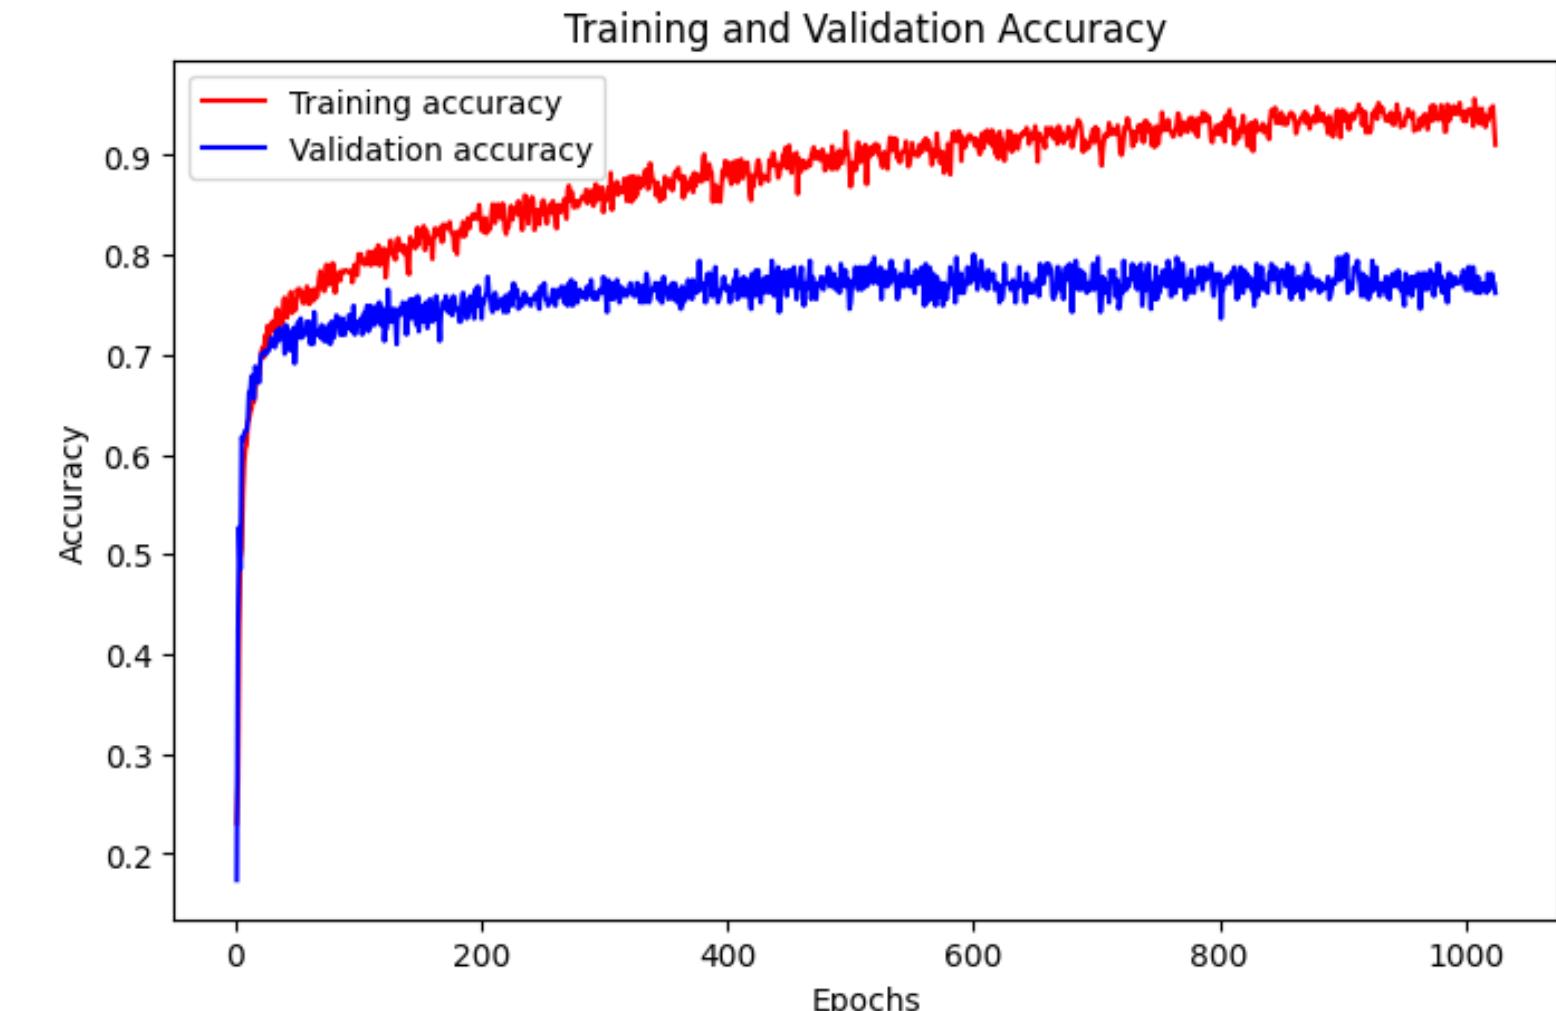
- 가설 3 : **드롭아웃**으로 일반화 성능 향상 가능
 - 은닉층마다 드롭아웃 적용

→ **일반화 성능 향상**
- 가설 4 : **모델의 깊이가 깊을수록 손실되는 정보가 많아짐**
 - **스킵 연결 기법**으로 앞쪽 은닉층 정보를 뒤쪽에도 전달

→ **전체 성능 향상**
- 가설 5 : **L2정규화를 은닉층마다 점진적으로 증가시키면 더 효과적으로 일반화 성능 향상 가능**

→ **일반화 성능 향상**
- 가설 6 : 학습하며 지나가는 가중치 중에 최적의 값이 있음
 - 전체 에포크 중에 **검증 정확도가 높은 10개의 가중치를 저장** 해서 시험 정확도 평가

→ **검증 정확도가 높으면 실제로 일반화 성능이 좋음**



Faulty Steel

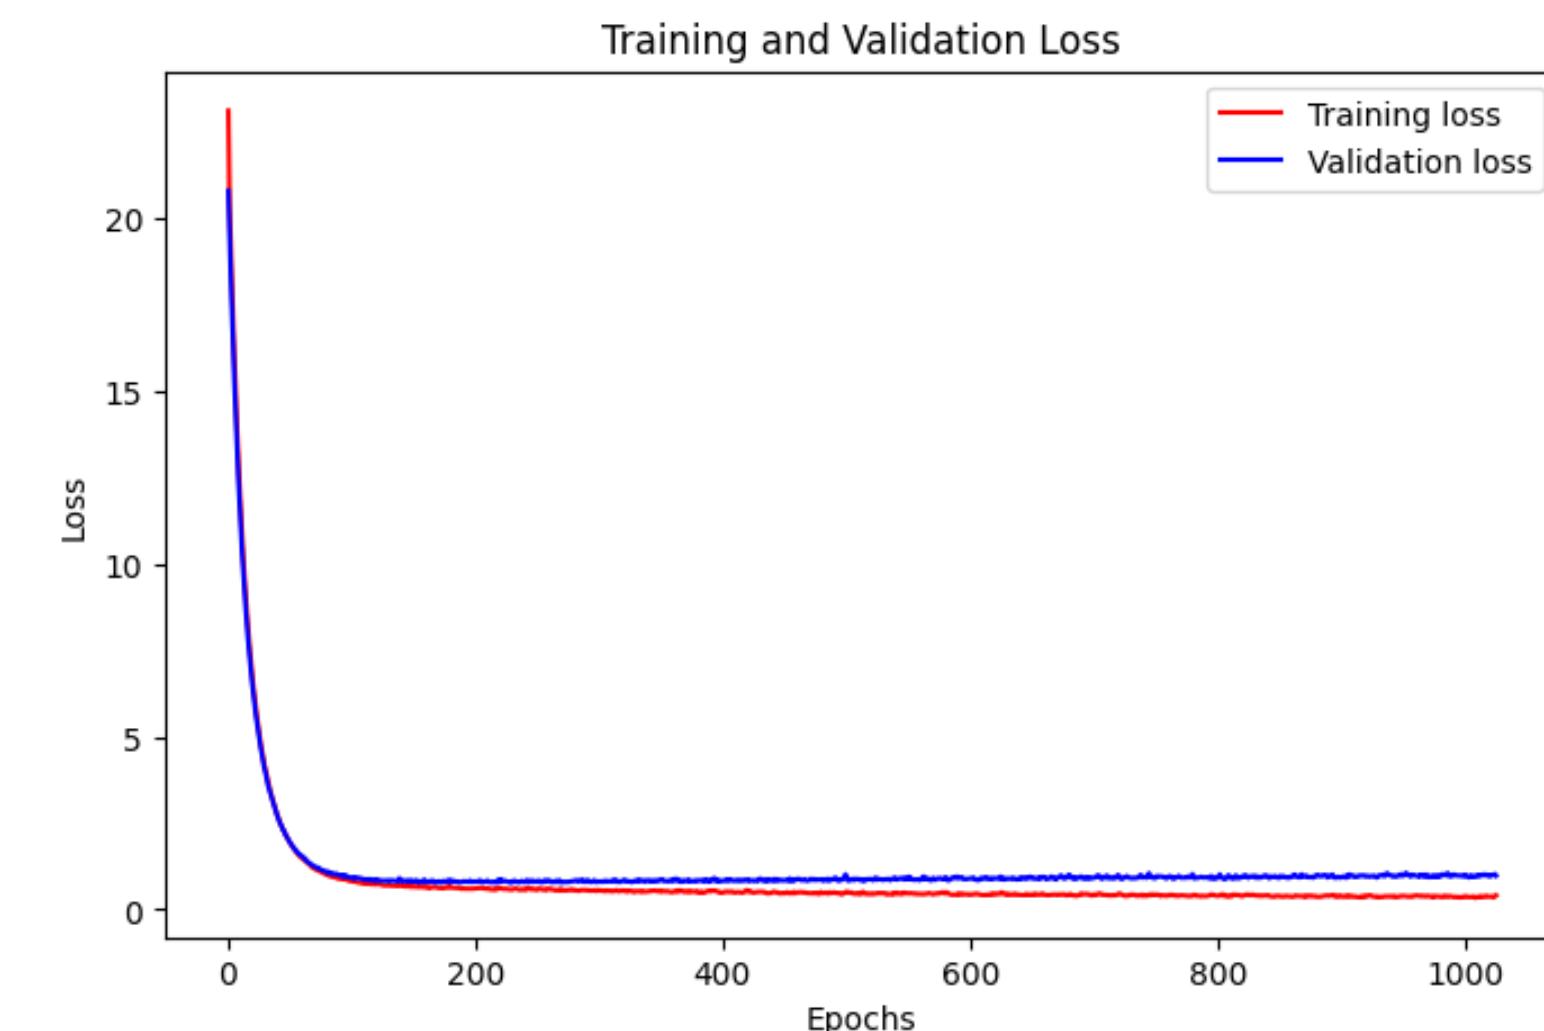
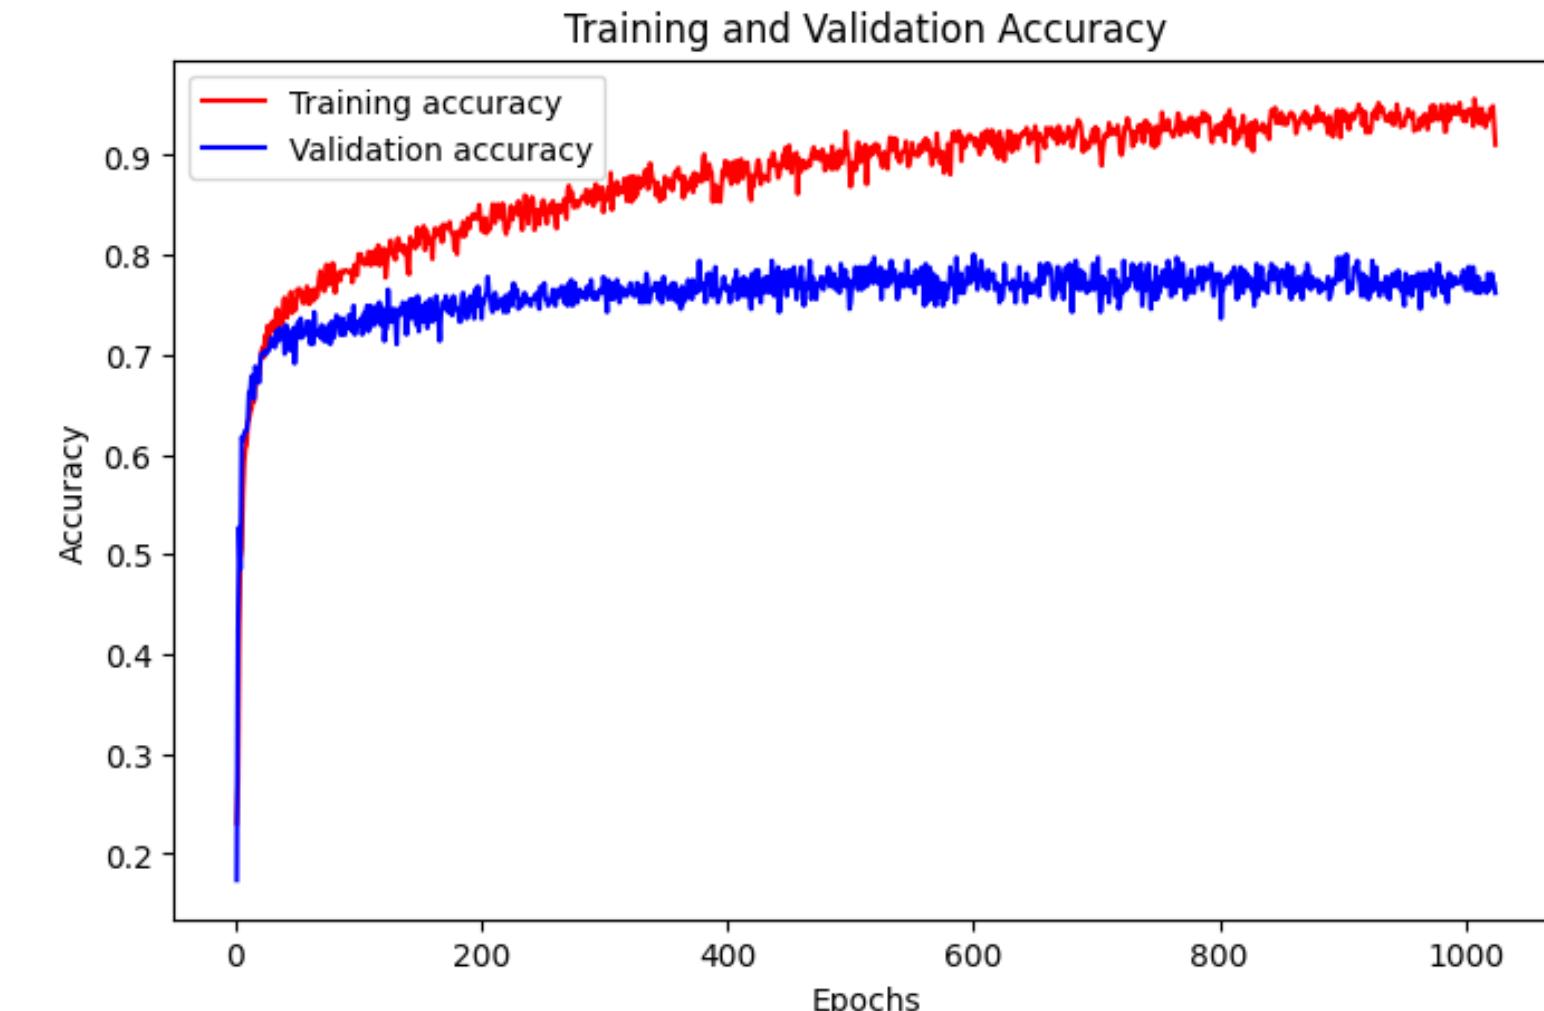
DL Model

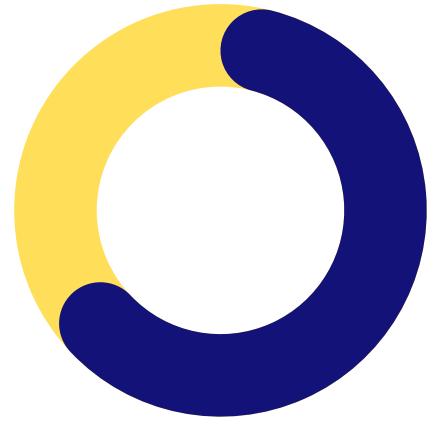
모델구성

- 최종 모델 구성
 - 스kip 연결 적용
 - 은닉층 : 8
 - 노드 : 256
 - L2 = 0.001 ~ 0.0185
 - 드롭아웃 : 0.2
 - 학습률 : 0.001
 - 에포크 : 1024
 - 미니배치크기 : 256

• 시험 세트 평가

- Validation Accuracy: 0.807
- Test Loss: 0.964
- **Test Accuracy: 0.807**
- **0.412 → 0.807 (95.87% 성능 증가)**





EDA를 통한 데이터 최적화

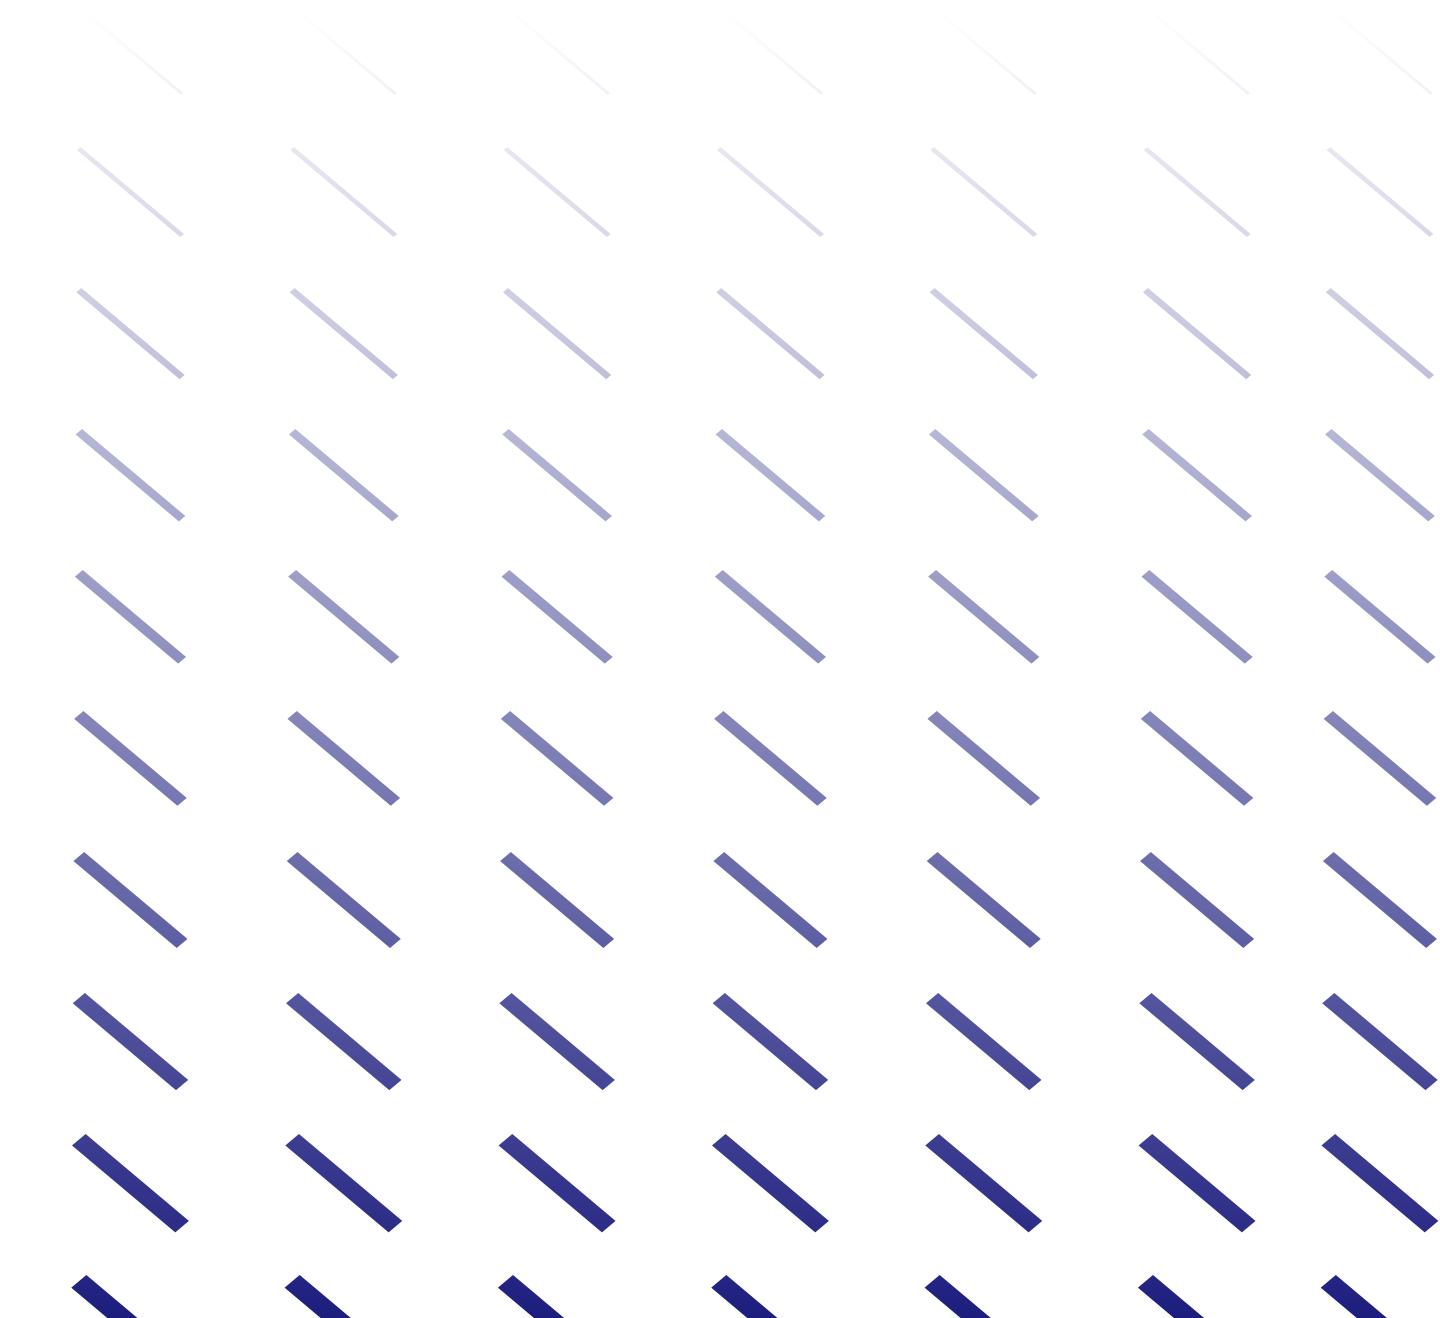
프로젝트 정리

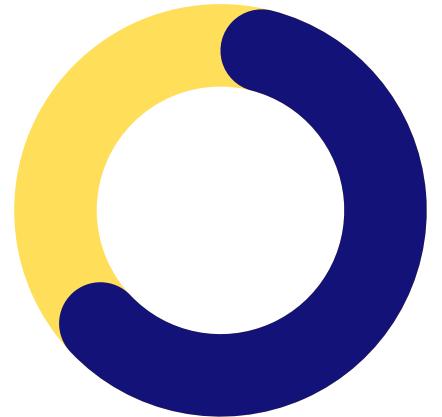
데이터마다
이상치 제거, 새로운 특성, 다중공선성 해소 등
각 데이터에 맞는 EDA를 진행하였음.

타겟 특성의 분포를 확인하고
모델을 구성하는데 참고하였음.

특성간 상관관계를 확인하고
상관관계가 높은 특성만 가지고 모델링 하는 등
다양한 시도를 진행하였음.

모델을 시각화 하여
지표를 확인하고 모델을 개선하는데 참고하였음.





딥러닝 모델 성능 향상

프로젝트 정리

[Abalone]

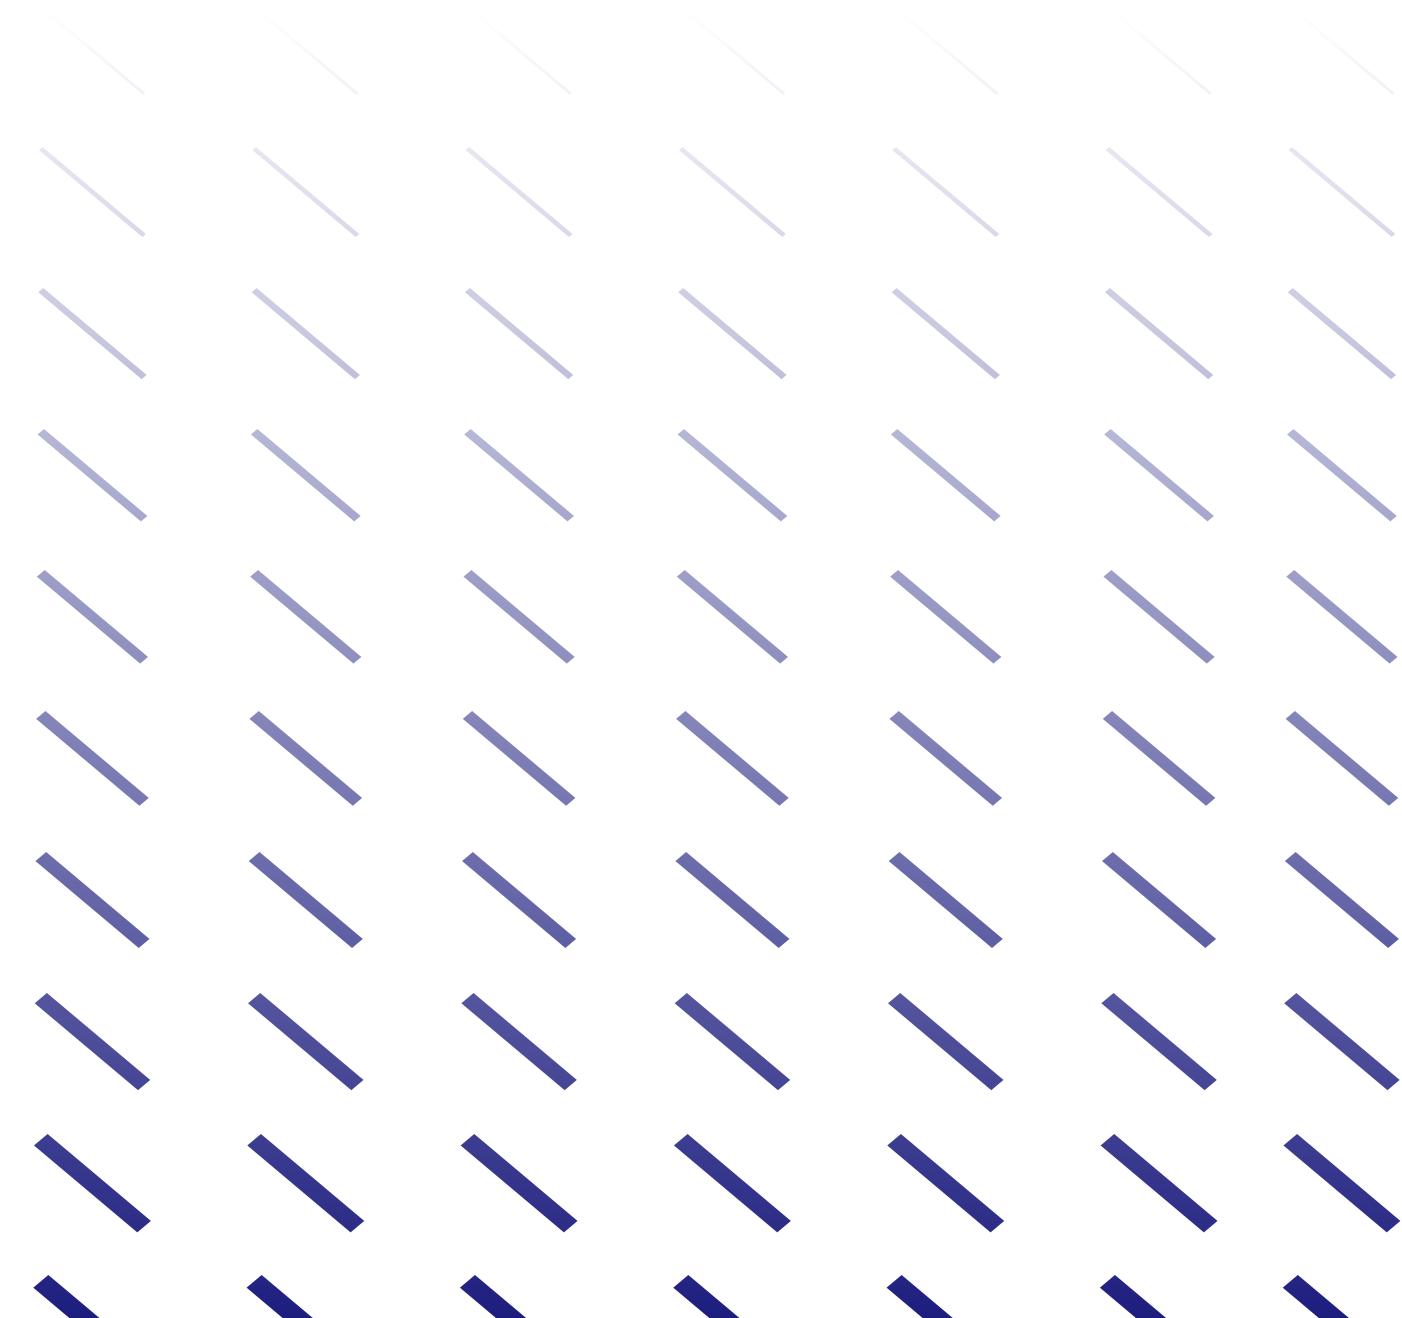
[Baseline Test Dataset] Accuracy = 0.827
[DL Model Test Dataset] Accuracy : 0.929

[Pulsar Star]

[Baseline Test Dataset]
Acc = 0.976, Precision = 0.926,
Recall = 0.789, F1 = 0.852
[DL Model Test Dataset] Acc: 0.980,
Precision:0.897, Recall: 0.871, F1 Score: 0.884

[Faulty Steel]

[Baseline Test Dataset] Accuracy = 0.412
[DL Model Test Dataset] Accuracy: 0.807





Django를 통한 UIUX 개선

강철판 결함 예측

강철판의 특징을 입력하면 어떠한 결함이 있는지 예측 해요.

프로젝트 정리

전복 연령 예측 모델

전복의 정보를 입력하세요

전복연령 예측하기

👉 예측된 전복 나이 : 9

암컷	수컷	새끼
길이(mm)	104	
폭(mm)	81	
두께(mm)	28	
전체무게(g)	165	
살무게(g)	72	
내장무게(g)	37	
껍질무게(g)	..	

맥동성(Pulsar Star) 여부 예측

별의 특징 정보를 입력하세요

맥동성이 아니에요 🔎

Integrated Profile

Mean	111
Standard deviation	46
Excess kurtosis	0.5
Skewness	48

DM-SNR Curve

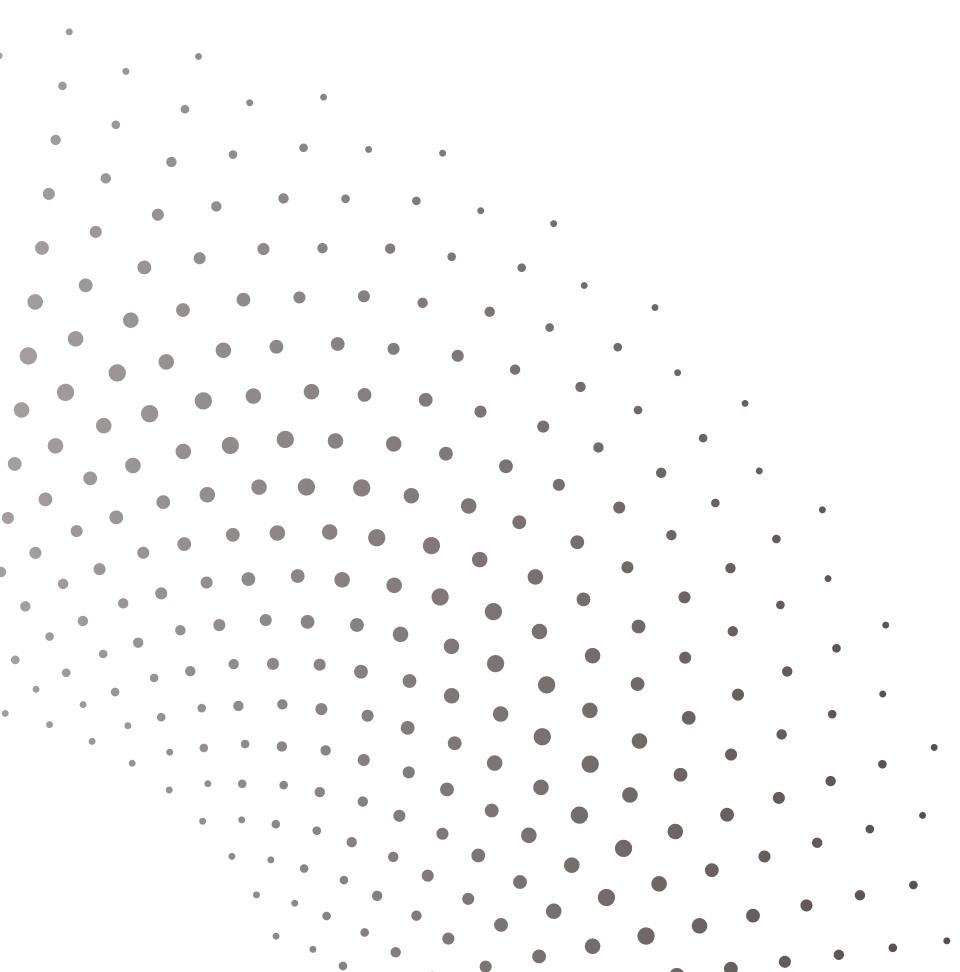
Mean	12
Standard deviation	26
Excess kurtosis	8
Skewness	104

어떤 결함이 있을까요?

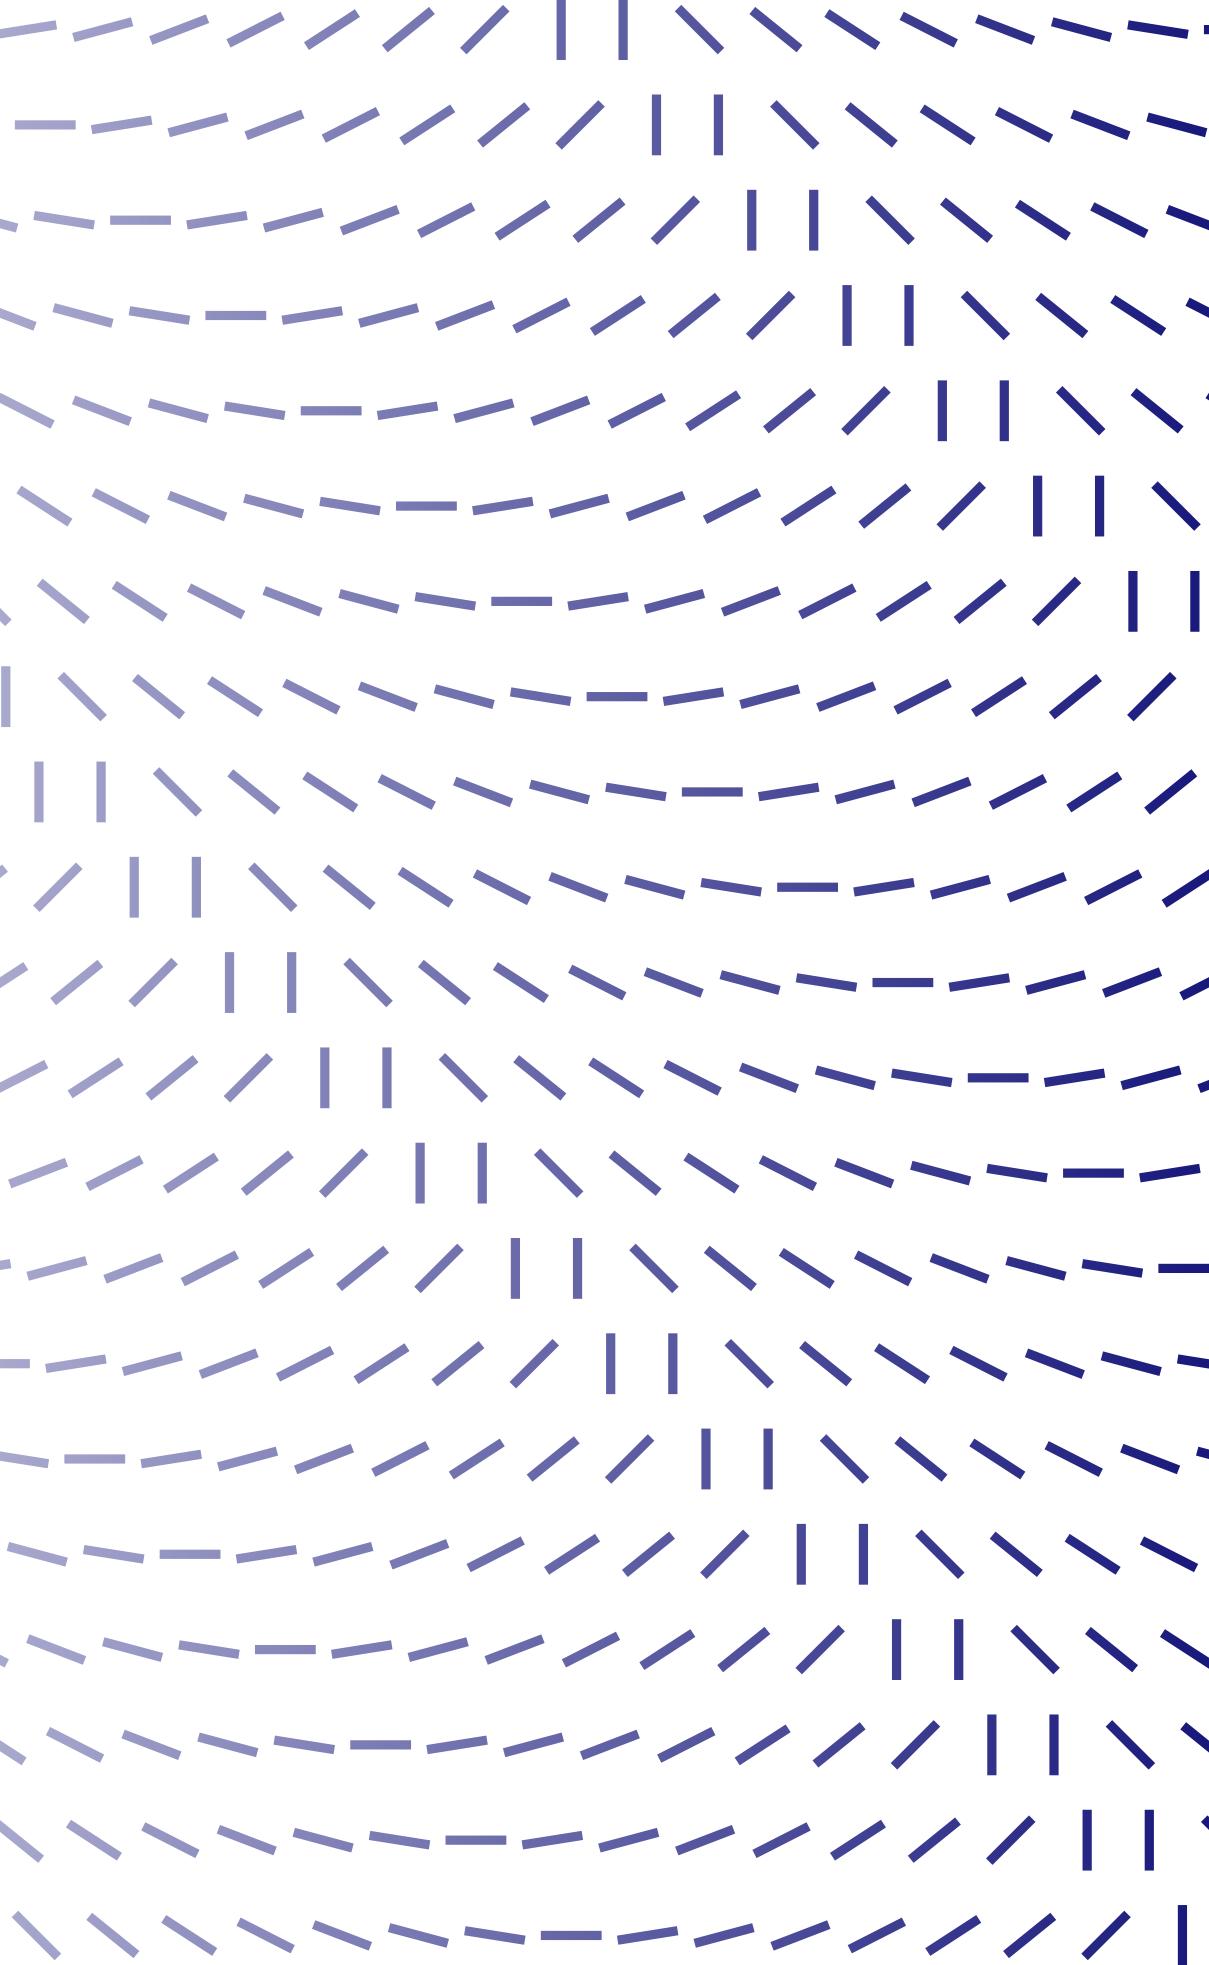
🔍 강판에는
75.47% 확률로 'Other_Faults' 결합
23.67% 확률로 'Bumps' 결합
이 있습니다. 😊

X_Minimum	0.5
X_Maximum	0.5
Y_Minimum	0.5
Y_Maximum	0.5
Minimum_of_Luminosity	0.5
Maximum_of_Luminosity	0.5
Length_of_Conveyer	0.5
Steel_Plate_Thickness	0.5
Edges_Index	0.5

- 추가 데이터를 확보하고 진행하면 더 유의미한 결과를 도출 할 수 있을거 같음.
- 딥러닝 전문회사에서 일하고싶다
- 딥러닝 모델에 앙상블 기법을 적용해보며 성능을 높여본다.
- 막연했던 딥러닝과 머신러닝의 개념이 이해가 되기 시작했다.



프로젝트 회고



GPTeacher's Day

Thank You

Git-hub

<https://github.com/GPTeachersDay>

Web Site

<http://leeyj85.shop/GPTeachersDay/>